

非完备信息下的联合循环机组性能 退化评估方法研究

(申请清华大学工学博士学位论文)

培 养 单 位： 能源与动力工程系

学 科： 动力工程及工程热物理

研 究 生： 宋 克 禹

指 导 教 师： 蒋 东 翔 教 授

二〇二六年三月

Research on Performance Degradation Evaluation Method of Gas-steam Combine Cycle Under Incomplete Information

Dissertation submitted to

Tsinghua University

in partial fulfillment of the requirement

for the degree of

Doctor of Engineering

in

**Power Engineering and Engineering Thermal
Physics**

by

Song Keyu

Dissertation Supervisor: Professor Jiang Dongxiang

March, 2026

学位论文公开评阅人和答辩委员会名单

公开评阅人名单

答辩委员会名单

关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：

清华大学拥有在著作权法规定范围内学位论文的使用权，其中包括：（1）已获学位的研究生必须按学校规定提交学位论文，学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文；（2）为教学和科研目的，学校可以将公开的学位论文作为资料在图书馆、资料室等场所供校内师生阅读，或在校园网上供校内师生浏览部分内容；（3）根据《中华人民共和国学位条例暂行实施办法》及上级教育主管部门具体要求，向国家图书馆报送相应的学位论文。

本人保证遵守上述规定。

作者签名：_____

导师签名：_____

日 期：_____

日 期：_____

摘 要

在“双碳”目标驱动下，燃气-蒸汽联合循环凭借高效率、低排放与快速响应能力，成为电力系统调峰的重要方式。准确评估设备性能退化对提升运行效率、降低维护成本至关重要，但生产环境下普遍存在非完备信息问题（测量信息、知识与状态信息不完备），制约了现有方法的应用。本文以联合循环为对象，围绕非完备信息条件下的性能退化评估开展方法研究，并在实际场景中验证。

针对联合循环电站在建模与负荷优化分配中存在的测量信息不完备问题，提出基于意外函数的联合循环不确定性建模与优化方法。实际运行数据验证表明，该方法能在测量不完备条件下建立设备性能模型，推算缺失参数、修正不准确参数，较现有方法具有更高鲁棒性和精度。基于所建模型研究“二拖一”机组负荷分配优化，给出燃机性能不对称时的偏置负荷分配策略，具有 0.3% 的燃料节约潜力。

针对生产环境下状态信息不完备问题中现有数据驱动方法对历史数据标注量 and 数据分布假设依赖性强的问题，提出基于自适应训练与伪标签的联合循环设备退化状态识别方法。公开数据集实验验证了该方法在降低标注依赖和数据分布假设方面的优势。在联合循环机组实际数据上应用，利用低成本标注建立了压气机进气滤网退化和汽轮机高压缸结垢退化的状态识别模型，结合部分负荷特性分析了退化影响、速率、趋势及原因，验证了识别精度。

针对生产环境下状态信息不完备问题，提出基于概率正-无标签学习的联合循环设备退化状态识别方法。公开数据集实验验证了该方法在利用运维记录时应对退化状态随机不确定性与认知不确定性的有效性，与现有方法相比在识别精度和鲁棒性上更优。在实际数据上应用，设计利用运维记录标注历史退化状态的方案，实现了对压气机进气滤网和汽轮机高压缸结垢退化状态的识别，降低了对历史数据和人工标注的依赖，提升了识别精度。

针对联合循环实际运行环境中测量信息与状态信息不完备并存的问题，提出基于联合学习的性能退化评估方法。基于实际电站运行数据及退化恢复记录的案例验证表明，该方法能在多种非完备信息共存条件下建立基准健康状态模型并实现性能退化评估，解耦工况、设备特性与性能退化。在一套联合循环机组上工程应用，实现了在线性能评估与负荷分配优化计算。

关键词：联合循环；燃气轮机；性能退化评估；非完备信息；不确定性

Abstract

Driven by the goals of carbon peaking and carbon neutrality, the gas-steam combined cycle has become a critical solution for peak load regulation in power systems due to its high efficiency, low emissions, and fast response capabilities. Accurately assessing equipment performance degradation is key to improving operational efficiency and reducing maintenance costs. However, the prevalence of incomplete information in production environments—including measurement incompleteness, knowledge incompleteness, and state information incompleteness—limits the practical application of existing methods. This paper focuses on performance degradation assessment under incomplete information for gas-steam combined cycles, conducting methodological research and validating its application in real-world scenarios.

To address the issue of measurement incompleteness in modeling and load optimization for combined cycle power plants, an uncertainty modeling and optimization method based on the surprise function is proposed. Validation using actual operational data demonstrates that the proposed method can establish performance models for combined cycle equipment under incomplete measurement conditions, infer missing parameters, and correct inaccurate ones, achieving higher robustness and accuracy compared to existing approaches. Based on the established performance model, the load allocation optimization problem for a "two-on-one" unit configuration is investigated, yielding a biased load allocation strategy and principle under asymmetric performance between the two gas turbines, with a potential fuel saving of 0.3%.

To overcome the limitations of existing data-driven methods, which heavily depend on labeled historical data and data distribution assumptions in addressing state information incompleteness, a degradation state identification method based on self-adaptive training and pseudo-labeling is proposed for combined cycle equipment. Numerical experiments on multiple public datasets, along with quantitative comparisons with existing methods, confirm the method's advantages in reducing dependence on labeled historical data and data distribution assumptions. Applied to actual operational data from combined cycle units, this method establishes state identification models for compressor inlet filter degradation and high-pressure cylinder fouling in steam turbines using low-cost data labeling, successfully identifying the degradation states of these components. Considering the off-

design characteristics of the equipment, the analysis further investigates the impact of degradation on equipment performance, as well as the degradation rate, trend, and underlying causes, validating the model's identification accuracy.

To further address the challenge of state information incompleteness, a degradation state identification method based on probabilistic positive-unlabeled learning is proposed for combined cycle equipment. Numerical experiments on multiple public datasets validate the effectiveness of the proposed method in handling both aleatoric and epistemic uncertainties inherent in operation and maintenance records. Quantitative comparisons with existing data-driven methods that utilize uncertain labels demonstrate the superiority of the proposed method in identification accuracy and robustness. When applied to actual operational data from combined cycle units, a scheme is designed and validated that leverages operation and maintenance records to label historical equipment degradation states, successfully identifying the degradation states of the compressor inlet filter and high-pressure cylinder fouling. This approach reduces the reliance on historical data and manual labeling while improving the accuracy of the degradation state model.

To address the coexistence of measurement incompleteness and state information incompleteness in real-world combined cycle operating environments, a performance degradation assessment method based on joint learning is proposed. Case studies using operational data and degradation/recovery records from an actual combined cycle power plant demonstrate that this method can establish a baseline health model and achieve performance degradation assessment under multiple coexisting forms of incomplete information, effectively decoupling the intertwined effects of operating conditions, equipment characteristics, and degradation. Implemented programmatically on a set of combined cycle units, the method achieves engineering application for online performance assessment and load allocation optimization.

Keywords: combined cycle; gas turbine; performance degradation evaluation; incomplete information; uncertainty

目 录

摘 要.....	I
Abstract.....	II
目 录.....	IV
插图清单.....	VII
附表清单.....	X
符号和缩略语说明.....	XII
第 1 章 绪论	1
1.1 研究背景及其意义	1
1.2 国内外研究动态	2
1.2.1 燃气-蒸汽联合循环系统概述.....	2
1.2.2 联合循环设备的退化机理.....	3
1.2.3 联合循环机组的设备退化评估方法研究现状.....	3
1.2.4 非完备信息问题.....	4
1.3 本文的主要研究内容	10
第 2 章 基于意外函数的联合循环不确定性建模与优化方法	12
2.1 引言	12
2.2 基础理论	13
2.2.1 不确定性量化.....	13
2.2.2 意外函数.....	13
2.3 基于意外函数的联合循环不确定性建模	15
2.3.1 建模方程.....	15
2.3.2 参数估计.....	21
2.4 方法验证	27
2.4.1 测量缺失条件下的建模性能对比.....	27
2.4.2 排气流量测量不准确条件下的燃气轮机建模.....	28
2.4.3 联合循环建模精度对比.....	30
2.5 联合循环负荷分配优化	33
2.5.1 负荷分配问题定义.....	33
2.5.2 优化问题求解.....	34
2.5.3 优化问题求解结果.....	35

2.5.4 负荷分配策略分析.....	36
2.6 小结.....	38
第 3 章 基于自适应学习与伪标签的联合循环设备退化状态识别方法	40
3.1 引言.....	40
3.2 理论基础.....	41
3.2.1 自适应学习.....	41
3.3 方法描述.....	42
3.3.1 联合循环设备退化状态识别算法整体流程.....	42
3.3.2 基于自适应伪标签的正-无标签状态识别算法.....	42
3.4 数值实验验证.....	46
3.4.1 数据集与实验设置.....	47
3.4.2 算法有效性的定量验证.....	50
3.5 联合循环设备性能退化状态识别应用案例	60
3.5.1 压气机进气滤网退化状态识别.....	61
3.5.2 汽轮机高压缸性能退化状态识别.....	66
3.6 小结.....	70
第 4 章 基于概率正-无标签学习的联合循环设备退化状态识别方法	72
4.1 引言.....	72
4.2 概率正-无标签学习算法设计	73
4.2.1 算法整体流程.....	73
4.2.2 基于运维记录和定性先验知识的概率标签构建.....	74
4.2.3 基于后验概率标签的风险估计器.....	77
4.2.4 在线设备状态识别.....	79
4.2.5 分类器模型选择.....	79
4.3 理论证明	80
4.3.1 风险估计器等价性证明.....	80
4.3.2 概率标签误差下的鲁棒性分析.....	81
4.3.3 数值案例.....	82
4.4 实验验证与分析	83
4.4.1 基准数据集上的算法分类能力评估	83
4.4.2 设备状态信息随机不确定性下的状态识别能力评估.....	87
4.4.3 设备状态信息认知不确定性下的状态识别能力评估	92

4.5 联合循环设备性能退化状态识别应用案例	95
4.5.1 压气机进气滤网性能退化状态识别	95
4.5.2 汽轮机高压缸性能退化状态识别	98
4.6 小结	101
第 5 章 基于联合学习的非完备信息下燃机性能退化评估	103
5.1 引言	103
5.2 方法描述	103
5.2.1 联合学习	103
5.2.2 方法流程	104
5.3 应用案例	106
5.3.1 数据基础	106
5.3.2 基准健康状态识别结果与特性曲线重建	107
5.3.3 燃气轮机性能退化评估	110
5.4 工程应用和程序开发	111
5.4.1 性能评估模块	112
5.4.2 负荷分配优化模块	115
5.5 小结	117
第 6 章 总结与展望	118
6.1 本文的主要内容及研究成果	118
6.2 本文的主要创新点	119
6.3 研究展望	120
参考文献	121
致 谢	131
声 明	132
个人简历、在学期间完成的相关学术成果	133
指导教师评语	135
答辩委员会决议书	136

插图清单

图 1.1	我国天然气供应量增长趋势 ^[6]	2
图 1.2	生产环境下可获取的数据特点	8
图 1.3	正-无标签学习、有监督学习、半监督学习和单类学习的训练数据构成 ..	9
图 1.4	本文的结构安排	10
图 2.1	联合循环机组的系统简图	22
图 2.2	1 号燃气轮机建模得到的关键性能参数曲线	25
图 2.3	1 号燃气轮机建模得到的关键性能参数曲线	26
图 2.4	高压缸模型和相关参数	27
图 2.5	通过余热锅炉高压蒸发器管道效率计算值分析燃机排气流量误差	30
图 2.6	模型 II 预测值与实际值对比	32
图 2.7	模型 I 和模型 II 预测误差分布	32
图 2.8	两台燃气轮机实际运行压比关系	35
图 2.9	优化后的联合循环机组两台燃机之间的负荷分配策略	35
图 2.10	优化后节约的燃料量	36
图 2.11	两台燃气轮机热效率随压比变化关系	36
图 2.12	联合循环热效率随总发电负荷变化关系	37
图 2.13	能量参数对燃料流率的敏感性分析	38
图 3.1	异常检测模型训练与在线评估流程	43
图 3.2	SatPU 算法整体流程	43
图 3.3	数据集 A 中的仿真信号示例 ^[114]	48
图 3.4	数据集 B 的数据样例 ^[115]	48
图 3.5	不同无标注样本比例下数据集 A 结果的 F1 分数对比	52
图 3.6	不同无标注样本比例下数据集 B 上 F1 分数对比	52
图 3.7	基于 PCA 降维的两个数据集数据分布对比	54
图 3.8	原始自适应训练算法 (Sat) 训练过程可视化	56
图 3.9	SatPU 算法训练过程可视化	57
图 3.10	各消融实验组在训练过程中的 F1 分数变化曲线	59
图 3.11	进气滤网差压数据示例	62
图 3.12	压气机滤网退化状态识别问题数据驱动模型识别结果	63
图 3.13	整体滤网差压与压比运行时间分布图	63

图 3.14	1 号压气机进气滤网历史退化趋势.....	64
图 3.15	压气机进气滤网退化状态标注.....	64
图 3.16	压气机滤网退化状态识别问题训练集模型输出与人工标注对比.....	65
图 3.17	压气机滤网退化状态识别问题测试集模型输出与人工标注对比.....	65
图 3.18	高压缸退化状态识别模型识别结果.....	67
图 3.19	高压缸等熵效率部分负荷特性.....	68
图 3.20	高压缸流量系数部分负荷特性.....	68
图 3.21	高压缸效率退化历史趋势.....	69
图 3.22	高压缸通流能力退化历史趋势.....	69
图 3.23	高压缸退化状态识别模型识别结果与人工标注退化状态对比.....	70
图 4.1	基于概率标签的正-无标签学习算法整体流程	74
图 4.2	概率标签生成示意图	76
图 4.3	nnPU 与 postPU 关于类别概率估计误差鲁棒性的对比实验	82
图 4.4	postPU 参数 r 的敏感性分析.....	87
图 4.5	训练标注构造示意图及监督基线模型检测结果	90
图 4.6	不同最大延迟 D 下各方法的 F1 分数对比.....	91
图 4.7	极端标注延迟条件下各模型识别结果对比	92
图 4.8	真实设备状态与模型识别结果对比	94
图 4.9	模型训练过程经验风险变化趋势	97
图 4.10	训练集状态识别模型输出.....	98
图 4.11	状态识别模型输出与人工标注对比.....	98
图 4.12	高压缸退化状态训练集标注及识别结果.....	100
图 4.13	高压缸退化状态识别模型识别结果和实际退化状态对比.....	100
图 4.14	高压缸效率退化程度每月变化趋势分析.....	101
图 5.1	联合电厂运行期间汽轮机和两台燃气轮机 (GT1,GT2) 发电功率历史数据	106
图 5.2	运行历史数据中两台燃气轮机热效率与压比关系	107
图 5.3	燃气轮机设备健康状态定性标注结果	108
图 5.4	算法对两台燃气轮机历史健康状态识别结果	109
图 5.5	算法对两台燃气轮部分负荷下热效率特性曲线的建模结果	109
图 5.6	两台燃气轮基准状态热效率与实际热效率的关系	110
图 5.7	使用全部数据建模时模型热效率与实际热效率的关系	110
图 5.8	两台燃气轮机退化在对其热效率的影响随时间变化趋势	111

图 5.9	性能评估模块的程序输出案例	115
图 5.10	性能评估模块的输出案例.....	115
图 5.11	负荷分配优化模块的程序输出案例.....	116
图 5.12	负荷分配优化模块的输出案例.....	116

附表清单

表 2.1	意外函数逻辑运算对应关系	14
表 2.2	典型定性表述的意外函数转换	14
表 2.3	燃气轮机设计参数	23
表 2.4	余热锅炉设计参数	23
表 2.5	汽轮机设计参数	24
表 2.6	供热系统设计参数	24
表 2.7	稳态数据筛选阈值和最小值设定	25
表 2.8	建模相关参数	28
表 2.9	建模输出参数精度对比	28
表 2.10	根据不同燃机流量值计算的高压蒸发器管道效率	31
表 2.11	模型 I 与模型 II 预测性能指标对比	31
表 2.12	决策变量及取值范围	33
表 3.1	数据集 A 上各对比方法性能指标汇总	51
表 3.2	数据集 B 上各对比方法性能指标汇总	53
表 3.3	仿真数据集 A 上的消融实验结果	58
表 3.4	压气机进气滤网退化识别模型输入参数	61
表 3.5	压气机进气滤网状态识别模型性能指标	66
表 3.6	高压缸退化状态识别模型输入参数	66
表 4.1	正-无标签风险估计器在概率标签估计误差下的鲁棒性比较	83
表 4.2	基准数据集样本数量统计	84
表 4.3	基准数据集上正-无标签学习条件下对比实验 F1 分数结果	85
表 4.4	基准数据集上正-无标签学习条件下的识别性能详细指标	85
表 4.5	使用粗略猜测后验概率时 postPU 的 F1 分数性能指标	86
表 4.6	无直接状态标注条件下各对比算法状态识别性能定量指标	95
表 4.7	燃气轮机进气滤网设备维护记录	96
表 4.8	基于更换时间的进气滤网退化状态定性标注规则	96
表 4.9	压气机进气滤网状态识别模型性能指标	99
表 4.10	基于维护时间的高压缸退化状态定性标注规则	99
表 5.1	燃气轮机进气滤网设备维护记录	108
表 5.2	基于退化恢复时间的设备健康状态定性标注规则	108

表 5.3	性能评估模块输出的性能参数	112
-------	---------------------	-----

符号和缩略语说明

α_f	空燃比
α_c	压气机抽气系数
$\dot{m}$	质量流量 (单位: kg/s)
$\dot{m}_c$	压气机质量流率 (单位: kg/s)
$\dot{m}_f$	燃料质量流率 (单位: kg/s)
$\dot{m}_t$	燃机透平工质质量流率 (单位: kg/s)
$\dot{Q}_{sg}$	余热锅炉总换热功率 (单位: MW)
$\dot{W}_c$	压气机耗功率 (单位: MW)
$\dot{W}_t$	燃机透平输出功率 (单位: MW)
$\dot{W}_{gt,e}$	燃气轮机发电机发电功率 (单位: MW)
$\dot{W}_{st,e}$	汽轮机发电机发电功率 (单位: MW)
η_c	压气机等熵效率 (单位: %)
η_t	燃机透平等熵效率 (单位: %)
η_{cc}	燃烧效率 (单位: %)
η_{gt}	燃机整机热效率 (单位: %)
η_m	机械效率 (单位: %)
η_e	发电机效率 (单位: %)
F_t	燃机透平流量系数 (单位: kg · K/(s · MPa))
F_{ht}	高压缸流量系数 (单位: kg/(s · MPa))
κ	比热容比
π_c	压气机压比
π_t	透平膨胀比
$\pi_{ht,0}$	高压缸设计膨胀比
σ_{cc}	燃烧室总压恢复系数
c_p	定压比热容 (单位: J/(kg · K))
h	比焓 (单位: J/kg)
p	压力 (单位: Pa)
q_{LHV}	燃料低位热值 (单位: J/kg)
T	温度 (单位: K)
$T_{t,in}$	透平入口总温 (单位: K)
$p_{t,in}$	透平入口总压 (单位: MPa)

$\dot{m}_{ms}$	高压主蒸汽流量（单位：kg/s）
$\dot{m}_{ias}$	中压补汽流量（单位：kg/s）
$\dot{m}_{rs}$	再热蒸汽流量（单位：kg/s）
$\dot{m}_{las}$	低压补汽流量（单位：kg/s）
$h_{sg,w,in}$	余热锅炉蒸汽侧入口比焓（单位：kJ/kg）
$h_{sg,a,out}$	余热锅炉烟气侧出口比焓（单位：kJ/kg）
$\dot{m}_{ex}$	抽汽质量流量（单位：kg/s）
$\dot{W}_{ex}$	抽汽做功能力（单位：MW）
$\dot{m}_{heat}$	热网回水质量流量（单位：kg/s）
$\dot{Q}_{heat}$	供热换热量（单位：kg/s）
LHV	低位热值（单位：MJ/kg）
IGV	压气机进口导叶
HV	余热锅炉高压蒸发器
SAT	自适应学习算法
LSTM	长短时记忆神经网络
下标 in	进口参数
下标 out	出口参数
下标 0	基准工况（设计工况）参数
上标 *	等熵理想状态
下标 c	压气机相关参数
下标 t	燃机透平相关参数
下标 cc	燃烧室相关参数
下标 ht	高压缸相关参数
下标 it	中压缸相关参数
下标 lt	低压缸相关参数
下标 sg	余热锅炉相关参数

第 1 章 绪论


1.1 研究背景及其意义

随着世界经济的持续发展，资源与环境约束问题日益凸显，在此背景下，中国政府于 2020 年 9 月在联合国大会中宣布了中国设立碳达峰与碳中和（“双碳”）目标的重大战略决策^[1]。作为重点管控的八大行业之一，电力行业肩负着能源转型与保障能源安全的双重使命^[2]。

燃气-蒸汽联合循环（Gas Turbine Combined Cycle, GTCC）机组是以燃气轮机、余热锅炉、汽轮机和发电机为核心设备、以天然气为燃料的实现热功转化的发电系统。联合循环具有高效率、低排放和快速响应能力的特点。首先，联合循环是所有大规模发电方式中热效率最高的发电系统。成熟的 9F 级热效率达 58.9% ~ 60.7%，高于压力最高的 37.5MPa 的超超临界燃煤机组^[3]。先进的联合循环热效率更可提升至 60 ~ 61%，若考虑热电联供，其总的能源利用效率可以达到 75%^[4]。此外，天然气燃料使联合循环成为一种清洁发电技术，氮氧化物排放可控制在 15 mL/m³ 以内，其二氧化碳排放强度约为超临界燃煤电站的 40%，并且完全消除了二氧化硫和粉尘的排放^[4]。系统中燃气轮机所具备的快速启停和优异负荷响应特性，更使得 GTCC 非常适用于需要灵活调峰的运行场景。

在“双碳”目标驱动下，燃气-蒸汽联合循环的上述特性凸显出其重要价值。天然气作为相对清洁的化石能源，已成为全球能源总需求中唯一保持增长的化石燃料^[5]。相应地，如图 1.1 所示，我国正有计划地扩大天然气利用规模^[6]，近年供应量呈现显著上升趋势。与此同时，能源转型加速推进，风能、光伏等可再生能源占比不断提升。然而，此类非化石能源固有的强间歇性与随机性，对电网消纳能力构成巨大挑战^[7]。《“十四五”现代能源体系规划》^[8]明确指出，需要进一步建设天然气调峰电站，以提升发电侧的协调运行能力。燃气-蒸汽联合循环电站具有大幅度变负荷的能力，最小负荷可低至最大负荷的 20%^[9]，是满足这一调峰需求的理想选择。

在“双碳”目标驱动下，联合循环发电技术既迎来发展机遇，也面临新的挑战与要求。其中，承担可再生能源消纳的调峰任务已成为联合循环机组的重要工作，但该任务导致两方面关键问题：一方面运行工况偏离设计点，机组长期在非设计工况下运行，造成热效率与经济性下降^[10]。另一方面负荷频繁调整，调峰需求迫使机组频繁启停及快速变负荷，加剧核心设备损耗并推高运维成本。具体而言：对于机械部件，启停过程中转子经过临界转速时易诱发共振，加速疲劳损伤，尤其

图 1.1 我国天然气供应量增长趋势^[6]

对共振裕度较低的压气机静叶影响显著^[11]；对于热端部件，温度的剧烈变化会引发低周热疲劳损伤，其机理在于启停阶段材料反复承受温度应力，导致非均匀膨胀/收缩，进而破坏微观结构^[12]。受我国天然气价格高及燃气轮机维护成本高昂的影响，联合循环机组发电成本达燃煤机组的 2~3 倍。因此，如何通过监控和控制设备退化来降低运维成本，已成为推动联合循环技术发展的关键问题之一^[13]。

随着运行时间累积，设备损耗不可避免，其渐进累积过程即构成设备的退化。在联合循环机组中，核心热功转化设备（燃气轮机、汽轮机）及换热设备（余热锅炉）的退化将导致热效率、通流能力等关键性能指标的变化，并偏离设计值^[14]。退化会削弱机组经济性，同时随退化程度加深，设备特性偏移可能需要重新整定控制参数与策略；当退化发展至严重阶段，故障概率的激增更将迫使停机维护。传统定期维护模式已难以满足现代能源设备的精细化需求——尤其对于燃气轮机等高价值复杂设备，且可再生能源消纳带来的负荷波动不确定性进一步要求运维的智能化，因此基于先进数据分析的预测性维护技术成为学界与工业界关注的焦点^[15]。政策层面，根据我国《“十四五”智能制造发展规划》^[16]的部署，需要强化装备的安全保障能力，并将装备预测性维护技术作为重点研发方向。预测性维护技术需以性能退化评估为基础，结合联合循环机组的热力学建模与性能计算。尤其在在我国燃气轮机关键技术仍高度依赖进口的背景下^[4,17]，深入研究其性能演变规律与退化机制，对提升燃气轮机及联合循环系统的技术自主可控性具有重要价值。

1.2 国内外研究动态

1.2.1 燃气-蒸汽联合循环系统概述

典型燃气-蒸汽联合循环系统的热力过程包含三个核心环节：以空气-燃气混合气体为工质的燃气轮机顶循环（遵循近理想气体行为的布雷顿循环），以水蒸气为

工质的汽轮机底循环（涉及气液两相转变的朗肯循环），以及连接二者的余热锅炉换热系统。在顶循环中，压气机消耗部分轴功将过滤空气加压送入燃烧室，燃料在此发生化学反应释放化学能并转化为工质内能；高温高压烟气随后在透平中膨胀做功，驱动发电机输出电能。燃气轮机透平排气仍具有 500℃ 以上温度，经余热锅炉回收余热以加热底循环工质。底循环工质（水蒸气）在余热锅炉中吸热后，推动多级蒸汽透平膨胀做功，乏汽进入凝汽器冷凝后由给水泵加压返回循环，蒸汽透平同样驱动发电机实现能量转化。

实际的联合循环更为复杂，汽轮机高压缸与中压缸间增设再热流程提升效率，配置冷却与轴封抽气，并有大量蒸汽分流用于供热。此外，机组的组合配置呈现多样性，如两台燃气轮机配两台余热锅炉及一台汽轮机的“二拖一”结构，一台燃气轮机配一台余热锅炉及一台汽轮机的“一拖一”结构等。多台燃机与汽轮机不同启停组合及负荷状态，构成了联合循环系统复杂的运行状态^[18]。

1.2.2 联合循环设备的退化机理

联合循环机组设备的性能退化（performance degradation）指设备随着运行时间累积必然出现的部件特性和性能参数逐渐偏离设计值的过程。当前的研究对这种退化的成因和机理给出如下的分析和解释：

燃气轮机气路部件的性能退化：Diakunchak^[19]研究了典型燃机气路故障及其影响，结垢（fouling）源于空气中杂质沉积，通过改变通流几何形状降低通流能力与效率，但可通过清洗恢复；而由化学反应引发的腐蚀（corrosion）及杂质冲击造成的侵蚀（erosion）则导致永久性结构损伤，表现为流量异常增大与效率下降。

余热锅炉的性能退化：Marner et al.^[20]分析了换热部件的结垢，结垢会导致局部超温和整体换热效率的下降。管路的泄漏则会导致压力损失和换热效率下降。

汽轮机的气路性能退化：Zwebek et al.^[21]通过仿真研究了联合循环中汽轮机性能退化对机组性能的影响。与燃机透平的性能退化机理类似，汽轮机结垢会降低通流能力与热效率，其腐蚀则反向增大通流能力但同步降低效率。

1.2.3 联合循环机组的设备退化评估方法研究现状

设备退化是一个复杂的过程，为定量表征设备在特定状态下的退化程度，需要构建一个或多个退化指标。根据国内外现有研究，退化程度的表征方法主要可分为以下四类：

第一类直接以测量参数作为退化指标。例如，Martha 与 Vatani^[22-24]通过燃机透平排气温度评估燃气轮机退化程度，而沙俊辉^[25]则采用燃机出力作为评估指标。然而，此类方法存在局限性，仅适用于仿真或试验环境下的恒定工况数据，难以在

实际生产中应用。

第二类以具有物理含义的性能参数作为退化指标，这些参数包括燃气轮机和汽轮机的效率、流量^[10,26-30]以及进气压力损失^[31-32]等关键性能指标。

第三类方法引入了退化因子作为性能指标，即通过性能参数与设计值的比值得到无量纲系数，以此表征设备退化程度^[3,33-36]。此类方法适用于宽工况运行的设备。

第四类方法逆向构建退化指标。Simon^[37]在燃气轮机模型中引入隐含变量作为健康度指标，并基于健康度指标单调下降且变化缓慢的假设，实现退化评估的逆向求解。Giantomassi^[38]和白玉金^[39]等学者则将设备剩余寿命（Remaining Useful Life, RUL）定义为健康程度指标，通过数据驱动方法，利用设备历史状态距离失效的时间来确定其退化程度。曹启威^[40]则采用设备维修前后的性能状态作为退化和健康的基准，假设退化过程设备状态连续变化，以此定义退化程度。Que^[41]基于生成式对抗网络，在最小化损失函数的条件下迭代确定汽轮机的健康度指标。

第二类和第三类方法均以联合循环设备的性能模型为基础。联合循环机组的热力学机理建模面向性能计算与退化评估，需建立燃气轮机、余热锅炉及汽轮机在稳态工况下的输入/输出参数与内部状态变量之间的定量关系。该建模框架包含三个核心部分：顶循环基于压气机折合参数特性曲线，结合燃烧室与透平的做功及温变规律构建燃机部分负荷模型；余热锅炉通过能量平衡方程、传热微分方程及整体传热系数经验公式，求解换热温差、传热量与压损；底循环基于水蒸气热物性参数与弗留格尔公式（表征透平压力-流量关系）建立汽轮机部分负荷模型。

综合上述研究现状，联合循环的热力学机理建模在实际应用中，仍然需要对部件特性缺失和测量不完备、不可靠的挑战。

1.2.4 非完备信息问题

在理想的仿真环境下，研究者可以精确控制输入条件、系统参数和模型结构，从而获得相对完备的信息。然而，在实际生产环境中，各类信息均存在不同程度的不完备性，以下描述非完备信息的分类，并分别阐述各类非完备信息的具体表现和研究现状。

1.2.4.1 设备性能退化评估问题

设备的建模问题可抽象为如下数学形式：

$$y = M_S(\theta; u, x) \quad (1.1)$$

其中, y 表示模型输出, u 为控制变量, x 为输入变量, θ 为模型参数, M_S 表示在状态 S 下成立的模型结构。下标 S 涵盖了设备的运行工况、异常状态以及退化状态等条件信息。根据信息类型, 可将非完备信息划分为三类:

测量信息: 指在系统特定位置获得的具有明确物理含义及单位的数值, 如温度、压力、流量等状态参数。在式 (1.1) 中对应输出变量 y 、输入变量 x 和控制变量 u 。

知识: 包括设备的物理原理、数学方程、特性曲线、经验公式、模型结构及其参数分布等, 对应式 (1.1) 中的模型结构 M_S 和模型参数 θ 。

状态信息: 指设备的运行工况、异常状态及退化状态, 对应式 (1.1) 中模型成立的条件 S 。

1.2.4.2 测量信息不完备

测量信息是建立设备模型与判定退化状态的关键依据。但在生产环境下, 测量信息的获取受到诸多限制与干扰, 普遍存在测量信息不完备问题, 主要表现为测量不确定性与测量缺失两方面^[42]。

测量不确定性包含随机不确定性与认知不确定性。随机不确定性源于传感器测量原理限制、校准状态漂移、环境干扰等因素, 导致测量值存在不可避免的随机误差。例如, 在联合循环电站中, 工质流量对性能计算至关重要^[43-44], 但流量计通常通过测量流体速度或压力间接计算流量, 此过程引入较高不确定度^[45-46]。认知不确定性则来自模型不完善或参数缺乏, 导致传感器实测值与设备机理模型对应物理量之间存在系统偏差。以抽凝汽轮机为例, 抽汽参数测点位于汽轮机外部, 蒸汽流经管路时产生压降与散热, 使得实测参数与内部实际蒸汽参数存在偏差。两类不确定性在生产环境中普遍共存, 共同构成测量信息的随机与认知不确定性问题。

测量缺失包括测点完全缺失与数据部分缺失两种情况。测点完全缺失往往由传感器布置的客观限制造成: 某些关键参数因环境恶劣无法直接测量 (如燃气轮机燃烧室温度)、或因几何条件无法安装传感器 (如孔板流量计要求足够长度的直管段^[47])、或因技术难度难以测取 (如汽轮机低压缸末级湿蒸汽状态^[48])。数据部分缺失则源于传感器可靠性不足或数据传输中断, 进一步加剧了测量信息的不完备性。

针对联合循环热力设备建模过程中存在的测量信息不完备问题, 现有研究方法在正向建模基础上, 引入了基于测量数据的逆向求解方法, 以推算部分未知参数。在汽轮机低压缸效率计算中, 排汽干度无法直接测量导致排汽焓难以确定。针对这一问题, 项博超^[29]基于各汽缸有效功率占比保持不变的假设, 利用热平衡设

计值推算低压缸功率占比，进而间接确定排汽焓值。在燃气轮机性能分析中，燃料量及组分信息常出现缺失或测量不准确。对此，刘佳^[49]假设在进口导叶（IGV）大开度下压气机处于阻塞状态，且透平在退化过程中通流能力保持不变，通过引入通流能力方差，利用性能试验数据确定流量，从而弥补方程求解所需条件的不足。

现有研究针对测量缺失问题给出了通过引入额外参数、假设和方程补偿缺失测点的方法。然而，现有方法对实际生产环境中普遍存在的测量不确定性问题关注较少，尚未对不同类型的测量不确定性开展系统性的理论分析，亦未形成对应的通用处理方法。

1.2.4.3 知识不完备

设备知识的不完备性主要体现在模型结构 M_S 和关键参数 θ 的缺失，例如缺乏精确的部件特性图、未知的退化机制、保密的设计参数等。针对知识完备程度的不同，现有建模方法可分为三类：

机理驱动（白盒模型）：基于守恒方程建立设备的热力学模型，可模拟稳态或瞬态性能^[50]。然而，此类方法的精度高度依赖于部件级特性曲线（如压气机的压比-效率图），这些曲线通常由制造商通过台架试验获得并作为商业机密，难以获取^[51]，限制了纯机理模型在实际工程中的直接应用。

数据驱动（黑盒模型）：针对机理知识不完备的问题，形成了一类基于数据的建模方法，通过拟合设备的输入与输出参数，构建描述其映射关系的黑盒模型（Black-box model）。例如，Sadrian et al.^[52]采用黑盒模型分析了入口滞止温度与级压比两个设计变量对汽轮机级性能的影响，并基于该模型实现了级损失的优化。纯数据的黑盒模型虽能有效捕捉高度非线性关系，但其内部参数通常缺乏明确的物理意义，导致模型的可解释性较差^[53]。

融合模型（灰盒模型）：灰盒模型（Grey-box model）旨在融合数据驱动方法（黑盒模型）与物理机理模型（白盒模型）的优势。其核心在于利用现场运行数据或有限的试验数据，对机理模型中的不确定参数进行修正与补偿。在系统复杂或领域知识不完备，难以建立纯机理模型的场景下^[54]，灰盒模型通过将部分已知的领域知识（如物理定律、守恒关系、系统结构信息）与运行数据相结合，能够在一定程度上克服单一建模方法的局限性，从而在模型的可解释性与对知识不完备问题的适应性之间取得平衡^[55]。

针对燃气轮机全工况特性曲线因制造商技术保护而难以获取的问题，杨承等^[10]与孟成^[56]提出采用典型的压气机与透平效率特性曲线，并通过运行数据拟合修正系数，以实现模型与实际机组的匹配。秦祖志等^[57]则将环境温度、负荷

等参数作为调度变量,构建了参数线性变化的灰盒模型,用于描述燃气轮机性能随工况的非线性变化关系。Wang et al.^[58]采用多项式或神经网络对压气机与透平的通用特性曲线进行拟合与外推。Ying et al.^[59]在热力学模型框架内引入经验修正项,以补偿模型预测与实际设备运行之间的偏差。王一丰等^[60]针对余热锅炉的高、中、低压汽包,分别基于能量平衡方程构建了机理模型框架,并利用历史运行数据辨识了总传热系数及烟气侧压降特性等关键参数。该方法通过数据驱动的方式确定了模型中的不确定参数,提升了模型对特定实际设备的模拟精度,并应用该模型预测了不同燃气轮机排烟条件下的产汽量与蒸汽参数。

上述方法通过利用实测数据,在一定程度上缓解了知识不完备带来的建模难题,并提高了模型在已知工况下的预测精度。然而,这类模型的泛化能力与物理可解释性仍显不足。当模型应用于未经历过的故障模式或极端工况时,其外推性能通常会显著下降,难以保证预测结果的可靠性。

1.2.4.4 状态信息不完备

状态信息包括设备的运行工况、异常状态以及设备的退化状态,设备的模型需要在一定的状态下生效,在不同的状态下比如不同工况或不同退化状态,可能需要不同的模型来描述设备。一方面,设备的物理或数据驱动模型仅在特定状态下有效,这意味着必须构建状态条件化的模型族,使得建模问题显著复杂化^[61]。另一方面,状态信息本身的识别具有直接的工程价值,如异常识别与退化评估,实时的异常识别能够为现场的生产运行提供预警信号,提高生产运行的安全性。

首先针对状态信息本身的识别问题如特定设备的异常识别问题,传统方法包括基于物理模型的方法和基于规则的方法,在面对更加复杂的设备和环境时展现出局限性^[62]。基于物理模型的方法起源于控制理论和系统辨识^[63]。其核心思想是建立被监控对象的精确数学模型,然后将实际系统行为与模型预测行为进行比较来检测设备状态是否存在异常^[64]。基于物理模型的方法要求建立高度精确的数学模型来描述被监控系统,复杂的系统和设备往往难以建立完全准确的解析模型,因为系统内部机制可能高度非线性、时变且包含未知或难以量化的因素^[65-66]。在人工智能早期,专家系统被引入故障诊断领域,旨在将人类专家的知识 and 经验编码为规则或逻辑,以实现自动化诊断,属于基于规则的方法^[67-68]。专家系统方法严重依赖于针对具体设备和领域经验丰富的专家提供详细的知识获取,而知识的编码过程复杂、耗时依赖人工且容易出错^[69]。

针对上述方法的难点,基于数据的方法逐渐发展成为研究热点。数据驱动方法通过格式化的输入数据和标注的设备状态标签,在优化迭代过程中逐步降低模型误差,从而在不依赖物理方程的条件下构建满足性能要求的状态识别模型。随

着人工智能领域的发展，数据驱动方法相继发展出了支持向量机^[70]、全连接神经网络^[71]、深度神经网络^[72]等模型，其非线性拟合能力越来越强。

随着发电机组系统的数字化，能够对生产现场的不同传感器的数据进行统一的采集存储和分析，如火电分布式控制系统（DCS），使得数据驱动方法所需的大量数据能够以较低成本获得。早期的异常状态识别研究以有监督学习为主，典型方法^[73-74]要求所有训练数据均带有准确的状态标签。随着机器学习技术的发展，各类神经网络结构相继被提出，并在模拟或实验数据集上表现出良好性能^[75-76]。然而，在工业异常检测的实际应用中，获取大量标注的异常实例极为困难，主要原因包括：其一，在真实工业系统中主动生成异常样本几乎不可行，且设备运行工况复杂、异常状态可能为新型或极其罕见、退化过程隐含且难以准确观测^[77-78]；其二，运行中的工业系统异常记录十分稀少^[79]；其三，即使发生异常，也通常依赖周期性检查（周期从一天到一个月不等）进行记录，异常发生的精确时间难以追溯。上述因素导致有监督方法在实际部署中面临严峻挑战。生产环境下可获取的数据特点如图1.2所示：通过实验或人工标注获得的有标注数据价值最高但数量稀缺，而来自数字化监测系统的无标注数据数据量大、易于获取。




图 1.2 生产环境下可获取的数据特点

鉴于标注数据的稀缺性，无监督学习方法被广泛采用。这类方法通常对正常数据的分布进行建模，并基于预定义的距离或差异度量检测异常。另一种常见形式为单类学习状态识别方法^[80-82]，其利用基于距离的方法对正常状态的数据特征建模，与多元统计方法^[83]（如主成分分析）的框架相似：通过历史记录建立正常状态模型，再评估新测量值相对于基线的偏差。单类学习仅使用正常状态数据进行训练，避免了从历史记录中人工挑选异常数据，但往往导致较高的误报率^[79]。

为在保持可接受精度的同时降低标注成本，研究者进一步提出了半监督学习方法^[84-85]，旨在利用稀缺但存在的标注数据中的标签信息。半监督异常检测同时使用标注数据提升检测精度，并结合未标注原始数据提高数据利用效率。在无监督方法表征学习能力的基础上，半监督方法进一步整合有限的监督信息，如部分

标签或关于异常特征的先验知识。图1.3对比了不同状态识别方法的训练数据构成模式，现有主要研究方向包括如下几类：

自监督学习：先在无标签数据上通过预定义任务进行预训练，再使用少量标注样本在下游异常检测任务中微调。在工程实践中，研究者利用预训练模型生成伪标签以丰富训练数据^[86-91]。

生成模型数据增强：一类方法通过如 Mixup^[92]的插值方式，线性或非线性组合样本并加入随机噪声生成合成样本；另一类方法基于生成对抗网络（generative adversarial network, GAN），学习正常或异常模式的数据分布并生成合成异常样本，以弥补真实异常实例的稀缺^[93-94]。

对比学习：通过拉近正样本对、推开负样本对来学习判别性表示。在半监督异常检测中，对比模型利用该框架增强判别能力，并结合标签传播技术（如 k 近邻分配或图扩散）为无标签实例赋予标签^[95-96]。

迁移学习与领域自适应：通过从相关源领域迁移知识，在目标领域数据有限的情况下实现有效模型训练^[97-98]。






问题模式	训练标签	训练集实际状态类别	模型
正-无标签学习			分类模型
半监督学习			分类模型
有监督学习			分类模型
单类学习			距离和阈值

图 1.3 正-无标签学习、有监督学习、半监督学习和单类学习的训练数据构成

正-无标签（Positive-Unlabeled, PU）学习^[99]是半监督学习的一个特殊分支，其训练集中仅包含正样本和无标签样本。在异常状态识别任务中，正-无标签学习能够仅利用一个类别的标签训练分类器，从而显著降低标注成本，同时保持可接受的检测精度。该框架在训练集中无需标注的异常数据：相较于稀缺的异常样本，标

注的正常状态数据相对容易获取，例如设备寿命早期或长期稳定运行期间的测量记录可作为可靠的正常状态数据。正-无标签学习通过引入先验概率校正假阴性样本的影响。尽管该框架提供了有前景的解决方案，但传统正-无标签学习设置对异常识别问题进行了简化：其忽略了假阳性的存在，且未考虑无标签数据集中不同样本的概率差异。这些简化假设在实际生产应用中往往难以满足。

1.3 本文的主要研究内容

本论文研究非完备信息条件下的联合循环机组性能退化评估问题。全文共分为六个章节，结构安排如图1.4所示。其中，第一章绪论介绍研究背景和研究意义，同时论述非完备信息的概念并总结现有研究方法，根据信息类别将非完备信息问题划分为测量信息不完备、知识不完备和状态信息不完备三类子问题；后续第二章至第四章分别针对测量信息不完备问题和状态信息不完备问题开展方法研究，第五章综合前文提出的方法，针对联合循环同时存在多种非完备信息的场景开展应用研究，第六章总结整篇论文。




图 1.4 本文的结构安排

第一章为绪论。首先阐述联合循环机组及其性能退化评估的研究背景与意义，分析实际生产环境中存在的非完备信息问题。在此基础上，根据信息类别将非完备信息划分为测量信息不完备、知识不完备和状态信息不完备三类子问题，并综述相关领域的研究现状，最后概括论文的总体结构。

第二章针对燃气轮机联合循环机组在建模与负荷优化分配中存在的测量信息不完备问题，提出基于意外函数的联合循环不确定性建模与优化方法，在实际数据上验证了方法的精度和鲁棒性，并在测量不确定和数据缺失条件下建立了联合

循环机组设备性能预测模型。在所建模型的基础上，分析多燃机联合循环机组在燃机效率不对称条件下的偏置分配策略。第二章的方法研究为第五章的应用研究提供了针对测量信息不完备问题的应对方法。

第三章针对状态信息不完备问题，提出基于自适应学习与伪标签的联合循环设备退化状态识别方法，实现了在不依赖设备部分负荷特性且历史退化状态数据稀缺条件下的退化状态识别。通过在公开数据集上的对比实验验证了所提方法对历史数据的标注数量和数据分布假设的依赖程度更低。在联合循环运行机组的实际数据上应用了该方法，实现了对压气机进气滤网退化和汽轮机高压缸结垢退化的状态识别，并分析了退化对性能的影响程度、退化速率、退化趋势和退化因素。第三章的方法研究提升了数据驱动的退化状态识别方法在标注稀缺和数据分布假设较弱的联合循环生产环境下的适用性，为第四章进一步研究如何利用联合循环运行维护记录所含的不确定性状态信息提供了基础支撑。

第四章针对状态信息不完备问题，提出基于概率正-无标签学习的联合循环设备退化状态识别方法，通过结合联合循环机组运行维护记录与定性假设推断设备历史退化状态，并建立退化状态识别模型。通过理论推导以及在公开数据集上的对比实验验证了该方法对状态信息随机不确定性和认知不确定性的鲁棒性更强。在联合循环运行机组的实际数据上应用了该方法，实现了对压气机进气滤网退化和汽轮机高压缸结垢退化的状态识别，设计和验证了利用滤网更换记录和汽轮机维护记录间接推断退化状态的方案，在第三章的基础上进一步提升了退化状态识别模型的精度。第四章的方法研究同时为第五章的应用研究提供了针对状态信息不完备问题的应对方法。

第五章针对联合循环实际运行环境中多种非完备信息并存的问题，提出一种基于联合学习的燃气轮机性能退化评估方法。该方法融合第二章和第四章提出的意外函数与概率正-无标签学习方法，分别处理建模过程中的测量信息不完备和状态标注不完备问题。通过定义协同损失函数，实现特性模型回归与性能退化状态识别任务的协同训练。基于实际联合循环电站的测量数据，结合滤网更换和压气机水洗等退化恢复记录，构建燃气轮机热效率的基准健康状态模型，并实现性能退化识别。最后，介绍与本文内容相关的工程应用与程序开发。

第六章总结全文研究内容，归纳主要创新点，并展望未来研究方向。

第2章 基于意外函数的联合循环不确定性建模与优化方法

2.1 引言

燃气-蒸汽联合循环是高效、清洁且具备快速响应能力的发电系统。经济性是衡量联合循环运行水平的核心指标之一，而系统中多台设备的工况选择与匹配关系直接影响热效率与经济性。因此，运行优化通过确定机组间负荷分配方案，对维持系统经济性具有关键作用。然而，电力系统调峰需求迫使联合循环机组频繁变负荷与启停：一方面导致运行工况长期偏离设计点，使机组在宽工况范围内运行；另一方面加剧压气机、透平、余热锅炉等核心设备的疲劳损耗，使设备实际特性逐渐偏离出厂设计参数。上述因素共同构成宽工况运行与设备特性漂移的双重挑战，增加了运行优化问题的复杂性。生产环境下测量信息普遍存在不完备问题，需要在优化过程中引入不确定性建模方法。测量不完备的具体表现包括：燃气轮机燃烧室温度因环境恶劣无法直接测量、汽轮机低压缸末级湿蒸汽状态难以测取、孔板流量计受直管段条件限制无法安装等。现有不确定性建模研究在模型构建与优化求解的衔接方面存在局限，所建概率模型在处理约束条件与目标函数时难以直接与成熟的确定性优化求解器结合，限制了其在工程优化问题中的适用性。另一方面，多拖一构型的联合循环机组中，不同燃气轮机之间可能因制造差异、运行历史或维护状态不同而存在效率差异，但现有运行优化研究对此类不对称性考虑不足，尚未系统揭示基于效率差异的最优负荷分配策略及其理论依据。

针对上述问题，本章提出基于意外函数的联合循环不确定性建模与优化方法。意外函数通过在近似表示不确定性概率分布的基础上，将概率分布上的函数运算转化为实数算术，从而能够与确定性优化求解器直接结合，应对生产环境下的测量不确定性问题。基于该方法建立联合循环系统负荷预测模型，进而讨论多台燃气轮机存在效率差异情况下的理论上最优负荷分配策略。本章节针对非完备信息问题下测量信息不完备的子问题开展方法研究，后续内容安排如下：2.2节描述不确定性量化的基础理论；2.3节描述建立联合循环负荷预测模型的具体过程，包括所用到的热力学方程和设备特性方程；2.4节在通过与联合循环机组实际测量数据定量对比，验证所提方法的有效性和精度；2.5节在已建立的联合循环负荷预测模型的基础上求解最优负荷分配策略并分析了其物理依据。

2.2 基础理论

现有研究在处理联合循环测量不确定性、测量缺失以及优化存在缺乏统一框架的不足，本节在不确定性量化理论中意外函数（Surprise Function）的理论基础上并提出一种基于意外函数的联合循环不确定性建模与优化方法。

2.2.1 不确定性量化

在不确定性量化研究中，概率理论与非概率理论是处理不确定性的两种主要框架。概率理论基于安德雷·柯尔莫哥洛夫（Andrey Kolmogorov）于1933年提出的公理化体系，其非负性、归一性和可数可加性三条公理（Kolmogorov Axioms）将概率论纳入测度论框架，从而能够对随机事件进行精确的数学描述与推断。基于概率论的不确定性量化方法通常需要充足的统计数据来构建精确的概率分布，即要求对事件发生频率具备充分的统计支持^[100-101]。当存在信息稀疏、信息模糊或涉及主观判断时，则需要引入非概率理论^[102]。

非概率理论以可能性理论（possibility theory）为基础，发展出与之关联的模糊集理论（fuzzy set theory）等方法。可能性理论^[103]定义了可能性（possibility）度量，相较于概率论放宽了可加性假设，将其替换为极大性（maxitivity），从而属于非加性测度框架。具体而言，可能性测度 Π 满足： $\Pi(\emptyset) = 0$ ， $\Pi(\Omega) = 1$ ，且对于任意集合族 A_i ，有 $\Pi(\bigcup_i A_i) = \sup_i \Pi(A_i)$ 。这种特性使得可能性理论适用于处理信息不完整导致的认知不确定性。

概率论侧重于随机不确定性（randomness），即事件发生的频率特性；可能性理论和模糊集理论则侧重于模糊不确定性（fuzziness）及知识的不完全性。在信息充足且随机性为主要考量时，概率论是更合适的工具；而在信息稀疏、模糊或涉及主观判断的情形下，可能性理论显示出特定优势^[102]。此外，在一定条件下概率与可能性可以相互转换^[104]。

2.2.2 意外函数

Neumaier^[105]提出了一种基于意外函数（Surprise Function）的不确定性量化方法，该概念也被译为“惊讶”或“惊诧”。意外函数 $s(x)$ 是一种与可能性度量对偶的度量，其值表征事件 x 的不寻常性（值越大表示事件越异常）。该函数通过反向变换与传统隶属函数（membership function）相关联。

论文中定义了 $s(x)$ 的极限情形中：当事件 $E(x)$ 为真时， $s(x|E) = 0$ ；为假时 $s(x|E) = \infty$ ，分别对应确定性判断。 $s(x|E) = 1$ 则代表完全模糊状态。意外函数的取值范围为 $s \in [0, \infty]$ 。

其核心性质是双重否定律，如式（2.1）所示：

$$\neg\neg s = s \quad (2.1)$$

意外函数与可能性理论的关联式如下：传统模糊集采用隶属函数 $d(x) \in [0, 1]$ 表示事件 x 的隶属程度，与意外函数的换算关系为：

$$d = \frac{1}{(s^e + 1)} \quad (2.2)$$

$$s = (d^{-1} - 1)^{1/e} \quad (2.3)$$

在式（2.1）的基础上，定义了与运算的意外函数表达 $s_1 \wedge s_2 = s_1 + s_2$ ，事件 x 的逻辑运算可在意外函数空间中转化为简单的代数运算，其对应关系如表 2.1 所示。典型定性表述的意外函数转换如表 2.2 所示。

表 2.1 意外函数逻辑运算对应关系

逻辑运算	意外函数表达式
与 ($\wedge$)	$s_1 \wedge s_2 = s_1 + s_2$
非 ($\neg$)	$\neg s = s^{-1}$
或 ($\vee$)	$s_1 \vee s_2 = \neg((\neg s_1) \wedge (\neg s_2)) = \frac{s_1 s_2}{s_1 + s_2}$
蕴含 ($\implies$)	$s_1 \implies s_2 = \neg(s_1 \wedge \neg s_2) = \frac{s_2}{1 + s_1 s_2}$
合取	$s_1 \wedge \dots \wedge s_n = \sum_{i=1}^n s_i$
析取	$s_1 \vee \dots \vee s_n = 1 / \sum_{i=1}^n s_i^{-1}$

表 2.2 典型定性表述的意外函数转换

定性表达	意外函数	参数范围
$x \approx \alpha \pm \delta$	$\left(\frac{x-\alpha}{\sigma}\right)^2$	$\sigma > 0$
$x \approx < \alpha \pm \delta$	$\left(\frac{\sigma-\alpha+x}{2\sigma}\right)^2$	$\sigma > 0$
$x \approx > \alpha \pm \delta$	$\left(\frac{-\sigma+\alpha-x}{2\sigma}\right)^2$	$\sigma > 0$

意外函数在计算上的优良性质使其适用于模糊优化问题的建模。模糊优化中的模糊约束和目标函数均可转化为意外函数之和的形式：

$$\begin{aligned} \min \quad & \sum_{i=1}^d s(y_i|u_i) \\ \text{s.t.} \quad & x \in \mathbb{X}, \quad F(x, y) \in \mathbb{F} \end{aligned} \quad (2.4)$$

其中, $\mathbb{X}$ 为输入 x 的不等式约束, $\mathbb{F}$ 为函数约束, u_i 为模糊尺度 (fuzzy scale)。该优化问题以最小化总意外值为目标。当函数约束仅右侧涉及模糊值时, 可将此类约束全部转化到目标函数中处理。

2.3 基于意外函数的联合循环不确定性建模

本节描述基于意外函数的联合循环机组的不确定性建模, 通过意外函数方法可在给定约束条件下, 对联合循环机组进行建模, 并可进一步用于负荷分配的鲁棒优化。建模所用的约束条件包括工质循环的热力学方程和各设备和部件的特性方程, 在2.3.1节中详细阐述, 在2.3.2节中给出建模所用的具体的参数以及建模结果。

2.3.1 建模方程

联合循环各设备的物理方程和特性方程如下:

2.3.1.1 燃气轮机

压气机: 压气机是燃气轮机中核心的耗功部件, 其主要功能是对进气进行压缩, 为后续燃烧过程提供高压空气。压气机的工质为空气, 经过多级压缩后, 其出口压力通常高于1 MPa, 温度一般超过600 K。在上述典型的出口工况下, 实际气体行为与理想气体模型的偏差, 以压缩因子 Z 衡量, 约为0.3%至0.6%。因此, 采用实际热容 c_p 的理想气体模型能够合理的近似^[106]。理想气体的等熵压缩是一个无损失、可逆的绝热过程, 其状态变化遵循特定的热力学关系。基于理想气体状态方程及等熵过程关系式, 可推导出等熵压缩前后温度与焓的变化关系, 如式2.5和式2.6所示。

$$T_{c,\text{out}}^* = T_{c,\text{in}} \times \pi_c^{(\kappa-1)/\kappa} \quad (2.5)$$

$$h_{c,\text{out}}^* - h_{c,\text{in}} = c_p T_{c,\text{in}} \cdot \pi_c^{(\kappa-1)/\kappa} \quad (2.6)$$

式中, π_c 为压气机的压比, 是衡量其压缩能力的关键参数; 参数下标 c 表示压气机, in 和 out 分别表示进口与出口参数, 上标 $*$ 表示等熵条件下的理想状态; T 为温度; h 为工质比焓, c_p 为工质定压比热容, 计算中取温度区间上的均值; κ 为工质的比热容比, 空气取 1.4。

为了量化实际压缩过程的不可逆程度，引入等熵效率（亦称压气机内效率） η_c 这一关键参数，其定义为等熵压缩所需的理想耗功与实际压缩耗功之比。因此，实际压缩过程的焓增与理想焓增之间的关系可表述为：

$$h_{c,out} - h_{c,in} = (h_{c,out}^* - h_{c,in})/\eta_c \quad (2.7)$$

基于上述关系及理想气体焓与温度的关系，可以推导出实际压缩后的出口温度与焓值的具体表达式：

$$T_{c,out} = T_{c,in} + T_{c,in} \cdot [\pi_c^{(\kappa-1)/\kappa} - 1]/\eta_c \quad (2.8)$$

$$h_{c,out} = h_{c,in} + c_p T_{c,in} \cdot [\pi_c^{(\kappa-1)/\kappa} - 1]/\eta_c \quad (2.9)$$

在稳态运行条件下，根据热力学第一定律，压气机作为一个开口系统，其能量输入与输出必须平衡。忽略动能与位能的变化，压气机的能量平衡方程可表示为：

$$\dot{m}_c(h_{c,out} - h_{c,in}) = \dot{W}_c \quad (2.10)$$

其中 $\dot{m}_c$ 为流经压气机的空气质量流量， $\dot{W}_c$ 为驱动压气机所消耗的轴功率（取绝对值）。

燃烧室：在燃烧室内，燃料与来自压气机的压缩空气混合并发生受控燃烧反应，生成的高温高压气体进入透平膨胀做功。不考虑详细的化学反应路径，整体燃烧过程遵循能量守恒定律，即混合工质的焓增等于燃料燃烧所释放的热量。释放的热量取决于燃料的低位热值（LHV）与燃烧效率。相应的能量平衡方程可表示为：

$$\dot{m}_c \alpha_c (h_{cc,out} - h_{c,out}) + \dot{m}_f (h_{f,out} - h_{f,in}) = \dot{m}_f \eta_{cc} q_{LHV} \quad (2.11)$$

其中， $\dot{m}_c$ 和 $\dot{m}_f$ 分别为空气与燃料的质量流量； α_c 表示压气机抽气系数，其物理含义为有部分空气不进入燃烧室而用于透平冷却，厂商不提供此参数因而需要通过其它参数推算或假设；下标 cc 表示燃烧室； η_{cc} 为燃烧效率，反映实际放热量与完全燃烧理论放热量的比值； q_{LHV} 为燃料的低位热值。

低位热值（Lower Heating Value, LHV）是指单位质量燃料完全燃烧后，假定其燃烧产物中的水蒸气保持气态时所释放的热量。与高位热值（HHV）相比，LHV 不包含水蒸气的凝结潜热，因此其数值较低。在燃气轮机等高温热力系统中，排气温度通常远高于水露点，水蒸气不会凝结，故采用 LHV 作为燃料能量计算的基准更为合理。

定义空燃比 α_f 为进入燃烧室的空气与燃料的质量比：

$$\alpha_f = \dot{m}_c / \dot{m}_f \quad (2.12)$$

空燃比 α_f 是影响燃烧室性能的关键参数，其值关系到燃烧稳定性、效率及污染物排放。在燃气轮机控制中，通常需要在部分负荷下将空燃比维持在设定的恒定值附近，以保证安全运行。

燃烧室出口、透平第一级动叶入口处的工质参数（总温 $T_{t,\text{in}}$ 与总压 $p_{t,\text{in}}$ ）是决定透平做功能力的核心参数。然而，在实际燃气轮机运行中，该测点的温度与压力往往难以直接测量。其中，透平入口总压 $p_{t,\text{in}}$ 可根据压气机出口总压 $p_{c,\text{out}}$ ，并考虑流经燃烧室产生的压力损失进行推算：

$$p_{t,\text{in}} = p_{c,\text{out}} \cdot \sigma_{cc} \quad (2.13)$$

其中 σ_{cc} 为燃烧室的总压恢复系数，即入口总压与出口总压的比值，取固定值 0.95。

透平：透平是燃气轮机中将高温燃气的热能和压力势能转化为机械功的核心部件。其工质通常为来自燃烧室的高温燃烧反应物，进口压力较高，温度通常超过 1000 K。在此温度范围内，虽燃气成分复杂，但在工程热力学分析中为简化计算，通常仍按理想气体处理。理想气体的等熵膨胀是一个可逆绝热过程，其状态变化遵循特定的热力学关系，由此可推导出等熵膨胀前后温度与焓的变化关系式：

$$T_{t,\text{out}}^* = T_{t,\text{in}} \cdot \pi_t^{-(\kappa-1)/\kappa} \quad (2.14)$$

$$h_{t,\text{in}}^* - h_{t,\text{out}} = c_p T_{t,\text{in}} \cdot \pi_t^{-(\kappa-1)/\kappa} \quad (2.15)$$

式中， π_t 为透平膨胀比，即进口总压与出口总压之比；下标 t 表示透平，in 和 out 分别表示进口与出口参数，上标 * 表示等熵条件下的理想状态； T 为温度； h 为工质比焓； c_p 为工质定压比热容，计算中取相应温度区间内的平均值； κ 为工质的比热容比，对于燃烧产物，其 κ 值可根据燃气具体组分选取，但由于燃料质量流量占比较小，在近似计算中也可直接采用空气的 κ 值。

为了量化实际膨胀过程中的不可逆损失，引入等熵效率 η_t （亦称透平内效率）来描述实际过程与理想等熵过程的偏差，其定义为实际膨胀功与等熵膨胀功之比。因此，实际膨胀过程的焓降与理想焓降之间的关系可表述为：

$$h_{t,\text{in}} - h_{t,\text{out}} = (h_{t,\text{in}} - h_{t,\text{out}}^*) \cdot \eta_t \quad (2.16)$$

基于此关系及理想气体性质，可以推导出透平实际出口温度与焓值的表达式：

$$T_{t,\text{out}} = T_{t,\text{in}} - T_{t,\text{in}} \cdot [1 - \pi_t^{-(\kappa-1)/\kappa}] \cdot \eta_t \quad (2.17)$$

$$h_{t,\text{out}} = h_{t,\text{in}} - c_p T_{t,\text{in}} \cdot [1 - \pi_t^{-(\kappa-1)/\kappa}] \cdot \eta_t \quad (2.18)$$

在稳态运行条件下，根据热力学第一定律，透平作为一个将热能转化为机械

能的开口系统，其能量平衡方程为：

$$\dot{m}_t(h_{t,\text{in}} - h_{t,\text{out}}) = \dot{W}_t \quad (2.19)$$

其中 $\dot{m}_t = \dot{m}_c + \dot{m}_f$ 为流经透平的工质质量流量， $\dot{W}_t$ 为透平输出的轴功率（取绝对值）。

对于部分负荷下的透平，其工质流量与进出口参数之间的关系常由弗留格尔公式描述，该公式反映了通流部件在相似流动条件下的流量特性：

$$\frac{\dot{m}_1}{\dot{m}_{10}} = \frac{\sqrt{p_1^2 - p_2^2}}{\sqrt{p_{10}^2 - p_{20}^2}} \frac{\sqrt{T_{10}}}{\sqrt{T_1}} \quad (2.20)$$

式中，下标 1 和 2 分别表示部件的进口与出口；下标末尾带 0 的参数（如 $\dot{m}_{10}$ 、 p_{10} 、 T_{10} ）代表某一已知的基准工况下的值。

在燃气轮机现场应用中，由于排气管道通流面积大、流场分布不均，直接精确测量排气流量 $\dot{m}_t$ 较为困难。因此可利用燃机的压比结合弗留格尔公式，由基准工况参数推算出部分负荷下的实际流量：

$$\dot{m}_t = \frac{\sqrt{p_{t,\text{in}}^2 - p_{t,\text{out}}^2}}{\sqrt{p_{t,\text{in},0}^2 - p_{t,\text{out},0}^2}} \frac{\sqrt{T_{t,\text{in},0}}}{\sqrt{T_{t,\text{in}}}} \cdot \dot{m}_{t,0} \quad (2.21)$$

定义其中仅与设计参数有关的部分为透平的流量系数 F ：

$$F = \frac{\sqrt{T_{t,\text{in},0}}}{\sqrt{p_{t,\text{in},0}^2 - p_{t,\text{out},0}^2}} \cdot \dot{m}_{t,0} \quad (2.22)$$

该参数可表征燃机透平部件本身的通流能力。

轴功：对于单轴燃气轮机，透平产生的轴功除用于驱动同轴的压气机外，剩余部分经由机械传动与发电机转化为电能。在稳态运行条件下，整个转子轴系的能量必须保持平衡，即透平输出功等于压气机耗功与发电机输入轴功之和。考虑机械传动损失与发电机损失，其能量平衡方程可表示为：

$$\dot{W}_t - \dot{W}_c - \dot{W}_{gt,e}/\eta_m/\eta_e = 0 \quad (2.23)$$

式中， $\dot{W}_t$ 为透平输出功； $\dot{W}_c$ 为压气机耗功； $\dot{W}_{gt,e}$ 为与燃气轮机相连的发电机的发电功率； η_m 为机械效率，主要考虑轴承摩擦及附件传动等损失，取典型值 0.98； η_e 为发电机效率，涵盖电机内部损失，取典型值 0.99。

部分负荷特性预估模型：在燃气轮机部分负荷分析中，根据燃气轮机轴上的能量平衡，燃气轮机的发电功率 $\dot{W}_{gt,e}$ 可直接由透平输出功与压气机耗功的差值，

并计入机械与发电机效率求得：

$$\dot{W}_{gt,e} = (\dot{W}_t - \dot{W}_c)\eta_m\eta_e \quad (2.24)$$

在部分负荷工况下，透平与压气机的功率主要受其压比变化的影响。基于本章前述推导的理想与实际过程方程，工质的质量流量及膨胀/压缩过程的焓差均与压比存在确定的函数关系。因此，透平与压气机的功率可分别展开并表示为压比的显函数形式：

$$\dot{W}_t = \dot{m}_t c_p T_{t,in} [1 - \pi_t^{-(\kappa-1)/\kappa}] \cdot \eta_t \quad (2.25)$$

$$\dot{W}_c = \dot{m}_t \frac{1 - \alpha_f}{\alpha_f} c_p T_{c,in} [\pi_c^{(\kappa-1)/\kappa} - 1] / \eta_c \quad (2.26)$$

其中，透平流量 $\dot{m}_t$ 亦可利用弗留格尔公式（见式2.20）关联进出口压力进行估算。由此，通过追踪不同负荷下压比参数的变化，即可预估整个燃气轮机系统的部分负荷性能特性。

2.3.1.2 余热锅炉

余热锅炉是联合循环发电系统中的关键换热设备，主要用于回收燃气轮机排气的余热，用以加热给水、产生蒸汽并驱动汽轮机做功。从热力学角度分析，以整个余热锅炉作为控制体，忽略散热等微小损失，其稳态工况下的能量平衡可表述为：燃气轮机排气所释放的热量，等于锅炉内各蒸汽管路中工质所吸收热量的总和。据此，可建立如下能量平衡方程：

$$\begin{aligned} \dot{Q}_{sg} &= \dot{m}_t (h_{t,out} - h_{sg,a,out}) \\ &= \dot{m}_{ms} (h_{ms} - h_{sg,w,in}) + \dot{m}_{ias} (h_{rs} - h_{sg,w,in}) \\ &\quad + \dot{m}_{rs} (h_{rs} - h_{rs,in}) + \dot{m}_{las} (h_{ls} - h_{sg,w,in}) \end{aligned} \quad (2.27)$$

式中， $\dot{Q}_{sg}$ 为余热锅炉的总换热量； $\dot{m}_t$ 和 $h_{t,out}$ 分别为燃气轮机排气的质量流量和出口比焓； $h_{sg,a,out}$ 为余热锅炉烟气侧的出口比焓。在蒸汽侧， $h_{sg,w,in}$ 为余热锅炉蒸汽侧工质的入口比焓，即低压省煤器的入口工质比焓。下标 ms、ias、rs 与 las 分别对应高压主蒸汽、中压补汽、再热蒸汽及低压补汽这四路蒸汽管路及其相应的状态参数。

部分负荷特性预估模型：在电站实际运行中，机组经常处于非额定负荷工况。因此需要建立能准确反映余热锅炉在部分负荷下性能的预估模型。其中，燃气轮机排烟的放热功率是模型的核心输入参数之一，它可直接通过排烟的质量流量、比热容以及温度变化进行计算，其表达式为：

$$\dot{Q}_{sg} = \dot{m}_t c_p (T_{t,out} - T_{sg,a,out}) \quad (2.28)$$

式中, c_p 代表排烟在平均温度下的定压比热容, $T_{t,\text{out}}$ 和 $T_{\text{sg,a,out}}$ 分别为燃气轮机排气出口温度与余热锅炉烟气出口温度。

在此基础上, 结合蒸汽侧的流量与焓变关系, 即可构建完整的余热锅炉部分负荷热力计算模型, 从而预测在不同燃机负荷、环境条件或运行策略下, 余热锅炉的产汽参数及整体热回收效率。

2.3.1.3 汽轮机

汽轮机是联合循环发电系统中将蒸汽热能转换为机械功的核心动力设备, 其输出轴直接驱动发电机旋转以产生电能。汽轮机与燃气透平均属于使工质膨胀做功的关键部件, 二者同样遵循实际膨胀过程方程 (见式2.18) 与弗留格尔公式 (见式2.20) 所描述的热力学关系。

汽轮机部分负荷特性: 汽轮机的负荷特性通常采用弗留格尔公式进行描述。由于透平各级普遍处于阻塞流动状态, 蒸汽质量流量与级间压差之间呈现明确的函数关系。在实际运行中, 蒸汽温度作为被控变量基本保持恒定, 因此汽轮机的负荷调节主要通过给水泵控制进汽压力来实现, 进而使得蒸汽流量随压力变化而发生相应调整。

与燃气轮机在通过改变压比和膨胀比改变负荷的运行方式不同, 汽轮机通常被设计为在部分负荷下保持膨胀比 $\pi_{ht,0}$ 基本恒定。以高压缸为例, 将恒定的膨胀比与入口温度代入弗留格尔公式 (见式2.20), 可推导得到:

$$\dot{m}_{ht} = \frac{\sqrt{p_{ht,\text{in}}^2(1 - \pi_{ht,0}^{-2})}}{\sqrt{p_{ht,\text{in},0}^2(1 - \pi_{ht,0}^{-2})}} \frac{\sqrt{T_{ht,\text{in},0}}}{\sqrt{T_{ht,\text{in}}}} \cdot \dot{m}_{ht,0} = \frac{p_{ht,\text{in}}}{p_{ht,\text{in},0}} \dot{m}_{ht,0} \quad (2.29)$$

该式表明, 汽轮机的蒸汽流量与其入口压力成正比。相应地, 定义高压缸的流量系数 F_{ht} 为:

$$F_{ht} = \frac{\dot{m}_{ht,0}}{p_{ht,\text{in},0}} \quad (2.30)$$

在实际运行中, 蒸汽温度通过控制系统维持稳定, 因此其进口焓值 $h_{ht,\text{in}}$ 以及对应的膨胀焓降 $h_{ht,\text{in}} - h_{ht,\text{out}}$ 可近似视为恒定。

$$h_{ht,\text{in}} - h_{ht,\text{out}} = h_{ht,\text{in},0} - h_{ht,\text{out},0} \quad (2.31)$$

对于汽轮机的单个汽缸 (如高压缸、中压缸或低压缸), 其能量平衡方程可表示为:

$$\dot{m}_{ht}(h_{ht,\text{in}} - h_{ht,\text{out}}) = \dot{W}_{ht}/\eta_m \quad (2.32)$$

式中, η_m 为机械效率。

部分负荷特性预估模型：将表征流量与压力关系的式2.29和表征恒定焓降的式2.31代入能量平衡方程2.32，可推导出通过入口压力直接预估汽轮机输出功率的关系式：

$$\dot{W}_{ht} = \frac{p_{ht,in}}{p_{ht,in,0}} \dot{m}_{ht,0} (h_{ht,in,0} - h_{ht,out,0}) \eta_m \quad (2.33)$$

对于热电联供机组，汽轮机系统还需与供热系统耦合，通常通过从中压缸抽取部分蒸汽作为热源。因此，在计算中压缸出力时，需扣除被抽走蒸汽所具有的做功能力 $\dot{W}_{ex}$ 。该抽汽做功能力可按式计算：

$$\dot{W}_{ex} = \dot{m}_{ex} (h_{ex} - h_{it,out}) \quad (2.34)$$

综合各缸出力及抽汽影响，汽轮机在发电机轴端的整体电功率输出预测公式可表述为：

$$\dot{W}_{st,e} = (\dot{W}_{ht} + \dot{W}_{it} + \dot{W}_{lt} - \dot{W}_{ex1} - \dot{W}_{ex2}) \eta_m \quad (2.35)$$

式中，下标 e 特指发电机端的电功率， η_m 为机械效率。

2.3.1.4 供热系统

在热电联供模式下，供热系统的核心功能在于高效回收并传递汽轮机抽汽的余热，以满足城市供热的需求。

换热器：热网系统以若干组换热器为核心设备。在换热工质流量较大的工况下，换热器向环境的散热量通常可以忽略不计。此时，换热器内部冷、热流体之间的能量平衡可由以下方程描述：

$$\dot{Q}_{heat} = \dot{m}_{heat} (h_{heat,out} - h_{heat,in}) = \dot{m}_{ex} (h_{ex,in} - h_{ex,out}) \quad (2.36)$$

式中，下标 $heat$ 代表热网回水的参数，下标 ex 则表示来自汽轮机的抽汽参数。

部分负荷计算：在热网变负荷控制中，热网回水参数通常由城市热网系统决定，而汽轮机的抽汽量则为可调节的操作变量。因此，变负荷计算主要基于式2.36的右侧关系式进行。式中出现的焓差 $h_{ex,in} - h_{ex,out}$ 主要由工质水的汽化潜热构成，其数值随工况变化不大，在工程计算中可近似视为常量。

2.3.2 参数估计

本节给出建立的联合循环机组负荷预测模型所用的具体的参数。模型 I 和模型 II 为应对测量缺失和不确定性两种方案，其中模型 I 直接使用联合循环机组设备的设计参数替代或推算后替代缺失和不准确的测量参数；模型 II 则为使用本章所提方法根据历史数据估计得到的参数建立的模型。

本章的研究对象为一个二拖一三压再热抽凝机组的热电联产联合循环，额定发电功率为 706MW，包含两台 GE 的 PG9351FA 燃机。系统结构图如图 2.1 所示。

图 2.1 联合循环机组的系统简图

2.3.2.2 模型 I：设计参数模型

燃气轮机子系统的关键设计参数如表2.3所示，涵盖了从压气机、燃烧室到透平的主要性能指标。

表 2.3 燃气轮机设计参数

符号	参数含义	单位	设计值
π_c	压气机压比	—	16.5
$\dot{m}_t$	透平排气流量	kg/s	711.89
$p_{t,in}/p_{c,out}$	燃烧室总压恢复系数	%	95
α_f	空燃质量比	—	43.1855
c_p	空气定压比热容	kJ/(kg · K)	1.0546
η_c	压气机等熵效率	%	86
$T_{t,in}$	透平第一级动叶进口温度	K	1627.55
η_t	透平等熵效率	%	88

表 2.4 余热锅炉设计参数

符号	参数含义	单位	设计值
$T_{sg,a,out}$	余热锅炉排烟温度	K	361.45
c_p	烟气定压比热容	kJ/(kg · K)	1.058
$\dot{m}_{ms} - \dot{m}_{rs}$	高压缸流量损失	kg/s	1.89
$\dot{m}_{las}$	低压补汽流量	kg/s	5.0
$h_{ms} - h_{sg,w,in}$	主蒸汽焓升	kJ/kg	3275.5
$h_{rs} - h_{rs,in}$	再热蒸汽焓升	kJ/kg	457.3
$h_{ias} - h_{sg,w,in}$	中压补汽焓升	kJ/kg	3359.2
$h_{las} - h_{sg,w,in}$	低压补汽焓升	kJ/kg	2828.8

汽轮机子系统的设计参数涉及主蒸汽、再热蒸汽及低压蒸汽的压力、流量和各级缸的焓降，具体数值汇总于表2.5。

供热系统（热网）的关键设计参数为两路抽汽的供热焓降，其数值如表2.6所示。

2.3.2.3 模型 II：运行数据估计模型

在面对测量缺失和不准确参数时，可以通过充足的历史运行数据进行参数估计，以获得更贴近实际运行特性的模型参数。模型 II 为使用本章所提意外函数方法基于历史运行参数得到的燃气轮机余热锅炉模型。特别是面对燃气轮机内部参数保密的情况下，使用运行数据建立燃气轮机的内部模型有助于掌握燃气轮机的运行特性。

表 2.5 汽轮机设计参数

符号	参数含义	单位	设计值
$p_{ht,in}$	主蒸汽压力	MPa	11.4557
$p_{it,in}$	热再热蒸汽压力	MPa	2.595
$p_{lt,in}$	低压主蒸汽压力	MPa	0.4849
$\dot{m}_{ht}$	主蒸汽流量	t/h	539.7
$\dot{m}_{it}$	热再热蒸汽流量	t/h	631.2
$\dot{m}_{lt}$	低压缸进汽流量	t/h	734.5
$h_{ht,in} - h_{ht,out}$	高压缸焓降	kJ/kg	372.57
$h_{it,in} - h_{it,out}$	中压缸焓降	kJ/kg	482.28
$h_{lt,in} - h_{lt,out}$	低压缸焓降	kJ/kg	563.08
$h_{ex1,in} - h_{it,out}$	一抽蒸汽可做功焓降	kJ/kg	186.29
$h_{ex2,in} - h_{it,out}$	二抽蒸汽可做功焓降	kJ/kg	35.41

表 2.6 供热系统设计参数

符号	参数含义	单位	设计值
$h_{ex1,in} - h_{ex1,out}$	一抽供热焓降	kJ/kg	3.1×10^3
$h_{ex2,in} - h_{ex2,out}$	二抽供热焓降	kJ/kg	2.9×10^3

由于燃气轮机启停迅速、负荷响应快，联合循环电厂常作为调峰机组运行，导致实际运行数据中包含大量由负荷频繁变动引起的非稳态工况。鉴于非稳态工况下无法直接应用基于稳态假设的能量平衡方程（尤其是对于余热锅炉等热惯性较大的设备），必须对原始运行数据进行预处理，筛选出稳态工况点，以此作为基于运行数据建模的可靠基础。

本节采用基于滑动窗口的方法进行稳态判定：对选定的关键负荷参数，计算其在固定时间窗口内的最大值与最小值之差，若该差值小于预设阈值，则判定该时段为稳态。


对于燃气轮机，选取压气机进口导叶（IGV）开度、发电功率和透平排气温度作为负荷表征参数；对于余热锅炉，则选取主蒸汽压力作为负荷参数。具体采用 1 小时作为滑动时间窗长度，各关键参数的判定阈值及用于排除停机状态的最小值设定如表2.7所示。

建模结果如图2.2和2.3所示。


因为联合循环燃气轮机的运行为恒定转速运行，不同于燃气轮机设计者的角

表 2.7 稳态数据筛选阈值和最小值设定


符号	含义	单位	阈值	最小值
IGV	压气机进口导叶开度	°	2.0	0.0
$\dot{W}_{gt}$	燃气轮机发电功率	MW	5.0	10.0
$T_{t,out}$	燃气轮机排气温度	K	12.0	200.0
p_{mst}	余热锅炉主蒸汽压力	MPa	0.3	3.0




(a) 压气机等熵效率




(b) 燃气透平等熵效率




(c) 燃烧温度



(d) 燃机发电功率



(e) 燃料质量流率



(f) 可提供的余热锅炉主蒸汽流量

图 2.2 1 号燃气轮机建模得到的关键性能参数曲线




图 2.3 1 号燃气轮机建模得到的关键性能参数曲线

度，从联合循环运行者的角度更加关注燃气轮机在不同工况和环境条件下的性能，因此不采用折合流量与折合转速等相似原理下的折合参数绘制特性曲线，而绘制在环境温度与压比下的燃气轮机关键参数的变化曲线图。图中横坐标表示作为工况标识的压比，颜色表示环境温度（℃）。

从图中可以看出两台燃机的性能参数存在一定差异，如 2 号燃机的压气机等熵效率的最大值高于 1 号燃机的压气机等熵效率最大值。本节所建立的模型能够计算给定环境温度和压比下，输出的燃机发电功率和消耗的燃料质量流率，从而

作为后续负荷分配优化的基础。

2.4 方法验证

本节在联合循环运行机组的实际数据上验证本章所提不确定性建模方法的有效性。具体2.4.1节在汽轮机高压缸的实测数据上模拟测量缺失条件并与传统建模方法定量对比，验证所提方法在测量缺失条件下的建模能力；2.4.2通过所提方法校正实际电厂中测量不准确的燃气轮机工质流量；2.4.3节定量评估上一节中的建立的联合循环性能预测模型的精度，验证所提方法在整体机组上建模的有效性。

2.4.1 测量缺失条件下的建模性能对比

测量参数的缺失和不准确常见于联合循环运行机组的生产实际中，例如燃烧室中因温度过高无法布置传感器导致燃烧室温度和压力损失的测量缺失，余热锅炉烟气流量优于烟道截面积过大造成测量不准确，低压缸排汽干度无法测量等。本章所提方法通过迭代求解的方式可以推算未被测量的参数，以应对生产实际中的测量信息缺失问题。但在使用该方法之前，首先需要验证其求解结果具有合理性和精度，因此本节以联合循环实测数据为基准，测试验证该方法推算参数的精度，同时分析其鲁棒性。

本节选取联合循环运行机组中测量较为完备的高压缸作为研究对象，其系统结构如图2.4所示。这一问题设定下，通过引入高压缸的部件特性作为约束条件可以补充测量参数缺失造成的模型欠定，从而能够优化求解得到设备模型，并能够进一步推算缺失的测量参数。拉格朗日乘子法是一种传统求解的带约束的优化问题的方法，分别使用传统的求解算法拉格朗日乘子法和本章所提意外函数法进行建模，并对比两种方法在测量缺失条件下的建模性能。




图 2.4 高压缸模型和相关参数

汽轮机高压缸模型所用参数如图2.4和表2.8所示，包含输入参数、性能参数和输出参数三类，其中输入参数和输出参数都是实际机组可测量的参数，输出参数

在模型求解时人为隐藏以模拟部分测量参数缺失的恶劣条件，性能参数为通过 1 年的历史运行数据计算得到的值。

表 2.8 建模相关参数

变量	单位	含义	均值	最小值	最大值	类型
$T_{ht, in}$	K	高压缸进口温度	839.15	823.32	840.36	输入参数
$p_{ht, in}$	MPa	高压缸进口压力	7.72	5.48	11.59	
η_{ht}	%	高压缸等熵效率	75.54	68.29	83.48	性能参数
F_{ht}	kg/(s · MPa)	高压缸流量系数	383.19	326.53	607.78	
$T_{ht, out}$	K	高压缸出口温度	662.49	641.99	680.77	输出参数
$p_{ht, out}$	MPa	高压缸出口压力	1.91	1.30	2.84	
$\dot{m}_{ht}$	kg/s	高压缸进口质量流量	100.46	60.48	159.56	

两个对比方法的建模结果如表2.9所示，其中平均误差为模型求解收敛后的输出参数值与实际测量值之间的平均差值，计算失败指优化求解不收敛的情况。从表中可以看出，在测量缺失条件下，所提意外函数方法在计算失败次数上远低于拉格朗日乘子法，且在输出参数的预测精度也优于拉格朗日。说明所提方法具有鲁棒性和较好的建模精度。

表 2.9 建模输出参数精度对比

参数	单位	指标	拉格朗日乘子法	意外函数方法
$\dot{m}_{ht}$	kg/s	平均误差	58.982	0.097
$T_{ht, out}$	K	平均误差	30.923	0.093
$p_{ht, out}$	MPa	平均误差	1808.483	0.513
	%	计算失败	24.13	0.00

2.4.2 排气流量测量不准确条件下的燃气轮机建模

本节在实际联合循环运行机组的数据上使用本章所提的基于意外函数的方法建立燃气轮机模型，并校正测量不准确的燃气轮机排气流量。燃气轮机的工质流量是联合循环能量计算中误差会产生显著影响的参数，如计算透平做功和压气机耗功时工质流量直接与焓差相乘，因此工质流量每存在 1% 的误差就会带来 1% 的功率计算的误差。其中燃气轮机的排气全部通入余热锅炉，燃气轮机排气流量与余热锅炉的烟气流量相等。联合循环现场部署的与其相关的主要流量测点包含两个。其一是燃气轮机的排气流量测点，测量原理与孔板流量计类似，通过燃气轮

机进出口压力推算经过的气体的流量。其二是余热锅炉的烟囱烟气流量测点，测量原理为通过烟气流速与烟道截面积推算烟气流量，由于烟道面积较大内部流速不均匀，该测点测量不准确并且不确定性较大。


结合现场经验，余热锅炉换热器的管道效率在 98% 至 99% 的范围内较为稳定，通过余热锅炉换热器的热平衡方程推算燃气轮机排气流量会比现有测点的精度更高。因此在建立燃气轮机建模时，将一组换热器的热平衡方程作为额外的约束引入求解过程，以校正测量不准确的燃气轮机排气流量。选取高压蒸发器作为控制体建立能量平衡方程，其管道热效率 η_{HV} 如式2.37所示表示为换热器冷端吸热量与热端放热量之比，表征了换热器向环境放热带来的损失。其中 $\dot{m}_{MST}$ 为主蒸汽质量流量， $h_{hv,s,out}$ 和 $h_{hv,s,in}$ 分别为蒸汽出口和进口的焓值， $\dot{m}_g$ 为烟气质量流量， $h_{hv,g,out}$ 和 $h_{hv,g,in}$ 分别为燃气出口和进口的焓值。对于蒸发器冷端工质为蒸汽且发生相变，可以通过占主导的汽化潜热估算冷端焓差。

$$\eta_{HV} = \frac{\dot{m}_{MST}(h_{HV,s,out} - h_{HV,s,in})}{\dot{m}_g(h_{HV,g,out} - h_{HV,g,in})} \quad (2.37)$$


选取运行时间较长的 1 号燃机为研究对象，通过所提方法迭代求解得到了燃气轮机模型中的排气流量 $\dot{m}_g$ 。将该结果和两个现有测点的值分别带入式2.37得到高压蒸发器的管道效率计算中，计算出的管道效率在一年数据中的频数分布如图2.5所示。

从图2.5(a)中可以看出使用现有燃气轮机排气流量测点计算的 η_{HV} 明显偏高，管道效率大于 100% 代表换热器从外界吸热，从热力学第二定律角度分析是不可能成立的，这是由于对热端热量计算偏低导致的误差，推测现有燃气轮机排气流量存在系统误差与实际值相比偏低；图2.5(b)中则显示了使用现有烟囱烟气流量测点计算的 η_{HV} ，其中位数也显著高于 100%，并且标准差高于通过燃气轮机排气流量计算的结果，说明通过烟气流速推算的余热锅炉烟气流量不确定性高于燃气轮机排气流量。图2.5(c)中是本章所提模型求解结果得到的排气流量 $\dot{m}_g$ 推算的 η_{HV} ，其中位数与合理值 98% 至 99% 的偏差显著降低，降低了约 73%，并且标准差降低了约 44%，说明求解得到的燃气轮机排气流量精度更高更接近实际值，并且不确定性更低。


上述结论验证了所提方法在联合循环实际运行机组上流量测量不准确条件下，建立燃气轮机模型时综合利用上下游设备测量值与约束方程，提高流量参数精度并降低参数不确定性的能力。上述结果的具体值在表2.10中展示。



(a) 通过燃机排气流量测点值计算



(b) 通过锅炉烟囱流量测点值计算



(c) 通过锅炉烟囱流量测点值计算

图 2.5 通过余热锅炉高压蒸发器管道效率计算值分析燃机排气流量误差

2.4.3 联合循环建模精度对比

为确保负荷预测模型的准确性，以支持后续的优化研究，本节利用为期一年的实际运行数据对构建的模型进行了验证。通过对比关键负荷指标的预测值与实际测值，评估了模型的预测精度，并对误差来源进行了分析。

表 2.10 根据不同燃机流量值计算的高压蒸发器管道效率

统计量	燃机流量值来源		
	燃机流量测点	烟囱流量测点	意外函数求解
中位数 (%)	124.1493	132.8885	106.4618
标准差 (%)	6.5959	8.4437	3.7683
均值 (%)	123.5499	133.3444	105.3794

模型预测的平均绝对误差 (MAE) 与决定系数 (R^2) 等指标汇总于表2.11。其中, 模型 I 为直接采用设计参数建立的热力学模型, 模型 II 为使用意外函数基于历史运行数据求解得到的模型。模型 II 对 1 号燃机、2 号燃机发电功率的预测平均绝对误差分别为 4.18 MW 与 4.10 MW, 误差低于模型 I。

表 2.11 模型 I 与模型 II 预测性能指标对比

符号	含义	单位	MAE - I	MAE - II	R^2 - I	R^2 - II
$\dot{m}_{f,1}$	1 号燃机燃料流率	kg/s	0.63	0.25	0.81	0.91
$\dot{W}_{gt,1}$	1 号燃机发电功率	MW	24.12	4.18	0.52	0.94
$\dot{m}_{f,2}$	2 号燃机燃料流率	kg/s	0.63	0.23	0.68	0.93
$\dot{W}_{gt,2}$	2 号燃机发电功率	MW	18.14	4.10	0.09	0.92

图2.6展示了基于意外函数建模的燃气轮机余热锅炉模型 (模型 II) 对核心负荷参数的预测值与实际值的回归散点图。图中点越靠近对角线, 表示预测精度越高。

为进一步探究误差来源, 图2.7展示了模型 I (设计参数模型) 的预测误差分布。从图中可以看出, 模型 I 普遍高估了燃气轮机的热效率, 进而导致对发电功率的预测值偏高。产生这一系统性偏差的主要原因在于建模时使用的关键设备特性参数存在误差。具体而言, 该燃气轮机在最近一次大修后已持续运行六年, 在此期间, 由于部件老化, 其满负荷热效率相较于设计值有所降低。此外, 在部分负荷工况下观测到的较大预测误差, 可能归因于模型基于设计点工况的假设; 由于可用的设备运行数据有限, 难以精确表征其非设计工况下的性能。

现有研究表明, 燃气轮机效率随运行时间下降的主要原因是叶片积垢。积垢导致的性能衰退占燃气轮机性能衰退总量的 70% 至 85%, 并可造成 2% 至 20% 的功率损失^[107]。性能退化通常分为可恢复性退化与不可恢复性退化两类。可恢复性退化主要由压气机积垢引起, 可通过离线水洗或更换空气过滤器来恢复。相比之




图 2.6 模型 II 预测值与实际值对比




图 2.7 模型 I 和模型 II 预测误差分布

下,不可恢复性退化则源于侵蚀、腐蚀以及叶顶间隙增大等长期累积效应,这些损伤随运行时长逐渐加剧,必须通过大修才能恢复^[108]。有研究记录表明,压气机在运行 2000 小时后,其等熵效率的下降幅度可达约 3% 至 4%^[107]。

2.5 联合循环负荷分配优化

在验证模型 II 的精度之后,在模型 II 的基础上可以推算不同负荷分配策略下的联合循环机组出力输出,进而可以进行负荷分配优化。本节具体描述负荷分配优化的问题背景、数学定义、求解结果和策略分析。

2.5.1 负荷分配问题定义

在联合循环机组运行期间,燃气轮机、余热锅炉及汽轮机等核心能量转换部件的性能受老化、结垢及潜在故障等因素影响,会逐渐偏离其设计值。对于采用“二拖一”配置的机组,两台燃气轮机之间可能存在效率差异。本节的目的是在满足给定外部电、热负荷需求的前提下,通过优化确定机组内关键设备的负荷分配策略,以提升电厂的整体运行效率。

效率优化问题关注联合循环的稳态运行,因此假设系统处于稳态。在实际运行中,发电功率与供热负荷由电网与热网需求给定,属于外部边界条件。因此,所述优化问题转化为:在满足给定电负荷 $\tilde{W}_{gtcc,e}$ 与热负荷 $\tilde{Q}_{heat}$ 的约束下,最小化系统的总燃料消耗率。目标函数定义为总体燃料消耗率,即两台燃气轮机燃料消耗率之和,其数学表达式为:

$$f(\mathbf{x}) = \dot{m}_f = \dot{m}_{f,1} + \dot{m}_{f,2} \quad (2.38)$$

优化问题选取的独立决策变量为控制机组运行状态的关键可控制参数,包括两台燃气轮机的压比 $\pi_{c,1}$ 、 $\pi_{c,2}$,以及汽轮机的两级供热抽汽流量 $\dot{m}_{ex1}$ 、 $\dot{m}_{ex2}$ 。决策变量的取值范围由设备物理极限与运行安全范围决定,具体如表 2.12 所示。

表 2.12 决策变量及取值范围

符号	含义	取值范围
$\pi_{c,1}$	1 号燃机压比	[0.0, 16.5]
$\pi_{c,2}$	2 号燃机压比	[0.0, 16.5]
$\dot{m}_{ex1}$	汽轮机一级抽汽流量 (kg/s)	[0.0, 55.0]
$\dot{m}_{ex2}$	汽轮机二级抽汽流量 (kg/s)	[0.0, 130.0]

优化问题的核心约束是确保联合循环的主要输出产品(发电功率与供热负荷)

达到目标值:

$$g_1(x) = \dot{W}_{gtcc,e} - \tilde{\dot{W}}_{gtcc,e} = 0 \quad (2.39)$$

$$g_2(x) = \dot{Q}_{heat} - \tilde{\dot{Q}}_{heat} = 0 \quad (2.40)$$

此外, 系统各部件的物理匹配关系引入了以下不等式约束。基于能量守恒, 每台余热锅炉的烟气放热量需不小于其内部蒸汽的总吸热量, 以保证换热过程的热力学可行性:

$$h_{1,2}(x) = \dot{Q}_{sg} - (\dot{Q}_{ms} + \dot{Q}_{ias} + \dot{Q}_{rs} + \dot{Q}_{las}) \geq 0 \quad (2.41)$$

基于质量守恒, 汽轮机的总抽汽流量不得超过中压缸的进汽流量, 以保证流量的可实现性:

$$h_3(x) = \dot{m}_{ipt} - (\dot{m}_{ex1} + \dot{m}_{ex2}) \geq 0 \quad (2.42)$$

综上, 该负荷分配优化问题的完整数学表述为:

$$\begin{aligned} \min f(x) &= \dot{m}_{f,1} + \dot{m}_{f,2}, \quad x = (\pi_{c,1}, \pi_{c,2}, \dot{m}_{ex1}, \dot{m}_{ex2}) \\ \text{s.t.} \quad g_i(x) &= 0, \quad i = 1, 2; \\ h_j(x) &\geq 0, \quad j = 1, 2, 3. \end{aligned} \quad (2.43)$$

重点关注两台燃气轮机的性能差异因此在整体联合循环优化的基础上做出简化, 简化底循环和供热系统将供热负荷目标改为两台燃机的顶循环向底循环提供达到目标的蒸汽量:

$$g_3(x) = \dot{m}_{MST} - \tilde{\dot{m}}_{MST} = 0 \quad (2.44)$$

此时优化问题的数学表述为:

$$\begin{aligned} \min f(x) &= \dot{m}_{f,1} + \dot{m}_{f,2}, \quad x = (\pi_{c,1}, \pi_{c,2}) \\ \text{s.t.} \quad g_i(x) &= 0, \quad i = 1, 3; \\ h_j(x) &\geq 0, \quad j = 1, 2, 3. \end{aligned} \quad (2.45)$$

2.5.2 优化问题求解

本节采用含约束的单目标优化算法(COBYQA)求解上述负荷分配优化问题, 最大迭代次数设置为100。在考虑参数不确定性的情况下, 使用意外函数将含不确定性的优化问题转化为公式2.4的总意外最小化的确定性形式。

2.5.3 优化问题求解结果

本节基于前文建立的联合循环性能预测模型与优化问题框架，展示并分析相应的负荷分配优化结果。

根据实际运行数据，可归纳出该联合循环电厂现行的运行策略，如图 2.8 所示。图中两台燃气轮机压比 π_c 的关系反映了其负荷分配模式：在“二拖一”工况下，绝大多数运行点位于对角线上，表明两台燃机通常按照相同的负荷系数（压比）对称运行；其余数据点对应于“一拖一”工况，即其中一台燃机停机（压比 $\pi_c = 1$ ），而另一台通过调节压比来承担负荷。




图 2.8 两台燃气轮机实际运行压比关系

优化后得到的运行策略如图 2.9 所示。




图 2.9 优化后的联合循环机组两台燃机之间的负荷分配策略

可以看到在“二拖一”工况下，对称的负荷分配不是最优策略。在一定负荷区间内 2 号燃机热效率相对较高，分配更多负荷到 2 号燃机可以提升整体的热效率，

并降低燃料消耗。对于“一拖一”工况，由于不存在两台燃机之间负荷分配调整的空间，因此优化策略与现有策略保持一致。

优化策略相对现有对称分配策略，在不同负荷下的燃料节约量如图2.10所示。平均而言，优化策略相较于现有策略能带来约 0.2kg/s 的燃料节约，对应每年 0.3% 的燃料节约潜力。




图 2.10 优化后节约的燃料量

2.5.4 负荷分配策略分析

通过优化方法的数值计算得到了最优的负荷分配策略，下面根据设备性能特性和性能差异对该策略优于现有策略的原因进行分析。

2.5.4.1 部分负荷分析

燃气轮机与汽轮机在部分负荷下的效率-负荷特性与设备的通流设计及性能衰减程度密切相关，需依据实际运行数据获得，难以仅通过理论热力学计算得出。本节基于筛选出的稳态运行数据，对核心热功转换设备的效率特性进行分析。

图 2.11 展示了两台燃气轮机实际运行热效率与压比的关系。




图 2.11 两台燃气轮机热效率随压比变化关系

单台燃气轮机的热效率 η_{gt} 介于 24% 至 36% 之间，且随压比升高呈现显著上升趋势。

图 2.12 展示了联合循环总发电热效率 $\eta_{gtcc,e} = \dot{W}_{gtcc}/(\dot{m}_f \cdot q_{LHV})$ 与总发电负荷 $\dot{W}_{gtcc}$ 的关系。




图 2.12 联合循环热效率随总发电负荷变化关系

图中左侧 $\dot{W}_{gtcc} < 400$ MW 部分为“一拖一”工况，效率 $\eta_{gtcc,e}$ 介于 43% 至 48% 之间；右侧 $\dot{W}_{gtcc} > 400$ MW 部分为“二拖一”工况，效率在 47% 至 52% 之间。联合循环的效率特性总体上由燃气轮机的效率特性主导，并随负荷增大而提升。值得注意的是，从最大“一拖一”负荷切换至最低“二拖一”负荷时，热效率反而出现下降，这是由于此时两台燃机分摊负荷，均运行在低效工况所致。

根据实际运行数据，从整体热效率角度，较高的负荷率更为有利；对单台燃气轮机而言，运行在越高负荷的工况下越有利。为进一步探究“二拖一”工况下的最优负荷分配，下文将对两台燃机的性能进行对比分析。

2.5.4.2 偏置策略分析

通过计算输出功率对燃料流率的偏导数 $\partial \dot{W}_{gtcc} / \partial \dot{m}_f$ ，即提升单位燃料流率所能获得的发电功率增量，或燃料的边际收益，可以量化并比较在不同负荷水平下，提升任一台燃机负荷所带来的功率增益差异。对比结果如图 2.13 所示。

进一步分析偏导数 $\partial \dot{W}_{gtcc} / \partial \dot{m}_f$ 的变化趋势可见，其值随压比的上升呈现逐渐下降的趋势。同样的压比下，2 号燃机的燃料的边际功率增益 $\partial \dot{W}_{gtcc} / \partial \dot{m}_f$ 高于 1 号燃机时，将部分燃料供给从 1 号燃机转移至 2 号燃机，可在总燃料消耗不变的情况下提升总发电功率。但是这种调整的收益是有上限的，当更多的燃料供给到 2 号燃机时，其工况点右移，而 1 号燃机的工况点左移，会使得 2 号燃机的燃料的边际功率增益下降而 1 号燃机的燃料的边际功率增益上升，直到两者的燃料的边际功率增益相等时，继续向 2 号燃机偏置负荷则会带来负收益。因此，在负荷偏置策略中，需要找到一个平衡点，使得燃料的边际功率增益差异达到最大，这与图




图 2.13 能量参数对燃料流率的敏感性分析

2.12展示的最优负荷分配策略是一致的，也就是2号燃机的燃料的边际功率增益大于1号燃机时，从1号燃机调配少量负荷到2号燃机，反之则从2号燃机调配少量负荷到1号燃机。

此外对于不同的运行模式之间的切换，尽管在低负荷下“二拖一”模式的燃料效率可能低于“一拖一”模式，但在实际调峰运行中，出于快速响应负荷变化的需求，通常不会在短时间内频繁切换运行模式。这是由于余热锅炉热惯性大，启动过程耗时较长。为满足调峰对变负荷速度的要求，即使在短期低负荷工况下，电厂也需要维持“二拖一”方式运行。

2.6 小结

针对联合循环运行机组生产环境下的测量信息缺失和不完备问题，本章提出了基于意外函数的联合循环不确定性建模与优化方法。使用具有不确定性建模的意外函数方法，结合热力学方程和部件特性建立了联合循环系统的负荷预测模型，并基于该模型通过优化算法求解了联合循环系统的最优负荷分配策略。通过实际运行机组上的数据分析，验证了所提方法在处理测量信息缺失和不确定性建模方面的有效性，并揭示了联合循环系统中多台燃气轮机存在效率差异情况下的理论上最优负荷分配策略及其物理依据。

(1) 使用意外函数法可以实现联合循环设备和整体机组的不确定性建模，并相对拉格朗日乘子法具有更高的精度和鲁棒性。

汽轮机高压缸模拟测量缺失条件下的建模测试中，所提方法求解不收敛案例比例为0%，低于拉格朗日乘子法的24%，并且收敛得到的解中缺失参数与实测值的平均误差低于拉格朗日乘子法。整体机组性能预测建模的对比结果表明，直接采用设计参数构建的模型（模型I）其预测误差普遍高于经运行数据校正后的模型

(模型 II)，误差源于燃气轮机部件效率偏离设计值。使用本章所提意外函数方法基于运行数据建立燃气轮机模型，对发电功率预测的平均误差分别为 4.18 MW 与 4.10 MW，相对模型 I 的误差降低约 83%。这表明，对实际电厂进行建模与优化时使用运行数据拟合可以提高模型精度，并且需要考虑燃气轮机长期运行导致的性能退化现象，其对模型精度具有重要影响。

(2) 在二拖一联合循环机组存在效率差异的情况下，对称分配负荷可能为次优方案，使用优化后的偏置负荷分配可以降低联合循环整体的燃料消耗率。

优化得到的最优负荷分配策略出现了明确的非对称性。在一拖二构型中，对称负荷分配除满负荷工况外均为次优方案。最优策略始终将较高负荷分配给效率较高的 2 号燃气轮机。平均而言，优化策略相较于现有策略能带来约 0.2kg/s 的燃料节约，对应每年 0.3% 的燃料节约潜力。

(3) 两台燃气轮机的负荷分配方案存在最优点，且该点位置为两台燃机的燃料的边际功率增益 $\partial \dot{W}_{gtcc} / \partial \dot{m}_f$ 相等的工况点。

优化计算结果表明，单位燃料的边际功率增益 $\partial \dot{W}_{gtcc} / \partial \dot{m}_f$ 随压比增大而单调下降，因此随着负荷向效率较高的燃机偏置，其边际功率增益也逐渐下降，当两台燃机的燃料的边际功率增益相等时，继续偏置带来负收益因此达到最优点。

第3章 基于自适应学习与伪标签的联合循环设备退化状态识别方法

3.1 引言

状态识别是指基于设备模型与测量数据,判断设备运行状态是否偏离正常状态。通过建立设备的在线状态识别模型,可以根据传感器实时测量的参数判断设备当前的状态是否偏离正常。识别异常状态后,可以进一步判断偏离正常状态是否由性能退化引起,并具体评估退化程度;也可以根据识别结果,给出告警信息,指导现场运行人员调整运行策略或者进行设备维护。联合循环机组设备的退化状态是设备的隐含变量,无法直接由传感器测量,设备退化状态的判定可以通过设备退化的机理模型推算或者现场的检查结果推断。使用机理模型推算的方法依赖全面准确地获取设备的设计参数和设备特性模型,对于联合循环机组的运行人员而言这些信息往往受到商业保护而无法获取,限制了机理模型的使用。而重要的现场检查需要在停机状态下进行,联合循环的生产要求不能支持频繁的停机,因此现场检查通常在预定的时间进行,如在每年城市用电量较低的春季和秋季进行以半年为间隔的春检和秋检,这使得现场检查的时效性不足以支持实时的状态识别。

数据驱动方法是实现设备在线状态识别的重要技术路线,此类方法基于大量历史数据与设备状态标注,通过人工神经网络等具有强非线性拟合能力的参数模型,拟合从传感器测量参数到设备状态的函数关系,从而训练状态识别模型,这一技术路线可在缺乏准确的设备特性参数和详细设备机理模型的情况下实现在线状态识别。然而传统的数据驱动方法的拟合过程依赖准确的设备状态标注,生产环境下普遍存在状态信息不完备问题使得获取与历史运行数据相配合的准确的状态标注是高成本的,这制约了数据驱动方法在生产环境下的工程应用。因此,如何高效利用大量缺乏准确状态标注的历史数据成为在生产环境下训练状态识别模型的重要问题。

现有研究针对这一问题发展出了半监督学习的研究思路,半监督学习可以在训练过程输入大量历史数据的同时,不要求全部的历史数据得到准确的标注,而只要求少部分数据得到准确的标注而剩余大量数据可为无标注。半监督学习降低了数据驱动方法对数据标注量的依赖,但是仍然依赖对部分设备异常状态数据的准确标注,而在生产环境中常出现异常数据稀缺的情况,针对这一问题进一步发展出了正-无标签学习方法。正-无标签学习方法在半监督学习的训练条件的基础上,

进一步放宽了需要准确标注异常数据的要求，可以仅标注部分正常数据。相对于异常数据，设备正常状态的判定相对容易，在检修后一段时间内设备状态通常为正常，因此可以较容易地获取大量正常状态的数据，这使得正-无标签学习方法在训练要求在生产环境中更容易达成。但是现有的正-无标签学习方法对训练数据的数据分布依赖完全随机抽取假设^[109-110]，使其难以适应联合循环设备退化状态识别问题中较弱的分布。

针对上述问题，本章在状态信息不完备的子问题下开展方法研究，提出一种基于自适应学习与伪标签（Self-adaptive Training based Positive-Unlabeled learning, SatPU）的联合循环机组设备退化状态识别方法。该方法在自适应训练框架中引入伪标签生成方案与动态重加权技术，利用中间模型预测校准初始训练标签，缓解确认偏差与收敛至平凡解的风险。进而降低了数据驱动的状态识别方法对数据状态标注量和状态分布假设的依赖性，从而提升在状态信息缺失和不确定条件下的状态识别性能，提升了数据驱动的状态识别方法在生产环境下的适用性。

本章后续内容如下：3.3节阐述 SatPU 方法的详细设计与实现；3.4节通过仿真与实际的传感器时间序列数据集上的对比实验验证 SatPU 的有效性，并进行消融实验以论证各技术组件的必要性；3.5在联合循环运行机组的压气机滤网退化案例中应用本章的方法实现退化状态识别；3.6节总结本章内容。

3.2 理论基础

针对现有数据驱动方法对设备历史退化状态的准确标注依赖高和对数据依赖高的不足，本章提出的基于自适应学习与伪标签的联合循环设备退化状态识别方法改进了现有的自适应学习方法并应用于联合循环设备退化状态识别。本节首先描述现有自适应学习方法，并在下一节中介绍本章所提方法流程。

3.2.1 自适应学习

自适应学习（Self-adaptive training）是一种由 Lang 等人提出的训练策略。该策略利用模型在训练过程中产生的预测结果，对目标标签进行动态校准，从而逐步修正标签中的噪声，最终缓解经验风险最小化（ERM）框架下模型对噪声标签的过拟合问题。该方法主要包含以下三个核心内容：

初始训练阶段：首先，模型基于给定的初始训练标签进行若干轮迭代训练，以获得一个初步合理的参数估计。此阶段为后续的标签校准提供了必要的初始模型。

伪标签生成：初始训练阶段结束后，在后续的每轮迭代中，采用指数移动平均

策略更新每个训练样本的伪标签。具体更新方式如下：

$$\tilde{y}_{i+1} \leftarrow \alpha \tilde{y}_i + (1 - \alpha) \hat{y}_i. \quad (3.1)$$

其中， $\tilde{y}_i$ 为上一轮迭代的伪标签， $\hat{y}_i$ 为当前模型对样本的预测输出， α 为平滑超参数。该机制使得伪标签能够依据模型预测的演变趋势进行渐进式调整。

样本加权：为降低可能错误的标签对训练的影响，该方法引入了一种基于的样本加权机制。样本权重 w_i 被设定为模型对该样本在各个类别上预测概率的最大值，即 $w_i \leftarrow \max_c [\hat{p}(x_i, y_i = c)]$ 。通过将更高的样本权重赋予预测结果具有更高确定性的样本，可以使得这些预测置信度高的样本主导训练过程。

自适应训练的关键在于其伪标签生成机制，该机制能够依据模型预测迭代地修正带噪声的标签。这种从噪声标签中学习的能力，使其在正例未标记学习（PU learning）中展现出良好的应用潜力。此外，该方法不依赖于“完全随机选择”（SCAR）假设，因而在实际应用中更具灵活性。然而，该方法对标签噪声的校正能力在误标较严重时有限；而在 PU 学习场景下，可用正样本通常很少，这也会对其分类性造成一定限制。

3.3 方法描述

针对现有方法对设备历史退化状态的准确标注和数据量依赖高的问题，本章改进了上述自适应学习框架及其伪标签生成函数，并结合联合循环测量数据的特点提出一种联合循环设备退化状态识别方法，本节描述该方法的流程。

3.3.1 联合循环设备退化状态识别算法整体流程

本章节所提算法旨在实现对联合循环设备退化的在线状态识别。算法的输入为多通道传感器流式数据，该类数据由部署于整个监测系统中的各类传感器持续采集所形成。如图 3.1 所示，首先利用历史测量数据训练一个退化状态识别模型；该模型训练完成后，即可根据最新的实时测量数据对系统的退化状态进行在线评估。训练集的构建方式为：按预先设定的时间区间对历史测量数据进行分段。在标注方面，仅对其中一小部分确认的退化状态为健康的样本进行人工标注，其余样本则保持未标注状态，以符合实际应用中标注稀缺的场景。

3.3.2 基于自适应伪标签的正-无标签状态识别算法

基于自适应伪标签的正无标签状态识别算法（SatPU）在随机梯度下降的迭代框架下运行，其训练输入为多变量时间序列数据，通常来自生产环境中的传感器信号。算法将部分已标注的正常状态样本作为正例未标记学习中的正例，进而训




图 3.1 异常检测模型训练与在线评估流程

训练得到一个用于状态识别的分类器。所得分类器以端到端方式运行，能够依据实时获取的最新传感器测量数据，在线预测设备的退化状态。训练过程分为两个主要阶段，即初始化阶段与自适应训练阶段。下文将具体阐述这两个阶段的实现细节与设计原理，整体算法流程如图 3.2 所示。




图 3.2 SatPU 算法整体流程

预热阶段：在预热阶段，算法使用固定的伪标签 $\tilde{y}_i$ 进行训练，训练轮数 E_{p0}

为预设值，一般设置在 10 至 30 之间。本文后续实验均取 $E_{p0} = 20$ 。

在正-无标签学习的问题设定下，训练数据包含正标签样本和无标签样本两类。对于正标签样本，即 $y_i = \text{Positive}$ ，其训练标签设为 $\tilde{y}_i = 1$ ；对于无标签样本，即 $y_i = \text{Unlabeled}$ ，其训练标签设为 $\tilde{y}_i = 1/2$ 。将样本的训练目标值设定为 $1/2$ ，表示模型对该样本是否为正例的初始判断处于不确定状态，其分类置信度介于确定为负样本的 0 与确定为正样本的 1 之间。预热阶段中训练标签的统一形式可表示为：

$$\tilde{y}_i = \begin{cases} 1, & y_i = \text{positive}; \\ 1/2, & y_i = \text{unlabeled}. \end{cases} \quad (3.2)$$

自适应训练阶段：自适应训练阶段基于自适应训练的基本思想，旨在通过迭代过程动态更新训练标签的方式应对训练标签不确定性。本文提出的 SatPU 算法在此基础上进行改进，使其进一步适应条件苛刻的正-无标签学习场景。本阶段包括锐化伪标签函数、平滑滤波和动态样本加权三个步骤。

锐化伪标签函数：在标准的自适应训练框架中，伪标签直接由模型预测生成并经过简单平滑。然而，在正-无标签学习设置下，此类简单的伪标签函数容易导致模型收敛至一个缺乏判别能力的平凡解，其典型表现是大多数样本的代理类别概率 $\hat{y}_i$ 会密集分布在 $\hat{y}_i = 0.5$ 的分类决策边界附近。

为解决上述问题，本章提出一种专为正-无标签学习设计的锐化伪标签函数。该函数通过对模型原始输出进行一系列变换，以放大高置信度样本的信号，其数学定义如下：

$$\begin{cases} q_i = \frac{1}{2} - \frac{1}{2} \cos \left[\pi \frac{t_i - \min_i(t_i)}{\max_i(t_i) - \min_i(t_i)} \right], \\ t_i = \frac{1}{1 + \exp \left(-\frac{\hat{y}_i - \mu_{\hat{y}}}{\sigma_{\hat{y}}} \right)}. \end{cases} \quad (3.3)$$

该函数的计算流程可分为以下几个步骤：（1）标准化与非线性激活：首先，对当前批次所有样本的模型原始输出 $\hat{y}_i$ 计算均值 $\mu_{\hat{y}}$ 与标准差 $\sigma_{\hat{y}}$ ，进行标准缩放。随后，将缩放后的结果输入 Sigmoid 函数，将其映射至 $(0, 1)$ 区间，得到中间变量 t_i 。此步骤初步增强了可能正例（ t_i 接近 1）与可能负例（ t_i 接近 0）之间的分离度。（2）归一化至概率区间：对当前批次内的 t_i 值进行最小-最大值缩放，将其线性归一化至区间 $(0, 1)$ 内。（3）余弦锐化变换：最后，应用余弦函数对归一化后的值进行非线性变换，得到猜测的类别标签 q_i 。该变换的特性是：对于接近区间两端的值（即高置信度样本），其输出 q_i 会被进一步推向 0 或 1；而对于中间区域的值，变换则相对平缓。这一设计显著强化了模型对高置信度样本的判别信号。该锐化伪标签

函数的计算复杂度为 $O(n)$ ，其中 n 为训练批次大小。

平滑滤波：直接使用锐化后的猜测标签 q_i 进行训练可能易受到单次预测随机波动的影响。因此，本方法引入平滑滤波机制，以平衡历史信息与当前预测，提高训练过程的数值稳定性。

指数加权移动平均滤波是基础的平滑策略，其公式为：

$$\tilde{y}_i = \alpha \hat{y}_i + (1 - \alpha)q_i, \quad (3.4)$$

其中 $\tilde{y}_i$ 为最终用于计算损失的伪标签， $\alpha \in (0, 1)$ 为平滑系数。该操作通过对当前模型预测 $\hat{y}_i$ 与锐化猜测标签 q_i 线性组合，实现伪标签的渐进式更新。

针对传感器信号等具有强时序相关性的数据，伪标签在时间维度上也应呈现连续性。为此，本文提出进一步将指数加权移动平均与中值滤波结合，利用数据的时序关联性平滑伪标签波动：

$$\tilde{y}_i = \alpha \hat{y}_i + (1 - \alpha)\text{median}(q_{i-2}, \dots, q_{i+2}). \quad (3.5)$$

此公式用当前样本 i 及其前后各两个相邻样本（共 5 个样本）的锐化猜测标签 q 的中位数，替代了公式 3.4 中单一的 q_i 。中值滤波能有效滤除时间序列上的脉冲噪声，并使伪标签的变化更加平滑，符合联合循环设备退化过程中退化状态通常连续变化的先验知识。对于不存在明显时序相关性的数据集，可直接采用公式 3.4 而无需中值滤波。

综合公式 3.3、3.4 和 3.5，从模型预测值 $\hat{y}_i$ 计算最终训练伪标签 $\tilde{y}_i$ 的完整流程可由以下联立公式表示：

$$\begin{cases} \tilde{y}_i = \alpha \hat{y}_i + (1 - \alpha)q_i, \\ q_i = \frac{1}{2} - \frac{1}{2} \cos \left[\pi \frac{t_i - \min_i(t_i)}{\max_i(t_i) - \min_i(t_i)} \right], \\ t_i = \frac{1}{1 + \exp \left(-\frac{\hat{y}_i - \mu_{\hat{y}_i}}{\sigma_{\hat{y}_i}} \right)}. \end{cases} \quad (3.6)$$

动态样本加权：锐化伪标签函数在提升判别力的同时，也增加了模型对潜在错误的高置信度伪标签（即确认偏误）过拟合的风险。原始的静态样本加权策略，其权重 w_i 仅依赖于数据集的类别先验概率 π ，无法区分样本的分类可靠性。

为更精细地缓解确认偏误，本文提出一种基于样本分类置信度的动态样本加权函数：

$$w_i = \left| \frac{\hat{y}_i - 1/2}{2} \right|^4 + \epsilon_w. \quad (3.7)$$

该函数以样本的代理类别概率 $\hat{y}_i$ 作为置信度量，通过样本权重分配，迫使训练过程将主要注意力集中于模型当前已能可靠分类的样本上。函数值 w_i 随 $|\hat{y}_i - 0.5|$ 的增大而单调递增。对于预测值 $\hat{y}_i$ 接近分类边界 0.5 的分类判别模糊的样本，其权重被显著降低至接近最小值 ϵ_w （例如 1×10^{-4} ）。反之，对于预测值 $\hat{y}_i$ 接近 0 或 1 的分类判别清晰的高置信度样本，其权重则通过四次多项式被渐进式放大。这有助于在训练早期，当伪标签质量尚不高时，减少因错误伪标签引入的噪声，从而有效抑制确认偏误的积累。该权重函数的计算复杂度同样为 $O(n)$ 。

3.3.2.1 算法整体流程

SatPU 的整体算法流程归纳如算法 3.1 所示，包含初始化、伪标签计算与平滑、样本重加权到模型参数更新的完整迭代步骤。

算法 3.1 SatPU 算法

Require: 多变量时间序列 $\mathbf{X} \in \mathbb{R}^{n \times m}$ ，部分标签 $\mathbf{Y} \in \{\text{U}, \text{P}\}^m$ ，二分类模型 $g(\mathbf{x}, \boldsymbol{\theta}) : \mathbb{R}^N \rightarrow [0, 1]$ ，以及超参数 α, E_{p0}, E_{ad} 。

Ensure: 训练后的模型参数 $\boldsymbol{\theta}$ 。

- 1: 使用公式 (3.2) 初始化训练伪标签 $\tilde{y}_i$ 。
 - 2: **for** 训练轮次 e 从 1 到 $E_{p0} + E_{ad}$ **do**
 - 3: **if** $e > E_{p0}$ **then**
 - 4: 计算模型在训练集上的中间预测值: $\hat{y}_i = g(\mathbf{x}_i, \boldsymbol{\theta})$ 。
 - 5: 使用公式 (3.6) 计算伪标签 $\tilde{y}_i$ 。
 - 6: 使用公式 (3.7) 计算样本权重 w_i 。
 - 7: **end if**
 - 8: 基于损失函数 $L(g, \boldsymbol{\theta}) = \frac{1}{\sum_i^n w_i} \sum_i^n w_i l[g(\mathbf{x}_i, \boldsymbol{\theta}), \tilde{y}_i]$ ，采用随机梯度下降法更新模型参数 $\boldsymbol{\theta}$ 。
 - 9: **end for**
-

算法包含一个初始的预热阶段（前 E_{p0} 轮）和后续的自适应训练阶段（ E_{ad} 轮）。预热阶段使用初始化的固定伪标签进行训练，旨在让模型获得初步的判别能力。进入自适应训练阶段后，每一轮迭代都会动态地根据当前模型状态重新计算伪标签和样本权重，从而实现对训练目标的持续优化与校准。后文将通过具体的数值实验，可视化展示该算法迭代过程中伪标签与样本权重的动态变化，并定量验证其在缓解确认偏误、提升最终分类性能方面的有效性。

3.4 数值实验验证

本节通过公开的传感器时间序列数据集验证了所提算法对训练所需历史数据的状态信息不完备问题具有更强的鲁棒性，具体包括对历史数据状态标注量的依赖性分析以及对训练完全随机抽取假设的依赖性分析。

3.4.1 数据集与实验设置

所用的两个公开数据集和实验设置如下。

3.4.1.1 数据集 A：故障仿真传感器时间序列数据

数据集 A 为包含预设故障的公开的仿真数据集 Tennessee Eastman Process (TEP)^[111]，数据形式为慢变传感器时间序列数据。该数据集被广泛用于过程监控领域的建模研究，并被视为检验状态识别方法最常用的基准数据集之一。本节通过公开数据集 A 上进行实验的核心目的是分析状态识别方法对历史数据状态标注量的依赖性。在生产环境下异常状态的标注较为稀缺，一方面由于定期的检修，联合循环运行机组的设备处于异常状态的数据样本较少，造成异常状态历史样本稀缺；另一方面，异常状态的标注需要结合设备专业知识因此标注成本较高，使得常见的数据情况为仅含正常标注而不含异常标注的正-无标签学习问题。为了模拟这种情况，在本数据集上仅将一小部分正常状态样本标注为正例，异常状态（负例）都不做标注，除被标注正常状态的样本外均为无标注样本，其比例为 p_u ，其中包含正例与负例。

数据集 A 由带有故障标注的时间序列测量数据构成。测量数据包含 52 个过程变量，采样间隔为 3 分钟。故障标注用于标识每段数据是否被注入了特定类型的异常（如偏置或漂移），以及所注入故障的具体类型。数据通过仿真模型在正常运行中注入各类异常生成。训练集中的每次仿真运行包含 500 个样本，涵盖了 20 种预设故障工况和 1 种正常工况。每种工况的训练集与测试集均源于独立的仿真运行。现有研究 Quiñones-Grueiro et al.^[112] 表明，多数故障工况（如 IDV-1、IDV-5 和 IDV-12）能被大多数检测方法有效识别；而部分工况（如 IDV-3、IDV-9 和 IDV-15）则因其故障信号微弱或与系统噪声混杂，存在固有识别难度，仅被少数方法成功检测。本文在数据集 A 上的实验，旨在评估各方法在正例-无标记学习（Positive-Unlabeled Learning）设置下处理模糊标注的能力，而非针对特定故障特征进行建模。因此，后续实验选取了具有代表性的异常工况 IDV-1。实验所用数据为公开数据集，是 Rieth et al.^[113] 所发布的原始数据集的扩展版本。图 3.3 展示了流程示意图及仿真信号示例。依据前文所述的正-无标签学习的问题条件，对数据进行分段处理。训练集与测试集均通过滑动时间窗口切片生成固定长度的序列样本。窗口长度设置为 36 分钟，对应 12 个连续测量时刻。每个样本以其窗口的结尾时刻作为判断是否发生故障的目标时刻。判定逻辑为：若故障注入时刻早于或等于该样本的结尾时刻，则该样本被标记为故障样本（正例）；否则标记为正常样本。最终，整个训练集包含 4000 个样本，每个样本的维度为 12×52 （时间点 $\times$ 过程变量通

道)。




图 3.3 数据集 A 中的仿真信号示例^[114]

3.4.1.2 数据集 B：实际传感器时间序列数据

数据集 B 采用的基准数据集是 The Development and Application of Methods for Actuator Diagnosis in Industrial Control Systems (DAMADICS) 公开数据集^[115]。对数据集 B 的处理方式与数据集 A 类似，在数值实验中不标注异常样本仅标注少量正常状态样本。

数据集 B 为实际传感器测量的时间序列数据，包含从 2001 年 10 月 29 日至 11 月 22 日期间在控制系统中连续采集的测量数据。在这 25 天的采集周期内，人为共引入了 19 次故障。数据采集系统每秒记录一次与三个关键执行器相关的 32 个实值测量数据，并附带时间戳。因此，每日生成一个维度为 86400×33 的数据矩阵。数据样例如图 3.4 所示。本实验重点关注被引入到 3 号执行器（进水流量控制器）的注入故障。训练集选自 2001 年 11 月 9 日第 59400 至 86400 号样本区间，并从中提取与 3 号执行器监测相关的 10 个传感器测量值（从总共 32 个传感器中选取）。如图 3.4 曲线所示，该训练数据段在起始部分包含两次阀门定位器供气压力下降事件，其余大部分时间处于正常运行状态。由于原始数据采样率（1 Hz）远高于许多实际监控系统的需求，为模拟更通用的监控场景，将其降采样至每 30 秒一个样本。测试集则选用 2001 年 11 月 17 日全天的数据段，其中共包含 10 次独立的异常事件。测试任务要求模型从中准确识别出与 3 号执行器相关的 3 次故障事件。为与在线监控框架保持一致（即以近期历史测量值作为模型输入），训练集与测试集均按照与数据集 A 实验相同的方式进行分段处理，即生成维度为 12×10 （时间点 $\times$ 传感器通道）的样本矩阵。经统计，数据集 B 中训练集与测试集的异常样本比例分别为 2.4% 和 1.4%。报告的所有评估指标均为进行 20 次独立试验后的平均值，以减少随机性影响。




图 3.4 数据集 B 的数据样例^[115]

3.4.1.3 实验设置与评估指标

联合循环生产运行环境下设备状态信息不完备导致的历史数据标注量不足的问题,造成了数据驱动的状态识别方法的应用受到局限,研究者针对这一问题提出了半监督学习方法以利用数据量大而标注量低的数据。本节的实验将所提 SatPU 方法与现有的半监督学习方法对比,定量对比其在历史数据标注量不足情况下的性能表现。

首先评估各对比方法对于历史数据标注量的依赖性,即无标注样本比例 p_u 对方法性能的影响。定义无标注样本比例参数 p_u 用于控制训练集的标记状态,其计算方式为 $p_u = 1 - N_{\text{positive}}/N_{\text{total}}$,表示训练集中无标注样本所占的比例,其中 N_{positive} 为标记为正例的样本数, N_{total} 为训练集总样本数。同时,训练集本身存在类别分布不平衡的挑战,异常样本在总体中的占比记为 $p_f = N_{\text{anomalous}}/N_{\text{total}}$,该比例显著低于正常样本比例。

其次定性评估各对比方法对历史数据分布假设的依赖性,具体通过方法在数据分布假设较强的仿真数据集 A 与数据分布假设较弱的实际传感器测量数据集 B 的异常识别性能差异对比。

评估指标 本实验主要采用 F1 分数作为综合评价各方法分类性能的核心指标,该指标综合了精确率与召回率,适用于类别不平衡的场景。除 F1 分数外,实验还同步报告准确率、精确率及召回率这三项常见的二分类性能指标,以提供更全面的比较视角。

精确率衡量的是模型预测为正例的样本中实际为正例的比例,侧重于控制误报(即假阳性);召回率则反映实际为正例的样本中被模型正确识别的比例,侧重于控制漏报(即假阴性)。两者虽互为补充,但各自存在局限:精确率无法反映模型对真实正例的覆盖程度,召回率亦不能体现预测结果的误判比例。在异常检测任务中,高精确率意味着报警可靠性高、误报率低;高召回率则代表对真实异常的检出能力强、漏报率低。理想的异常检测方法应在两者间取得良好平衡。

准确率虽然同时考虑了假阴性与假阳性,但在异常样本极少的不平衡数据中,该指标容易由占多数的正常样本主导,从而掩盖模型对关键少数类(即异常)的识别能力。因此,仅依靠准确率难以充分评估异常检测模型在目标类别上的实际表现,需结合更具判别性的指标进行综合分析。

3.4.1.4 参与对比的现有方法

为定量评估本章所提出的自适应训练正-无标签学习方法（SatPU）的性能，本节的实验将其与当前主流正-无标签学习方法以及一个基于相同分类模型的简单有监督基线方法进行对比。各对比方法的具体说明如下。

有监督基线方法: 该方法将分类模型直接作为有监督分类器使用，不引入任何正-无标签学习机制，且将所有无标注样本视作负例进行训练。在此设定下，当训练集中无标注样本比例较高时，模型极易对噪声标注产生过拟合。该基线模型的结构依次为：包含 18 个节点并使用 ELU 激活函数的 LSTM 层（在数据集 B 的实验中，由于数据特性将该层替换为全连接层）、丢弃率为 4% 的 Dropout 层、包含 2 个节点且采用线性激活的全连接层，以及最终的 Softmax 输出层。需特别说明，本实验中所有对比方法均采用完全相同的模型结构，以确保比较的公平性。

DeepDCR^[116]: 该方法由 Zeng et al.^[116]提出，是一种两阶段正-无标签学习方法，其核心在于第一阶段通过负例扩展策略筛选出高置信度的负例样本。

Dist-PU^[117]: 由 Jiang et al.^[117]提出的一种无偏正-无标签学习方法。该方法通过最小化预测结果的总体熵，促使模型输出与已知类别先验分布保持一致。

robustPU^[118]: 由 Zhu et al.^[118]提出的一种正-无标签学习方法。该方法采用迭代微调策略，在训练早期通过伪标注技术筛选出学习难度较低的样本进行模型更新。

nnPU^[99]: 一种经典的基于无偏风险估计的正-无标签学习方法，其建立在 SCAR 假设之上。该方法利用已知的类别先验概率，对经验风险进行无偏估计以优化模型。

ImbPU^[119]: 一种专门针对类别不平衡场景设计的无偏正-无标签学习方法，其在风险估计中考虑了类别分布的不均衡性。

LSIF^[120]: 一种基于重要性加权拟合的正-无标签学习方法。该方法无需预先获取类别先验知识，并通过重要性估计来缓解分布偏移与标注偏差问题。

3.4.2 算法有效性的定量验证

本节分析各对比算法在训练数据标注缺失条件下的状态识别性能，具体通过定量比较 F1 分数等指标随无标注样本比例 p_u 的变化情况来实现。

3.4.2.1 无标注数据比例影响分析

无标注样本比例 p_u 的升高直接导致训练集中可用的标注信息减少，从而对半监督学习方法的性能构成更严峻的考验。分类性能的定量结果如表 3.1 所示，当 p_u

从 0%（即全监督问题设定）增至 80% 时，该方法的 F1 分数从 95.77% 大幅下降至 31.71%。与此形成对比的是，各类正-无标签学习方法在此条件下的性能均稳定优于监督基线。这一对比结果表明，正-无标签学习框架能够有效利用未标记数据，缓解因监督信息不足而导致的模型性能退化。

表 3.1 数据集 A 上各对比方法性能指标汇总

指标 (%)	p_u	有监督	SatPU	DeepDCR	DistPU	robustPU	nnPU	ImbPU	L-SIF
F1 分数	80	31.71	95.91	63.62	95.65	27.68	95.65	90.38	95.68
	60	40.93	95.74	83.33	95.65	40.87	95.68	87.97	95.68
	40	59.21	96.14	92.42	95.65	73.04	95.83	95.25	95.65
	25	89.57	96.21	90.59	95.65	95.75	94.88	96.11	95.65
	0	95.77	96.26	96.40	95.65	95.68	62.29	95.83	95.65
准确率	80	36.29	98.82	84.33	98.75	22.20	98.75	97.07	98.76
	60	58.22	98.76	94.54	98.75	57.88	98.76	96.17	98.76
	40	80.52	98.88	97.80	98.75	89.58	98.80	98.62	98.75
	25	96.75	98.90	97.22	98.75	98.78	98.49	98.88	98.75
	0	98.77	98.92	98.96	98.75	98.76	82.90	98.80	98.75
精确率	80	18.89	99.64	48.80	> 99.99	16.08	> 99.99	88.97	> 99.99
	60	25.97	98.70	76.89	> 99.99	25.89	> 99.99	83.24	> 99.99
	40	43.16	99.88	95.66	> 99.99	59.66	> 99.99	98.17	> 99.99
	25	86.34	99.64	92.18	> 99.99	99.82	96.71	99.94	> 99.99
	0	98.65	99.76	> 99.99	> 99.99	> 99.99	46.54	> 99.99	> 99.99
召回率	80	98.61	92.44	91.39	91.67	99.28	91.67	91.83	91.72
	60	96.50	92.94	90.94	91.67	97.06	91.72	93.28	91.72
	40	94.28	92.67	89.39	91.67	94.17	92.00	92.50	91.67
	25	93.06	93.00	89.06	91.67	92.00	93.11	92.56	91.67
	0	93.06	93.00	93.06	91.67	91.72	94.17	92.00	91.67

分类性能随无标注样本比例 p_u 的变化趋势如图 3.5 所示。可以看到随着无标注样本比例 p_u 的逐步增加，有监督基线方法的性能显著下降。

在无标注数据比例高达 80% 的极端设定下，SatPU、DistPU 及 LSIF 三种方法所达到的性能，与有监督基线在 $p_u = 0$ （即拥有全部标注）时的性能水平相当。这




图 3.5 不同无标注样本比例下数据集 A 结果的 F1 分数对比

一发现证实，在完全随机抽取假设条件下，本文所提出的 SatPU 方法在正-无标签学习任务上达到了同类算法的当前最优性能。

此外从实验数据观察到，监督基线方法的召回率数值异常偏高。其根本原因在于，该方法的训练策略将所有无标注样本默认归类为负例，致使模型在学习过程中产生将样本过度预测为正例的倾向。此种策略虽然能够最大限度地减少假阴性样本的数量，即提高召回率，但同时也引入了大量的假阳性样本，导致精确率急剧下降。因此，其综合性能指标 F1 分数仍会出现严重下滑，这进一步凸显了在标注缺失情况下采用专门设计的学习框架（如正-无标签学习）的必要性。

3.4.2.2 数据集 B 结果的定量讨论

为系统评估无标注数据比例 p_u 对模型性能的影响，进一步分析各方法在数据集 B 的时间序列上的状态识别性能。该数据集不满足完全随机抽取（SCAR）假设，更贴近实际应用场景。为减少随机性的干扰，所有结果为 20 次试验的平均值。

图 3.6 展示了各方法在数据集 B 上随 p_u 变化的性能趋势。




图 3.6 不同无标注样本比例下数据集 B 上 F1 分数对比

表 3.2 数据集 B 上各对比方法性能指标汇总

指标 (%)	p_u	有监督	SatPU	DeepDCR	DistPU	robustPU	nnPU	ImbPU	LSIF
F1 分数	80.0	2.18	29.72	2.05	2.24	2.68	0.00	2.01	2.68
	60.0	1.91	42.17	4.84	2.94	3.18	0.57	2.13	2.68
	40.0	1.61	43.64	4.08	2.57	6.99	2.26	5.46	2.70
	25.0	8.98	46.99	21.58	7.22	12.43	8.70	9.64	3.01
	20.0	24.47	38.91	33.99	23.68	33.18	9.02	11.05	3.48
准确率	80.0	8.75	91.34	12.64	78.70	1.36	98.42	11.58	1.37
	60.0	27.01	94.23	71.90	72.42	25.70	97.73	7.76	1.39
	40.0	21.47	97.33	66.14	76.22	77.72	96.51	61.91	2.01
	25.0	76.61	97.98	86.37	81.17	82.81	97.45	69.25	12.32
	20.0	92.10	97.09	94.33	93.93	95.08	97.98	79.57	24.57
精确率	80.0	1.11	21.13	1.04	1.19	1.36	0.00	1.02	1.36
	60.0	0.97	35.51	2.72	1.55	1.62	0.51	1.08	1.36
	40.0	0.82	35.97	2.37	1.36	3.70	1.84	2.88	1.37
	25.0	4.76	43.79	13.17	3.87	6.68	24.37	5.98	1.53
	20.0	14.23	27.89	21.98	14.29	20.35	22.06	6.26	1.77
召回率	80.0	74.87	72.56	66.92	17.95	> 99.99	0.00	65.90	99.74
	60.0	52.05	71.79	35.77	30.77	89.74	0.64	74.49	> 99.99
	40.0	47.05	65.77	27.56	23.08	61.54	3.08	68.85	> 99.99
	25.0	83.08	57.95	90.13	53.85	89.74	8.59	71.15	> 99.99
	20.0	90.26	66.41	87.82	69.23	89.74	8.33	66.54	> 99.99

结果显示,当无标注样本比例升高时,多数对比方法的性能出现大幅下降。具体而言,当 p_u 从 25% 增至 80% 时,传统无偏正-无标签学习方法的平均 F1 分数下降幅度超过 40%。表 3.2 提供的详细性能指标进一步表明,这种衰退主要源于模型精确率的急剧降低,反映出假阳性预测数量显著增加。在在线异常检测任务中,假阳性导致的误报会直接影响告警系统的可信度,并产生不必要的运维成本,因此精确率下降相比召回率变化是一个更为严峻的问题。

综合数据集 A 和数据集 B 的实验结果得出结论,所提出的 SatPU 方法对基于仿真和实际传感器数据的状态识别任务均具有有效性。尤其在无标注比例较高的非理想条件下, SatPU 的性能达到或超过了现有主流方法。

3.4.2.3 定性分析与假设依赖性讨论

完全随机抽取 (Select Completely At Random, SCAR) 假设是无偏正-无标签学习方法的理论基础。该假设要求已标注的正例样本是从整个正例分布中完全随机抽取的一个子集, 这意味着已标注正例在特征空间中的分布应与全部潜在正例 (包括已标注和未标注) 的总体分布一致。基于此假设, 无偏方法能够推导出无需负例标注的经验风险估计器。然而, 这一严格假设在联合循环生产运行环境中通常难以满足, 从而限制了此类方法在工程实际中的适用性。

为直观检验完全随机抽取假设在不同类型数据中的有效性, 本节使用前述的两个具有代表性的数据集进行对比分析, 具体使用了主成分分析 (Principal Component Analysis, PCA) 进行高维原始数据的降维。PCA 能够在不大量丢失数据信息的情况下, 降低数据维度并提高可解释性^[121]。




图 3.7 基于 PCA 降维的两个数据集数据分布对比

图 3.7 展示了对两个数据集应用 PCA 降维后的数据分布对比。在图 3.7 (a) 所示的仿真数据集 A 中, 已标注正例 (以橙色点表示) 的分布与整个数据集中所有正例样本的分布区域高度重叠。这种分布一致性符合 SCAR 假设的预期, 表明在该仿真环境中, 正例的标注过程可以近似看作完全随机抽样。相比之下, 图 3.7 (b) 展示的实际传感器时间序列数据集 B 呈现出明显不同的模式。该数据集中, 已标注正例的分布显著偏离了整体正例样本的潜在分布区域, 形成了偏置的分布形态。

这一现象直观表明，真实工业场景中的故障记录或标注过程并非完全随机，很可能受到隐性选择偏差的影响，导致完全随机抽取假设不成立。通过对比仿真与真实数据集的分布差异，本研究为后续方法设计提供了关键的实证依据，即需要开发对完全随机抽取假设依赖更弱的学习算法以应对现实挑战。

训练过程对比：鉴于完全随机抽取假设在联合循环生产环境数据中的脆弱性，本章所提方法改进于自适应训练（Self-adaptive training）框架，其不依赖于该假设，而是通过模型自身的预测迭代地优化训练目标，因此被引入用于处理实际传感器数据。然而，原始的自适应训练算法在正-无标签学习场景下存在收敛至次优解的风险。

为具体说明该问题并展示改进效果，本节从上文所述的实验设定选取一个特定实验案例进行对比：使用数据集 A，设定未标注样本比例 $p_u = 40\%$ ，即数据集中包含 40% 的已标注正例和 60% 的未标注样本（其中包含未标注正例与负例）。在此设置下，分别应用原始自适应训练算法（Sat）与本文提出的改进算法（SatPU）进行训练，并可视化关键训练阶段的模型内部状态。

图 3.8 (b) 展示了原始自适应训练算法在训练接近收敛时某一轮次的详细状态。图 3.8 (b) 上方的核密度估计图反映了模型预测值的分布情况。可以观察到，代表正例（含已标注 LP 和未标注 UP）与负例（UN）的分布曲线之间存在较大的重叠区域，表明两类样本的类间距离较小，区分度有限。同时，未标注正例（绿色分布）自身的分布范围较宽，显示出较大的类内距离。这两项特征共同说明，模型未能学习到具有高度判别力的特征表示，导致大多数样本的代理类别概率 $\hat{y}_i$ 聚集在分类决策边界（ $\hat{y}_i = 0.5$ ）附近，学习过程陷入一个缺乏判别能力的局部平衡点。

图 3.9 (b) 展示了在完全相同的实验设置下，采用 SatPU 算法训练至相同时期的状态。与图 3.8 (b) 对比，其分布形态发生显著变化。首先，正例样本（包括已标注和未标注）的预测值分布明显偏向正例类别边界（ $\hat{y}_i = 1$ ）方向，而与负例分布的重叠区域大幅减少，即类间距离增大。其次，未标注正例内部的分布变得更加集中，类内距离减小。这种分布变化表明，SatPU 算法通过其设计的锐化伪标注函数与动态样本加权机制，有效引导模型学习了更具判别性的特征，获得了比原始算法更明确的分类决策边界。此外，图下方面板展示了 SatPU 算法中样本权重 w_i 的动态调整结果。权重根据模型对各样本的分类置信度（即 $|\hat{y}_i - 0.5|$ ）进行非线性分配，对预测模糊的样本赋予极低权重，从而将训练焦点集中于当前模型已能可靠分类的样本上。这一机制有助于缓解因早期错误伪标注而引发的确认偏误（confirmation bias）问题。上述训练动态的定性对比，从算法内部运作机制的角度，验证了 SatPU 在应对正-无标签学习挑战方面的改进与有效性。




图 3.8 原始自适应训练算法 (Sat) 训练过程可视化

不同类别方法在仿真与实测数据集上表现出的性能差异，根源在于其对完全随机抽取假设的依赖程度不同。数据集 A 作为仿真数据集，其已标注正例的生成严格遵循完全随机抽取假设，即它们是从所有真实正例中完全随机抽取的，与样本特征无关。这使得基于该假设设计的无偏方法（如 DistPU, nnPU, ImbPU）在此类数据上能够充分发挥其理论优势。如图 3.5 中橙色与褐色曲线的趋势，即使在未标注样本比例 p_u 较高的情况下，这类方法的 F1 分数下降幅度也能被控制在 10% 以内，证明了在理想假设条件下其风险估计器的有效性。

然而在实际生产环境下的传感器测量数据集上，退化状态标注并非完全随机，而是标注了其中退化状态确定性最高的部分数据，存在显著的偏向性，从而违反了完全随机抽取假设。此时，同样依赖于该假设的无偏方法出现了显著的性能衰退。如图 3.6 所示，同样算法 DistPU, nnPU, ImbPU 的 F1 分数大幅下降，同时精确




图 3.9 SatPU 算法训练过程可视化

率显著降低，这主要是因为算法的无偏性严重依赖于“已标注正例分布与全体正例边际分布完全相同”这一前提。当此前提不成立时，其基于完全随机抽取假设推导的风险估计器会产生系统性偏差，导致模型判别能力下降，具体常表现为将大量实际负例错误地判定为正例。

相比之下，本章提出的 SatPU 方法通过自适应训练机制，降低了对完全随机抽取假设的依赖。图 3.5 和图 3.6 的定量结果表明，SatPU 方法在数据集 A 和数据集 B 上，面对不同的 p_u 条件，均能维持较高的精确率与 F1 分数。性能表现的稳定性说明，SatPU 的损失函数设计与动态权重调整策略，能够在一定程度上自适应地补偿因标注缺失机制非随机性所带来的分布偏移问题，从而在更宽松的假设条件下实现建立状态识别模型。

上述定性分析表明，SatPU 方法通过其自适应训练框架，实现了对完全随机抽取假设的松弛依赖，对历史数据的数据和状态分布假设的依赖性更低，具有更强

的对状态信息非完备条件的生产数据的鲁棒性。这一特性使其相对传统无偏方法在较为复杂的联合循环生产运行环境中的受到数据分布假设的限制更小，为正-无标签学习技术在更广泛、更复杂的实际应用中提供了新的可行方案。

3.4.2.4 消融实验

为评估本章所提 SatPU 方法中各改进环节的有效性，本节在仿真数据集 A 的 IDV-1 故障案例上设计并进行了消融实验，实验设定未标注样本比例为 40%。如表 3.3 所示，共设置了多个对照组进行对比分析。S 组作为基线对照组，代表将原始的自适应训练方法直接应用于当前的正-无标签学习问题。A 组与 A+ 组为 SatPU 方法的不同变体：A 组采用指数移动平均进行平滑滤波；A+ 组则在 A 组基础上，进一步结合了中值滤波与指数移动平均，构成针对时序数据的平滑滤波策略。此外，通过从 A 组配置中依次移除不同的改进环节，构建了 A1、A2、A3 三个消融实验组，旨在分别探究保守初始标注、样本动态加权以及锐化伪标注这三个关键改进环节的个体贡献。具体而言，A1 组移除了保守初始标注改进，A2 组移除了样本动态加权改进，A3 组移除了锐化伪标注改进。

表 3.3 仿真数据集 A 上的消融实验结果

符号	方法	F1 分数 (%)
B	有监督基线方法	70.93
S	原始的自适应训练方法	97.46
A1	无保守初始标注的 A 组方法	85.50
A2	无样本动态加权的 A 组方法	73.70
A3	无锐化伪标注的 A 组方法	91.90
A	无时序平滑滤波的 SatPU 方法	99.10
A+	完整的 SatPU 方法	99.29

表 3.3 汇总了各组方法由 F1 分数评价的最终分类性能。为详细观察策略对训练过程的影响，图 3.10 进一步绘制了各方法在训练期间，每一轮次在独立测试集上计算得到的 F1 分数变化曲线。为降低训练随机性的影响，图中结果为 20 次独立重复实验的平均值。图中各曲线与表 3.3 中的方法一一对应。

从训练动态曲线中可以获得以下观察与分析。

首先，代表基线方法 B 的蓝色曲线显示，该策略将所有未标注样本简单标记为负例，其 F1 分数在大约第 5 个训练轮次后便开始下降，表明模型很快出现了过拟合。相比之下，代表原始自适应训练方法 S 的黄色曲线在进入自适应训练阶段




图 3.10 各消融实验组在训练过程中的 F1 分数变化曲线

(约第 20 轮次后)后, F1 分数开始稳步上升。这说明自适应训练机制本身能够在校准伪标注的过程中带来性能增益, 验证了其在正-无标签学习问题中的有效性。

其次, 代表 SatPU 方法的 A 组(棕色曲线)和 A+ 组(粉色曲线)显著优于 S 组。两者在预热阶段及自适应训练早期, F1 分数均保持平稳, 未出现明显过拟合。方法 A 作为通用版本变体, 未使用时序滤波器; 方法 A+ 则是为具有时序相关性的传感器数据设计的 SatPU 变体。两种变体的收敛速度均远快于 S 组, 在进入自适应训练阶段后的 20 个轮次内, F1 分数便迅速提升至 97% 以上, 并最终稳定在 99% 左右。这一结果从训练效率和最终精度两方面证实了 SatPU 相对于原始自适应训练方法的优势。同时, A+ 组性能略优于 A 组, 表明在处理时序数据时, 在伪标注生成环节引入时序滤波能够带来额外的性能提升。

针对三个消融组的分析揭示了各改进组件的具体作用:

A2 组(红色曲线)移除了动态样本加权策略, 即使用原始自适应训练中的静态权重(公式 3.1)替代 SatPU 的动态权重函数(公式 3.7)。其 F1 分数在第 20 轮次后出现显著下降。这归因于在缺乏动态权重调节的情况下, 模型对早期可能错误的高置信度伪标注过拟合, 从而引发了严重的确认偏误。SatPU 的动态加权通过降低分类不确定样本的权重, 有效缓解了这一问题。值得注意的是, A2 组虽使用了锐化伪标注, 但因缺少动态加权的平衡, 其最终性能反而低于 S 组。

A3 组(紫色曲线)移除了锐化伪标注策略, 即使用原始自适应训练的线性伪标注函数(公式 3.1)替代 SatPU 的锐化函数(公式 3.3)。其训练曲线在整个过程中变化平缓, 性能提升有限, 最终结果也低于 S 组。这表明, 仅依靠动态加权而缺乏锐化伪标注提供的判别力增强, 模型优化会过于保守, 难以有效利用数据进行学习。

A1 组（绿色曲线）移除了保守初始标注策略（公式 3.2）。如图左侧所示，在预热阶段（前 20 轮次），B 组、S 组和 A1 组的 F1 分数均呈现相似的下降趋势。而采用了保守初始化的 A2、A3、A、A+ 各组则在该阶段保持了稳定。对比 A 组与 A1 组的最终性能可知，保守初始化有效缓解了预热阶段的过拟合，为后续自适应训练奠定了更优的起点，从而显著提升了最终模型的判别准确率。

综合以上分析，锐化伪标注与动态样本加权两项改进在实践中呈现出一种对抗平衡关系：锐化伪标注旨在增强模型判别力，但可能提高确认偏误的风险；动态加权则通过抑制不确定性样本的贡献来对抗由此引发的确认偏误。消融实验表明，二者单独使用时均无法取得最优效果，甚至可能劣于原始方法；只有当它们如 A 组所示被结合使用时，才能在提升判别力与控制训练偏差之间取得良好平衡，从而实现性能的显著提升。

本节的消融实验系统性地验证了 SatPU 方法中各项改进设计的必要性与有效性。实验结果表明：首先，保守初始标注策略有效缓解了训练初期因标注严重缺失导致的模型过拟合，为后续学习提供了稳定的起点。其次，锐化伪标注函数与动态样本加权策略共同构成了 SatPU 性能提升的核心。二者相互协同，缺一不可：锐化伪标注增强了模型对潜在类别的区分能力，而动态加权则通过对不确定样本降权来抑制由此可能加剧的确认偏误，从而保障了训练过程的稳健性。最后，时序平滑滤波作为针对时序数据的可选增强，能够进一步利用数据的时间相关性，带来额外的性能增益。综上所述，消融实验定量与定性地证明了 SatPU 所集成的改进策略作为一个整体，能够显著提升模型在正-无标签学习场景下的分类精度、收敛速度与训练稳定性，从而验证了本章方法设计的合理性与有效性。

3.5 联合循环设备性能退化状态识别应用案例

本节针对实际的联合循环运行机组进行部分设备或部件的退化状态识别，选取的研究对象为 2.3.2.1 中展示的 706MW 二拖一机组。在该联合循环机组中最常见的设备退化为压气机进气滤网的退化，此外汽轮机的退化也会造成其效率的恶化，进而降低汽轮机的出力。

在上一节中通过公开的传感器时间序列数据集，检验了本章所提的基于自适应学习和伪标签的状态识别算法的性能和鲁棒性，验证了算法能够在历史数据状态标注量小、仅标注正常状态并且标注不满足完全随机抽取假设的条件下，可以训练状态识别模型。本节利用所提算法的能力，在联合循环设备的退化状态识别问题中应用，实现压气机进气滤网和高压缸的退化状态识别，并降低建模对数据标注和设备知识的依赖。

首先通过所提 SatPU 算法基于历史数据和少量标注构建状态识别模型，并识别设备的历史退化状态；再在识别结果的基础上，结合设备的部分负荷特性，对退化状态进行评估，并对退化趋势和退化原因进行分析；最后用结合了部分负荷特性对设备退化状态的的人工判断，与模型的识别结果对比来验证模型的识别效果。

3.5.1 压气机进气滤网退化状态识别

压气机进气滤网包括预过滤器、粗滤和精滤的多级滤网，其作用是对进入压气机的大气进行预先过滤，以防止大气中的杂质对燃机叶片造成损伤。随着运行时间的增加，杂质在滤网上逐渐积累，导致滤网通流能力下降，即发生性能退化。该退化状态的直接表现为通过滤网的空气差压增大，进而造成压气机进气压力降低，最终导致燃机的整体热效率下降。其与联合循环的经济性密切相关，因此约 3 至 6 个月就会通过更换预过滤器来恢复进气滤网退化造成的性能下降。

3.5.1.1 案例描述

构建进气滤网退化状态识别模型的基础是选取与滤网工况和性能密切相关的监测参数作为模型输入。本节选取的输入参数如表 3.4 所示。

表 3.4 压气机进气滤网退化识别模型输入参数

参数	含义	单位
π_c	压气机压比	-
T_{amb}	环境温度	K
p_{amb}	环境压力	kPa
$\dot{W}_{gt}$	燃机出力	MW
Δp_1	预过滤器及粗滤差压	kPa
Δp_2	整体滤网差压	kPa
Δp_3	滤网及喇叭口差压	kPa

模型训练数据取自进气滤网升级改造后，自 2024 年 9 月至 2025 年 4 月春检前的运行数据。经数据清洗后，共获得 18555 条有效数据。模型的评估与验证则采用春检后 2025 年 6 月至 2026 年 1 月的运行数据。

数据的示例如图 3.11 所示，可以看到数据点展示了数据的示例片段，为 1 号燃机在 2024 年 10 月某一时段内、经筛选后的稳态工况点。图中显示，整体进气差压 Δp_3 的波动范围约为 10 至 20Pa，且该差压与反映工况的压比 π_c 呈现强相关性。




图 3.11 进气滤网差压数据示例

3.5.1.2 数据驱动的压气机滤网退化状态识别

根据本章引言中所提的思路使用本章所提的 SatPU 方法，尝试在既不输入准确的滤网部分负荷特性，也不提供全部数据的准确状态标注的情况下训练状态识别模型。选择少量较为确定为健康状态的时间段，标注为正例。获知预过滤器滤网在 2025 年 1 月 5 日更换，更换后的滤网在一段时间内为正常状态，因此将 2025 年 1 月 5 日后 25 天内的数据标注为正例，剩余数据都作为无标注样本。将表 3.4 的传感器测量历史数据和上述标注输入 SatPU 算法，此数据构成标注量少且不满足完全随机抽取假设的训练集，依赖于 3.4 节验证的算法在这两个条件下的建模能力。训练得到退化状态识别模型，再利用该模型分别对 2024 年 10 月至 2025 年 5 月之间的训练数据，以及 2025 年 6 月至 2026 年 1 月之间的测试数据进行退化状态识别。

识别的结果如图 3.12 所示，其横坐标表示时间，深色区间表示识别的退化状态，可以看到识别得到两台压气机滤网的退化状态多数情况下同步，并且以 3 至 4 个月的周期在退化状态与健康状态之间波动。下文结合进气滤网部件的部分负荷特性在识别结果的基础上进一步进行退化评估和退化趋势退化原因分析，并分析模型识别结果的合理性。

3.5.1.3 压气机滤网性能退化评估

进一步基于具体的滤网的部分负荷特性，分析其性能退化的程度和发展趋势。整体滤网差压 Δp_2 与压比 π_c 的历史数据分布如图 3.13 的散点所示。图中显示，整体滤网差压 Δp_2 随压比的增大而增大。进一步的数据分析表明，各差压测量值与进气温度也存在相关性。以整体滤网差压 Δp_2 与压比 π_c 的联合分布为依据，可人工标注退化状态样本，其分界线如图 3.13 中虚线表示的退化基准线 Δp_2^* 所示。健康状态的数据点集中分布于虚线 Δp_2^* 下方，而性能退化状态的数据点则位于虚线




图 3.12 压气机滤网退化状态识别问题数据驱动模型识别结果

上方，表现为在相同工况下具有更高的差压。




图 3.13 整体滤网差压与压比运行时间分布图

将与压比相关的实测差压 $\Delta p_2(\pi_c)$ 与同压比下的退化基准线 $\Delta p_2^*(\pi_c)$ 做差对比，可以在部分负荷下评估其退化程度。1号压气机进气滤网在两年间的退化程度变化趋势如图 3.14 所示。可以看到由红色虚线标识的是维护发生的时刻，包含多次与过滤器更换和春检秋检，在两次维护之间的 2 至 5 个月的时间中退化程度明显上升，呈现逐渐加速的趋势。在 2025 年 5 月春检之前两轮维护之前滤网退化造成的差压增大在 5Pa 至 8Pa 之间，并且更换预过滤器后滤网差压相比退化基准线 $\Delta p_2^*(\pi_c)$ 稳定低约 2Pa。与之相比在 2025 年 5 月春检之后的退化趋势与之前显著不同，4 月更换的预过滤器并未恢复到比退化基准线 $\Delta p_2^*(\pi_c)$ 低 2Pa 的差压，并且在仅 1 个月

中差压增大了约 5Pa 并被再次更换；2025 年 5 月更换的预过滤器的差压高于退化基准线 $\Delta p_2^*(\pi_c)$ 约 1Pa；2025 年 9 月秋检更换的预过滤器在 2025 年 12 月出现严重退化，差压高出退化基准线 $\Delta p_2^*(\pi_c)$ 达到 20Pa。与现场交流得知，在 2025 年 5 月春检之后使用的预过滤器的生产商与此前不同，因此可以判断前后退化速率的差异是不同预过滤器性能的差异造成的。另一方面，2025 年 12 月出现的严重退化是由于冬季供暖季联合循环机组长期处于高负荷状态，导致的进气滤网的退化加速；另外根据现场人员的经验，空气污染物高也会加速进气滤网的退化，因此冬季空气污染物高也可能是此次严重退化的成因之一。




图 3.14 1 号压气机进气滤网历史退化趋势

3.5.1.4 退化状态识别模型精度评估

将根据上述部件特性人工判断的实际的历史退化状态作为基准，也就是 $\Delta p_2(\pi_c) > \Delta p_2^*(\pi_c)$ 时判断为退化状态并标注相应的历史数据，用于评估本章所提退化状态识别方法建立的模型的精度。首先训练集的人工标注如图 3.15 所示，横坐标表示时间，上方红色区间为根据部件特性人工标注的退化状态，下方的绿色为 SatPU 训练时所假设的设备正常状态，可见此段时间确实属于低滤网差压的正常状态，标注所用的假设是合理的。






图 3.15 压气机进气滤网退化状态标注

标注得到的压气机滤网退化状态与模型判断结果的对比如图 3.16(a)和 3.17 所示，横坐标表示时间，上方红色区间为基于机理方法标注的退化状态，下方的蓝

色较深区间为模型识别的退化状态。可以看到模型的判断与机理方法标注的结果基本一致，训练数据和测试数据上都能够相对准确识别退化状态。模型在测试集上的识别效果的定量指标如表3.5所示，其 F1 分数分别为 1 号燃气轮机 72.65% 和 68.43%，也证实了模型的识别结果较为合理。因此通过本章所提的退化状态识别算法能够在不依赖准确的部件部分负荷特性和准确人工标注的情况下，具备与机理方法相近的在线识别能力，从而降低了对准确设备知识以及人工标注的依赖。




(a) 1 号燃机训练集状态识别模型输出




(b) 2 号燃机训练集状态识别模型输出

图 3.16 压气机滤网退化状态识别问题训练集模型输出与人工标注对比



(a) 1 号燃机测试集状态识别模型输出



(b) 2 号燃机测试集状态识别模型输出

图 3.17 压气机滤网退化状态识别问题测试集模型输出与人工标注对比

表 3.5 压气机进气滤网状态识别模型性能指标

模型指标	1 号燃机	2 号燃机
F1 分数 (%)	72.65	68.43
准确率 (%)	57.05	52.01
精确率 (%)	100.0	100.0
召回率 (%)	52.01	52.01

3.5.2 汽轮机高压缸性能退化状态识别

汽轮机是联合循环底循环的热工转换设备，其中高压缸是汽轮机中蒸气参数（压力和温度）最高的部件。高压缸的性能退化主要表现为通流能力的下降和等熵效率的下降，进而造成汽轮机出力的下降。

3.5.2.1 案例描述

构建高压缸退化状态识别模型的流程与前述压气机进气滤网的案例类似，首先选取与高压缸工况和性能相关的测量与计算参数，如表 3.6所示。与燃气轮机不同，汽轮机大部分工况都在恒定压比下工作，因此压比不适合表征高压缸的工况，适合表征其工况的参数是高压缸进口压力 $p_{ht,in}$ ，最高压力可达 12MPa。

表 3.6 高压缸退化状态识别模型输入参数

参数	含义	单位
$\dot{m}_{ht}$	高压缸流量	kg/s
$p_{ht,in}$	高压缸进口压力	MPa
$T_{ht,in}$	高压缸进口温度	K
$p_{ht,out}$	高压缸出口压力	MPa
$T_{ht,out}$	高压缸出口温度	K
η_{ht}	高压缸等熵效率	%
F_{ht}	高压缸流量系数	kg/(s · MPa)
$\dot{W}_{ST}$	汽轮机出力	MW
T_{Amb}	环境温度	K

模型训练数据自 2024 年 4 月至 2025 年 4 月为期一年的运行数据共 30764 条，并且经过数据清洗筛选了稳态工况，此外由于一拖一工况下高压缸流动不处于阻塞状态不利于退化评估，因此筛选二拖一工况。在模型训练时选取 2025 年 2 月之

前作为训练集，之后的数据作为测试集。

3.5.2.2 数据驱动的高压缸退化状态识别

与上一节的思路类似，同样使用本章所提的 SatPU 算法，在不使用准确的高压缸设备部分负荷特性也不使用全部历史数据准确的状态标注的情况下，训练退化状态识别模型。选择少量较为确定为健康状态的时间段，获知汽轮机在 2025 年 9 月秋检时维护，因此选取 2025 年 9 月之后 50 天的数据作为健康状态数据标注为正例，其余训练数据作为无标注样本。将表 3.6 的传感器测量历史数据和上述标注输入 SatPU 算法，训练得到状态识别模型。再利用该模型分别对 2024 年 4 月至 2025 年 2 月之间的训练数据，以及 2025 年 2 月至 2025 年 4 月之间的测试数据进行退化状态识别。

识别的结果如图 3.18 所示，其横坐标表示时间，深色区间表示识别的退化状态，结果显示识别出的退化状态大部分都在秋检之前，而秋检之后几乎没有。下文结合高压缸的部分负荷特性在识别结果的基础上进一步进行退化评估和退化趋势退化原因分析，并分析模型识别结果的合理性。




图 3.18 高压缸退化状态识别模型识别结果

3.5.2.3 高压缸性能退化评估

进一步基于具体的高压缸的部分负荷特性，分析其性能退化的程度和发展趋势。图 3.19 展示了高压缸等熵效率部分负荷特性，即等熵效率 η_{ht} 与其进口压力 $p_{ht,in}$ 的关系，其中橙色散点表示由模型识别出的退化状态样本。首先可以观察到在进口压力 7.5MPa 之上和之下分为两个不同的模式，这对应了联合循环二拖一运行模式和一拖一运行模式，其中二拖一模式下高压缸输入两台余热锅炉供给的主蒸汽，进口蒸汽压力较高、蒸汽流量较高的同时等熵效率也较高，在 75% 至 84% 之间，并且与工况几乎无关；一拖一模式下高压缸输入一台余热锅炉供给的主蒸汽，进口蒸汽压力较低、蒸汽流量较低的同时等熵效率较低，在 68% 至 76% 之间，随进口压力的增大而增大。这是由于二拖一工况下，高压缸透平内的流动处于阻塞状态因而效率稳定，而在一拖一模式下蒸汽流量不足未达到透平阻塞流量导致的。

进一步从图 3.20 展示的高压缸流量系数与进口压力的关系可以证实，进口压力 $p_{ht,in}$ 高于 7.5MPa 的二拖一工况下其流量系数接近常数，这说明此工况下高压缸




图 3.19 高压缸等熵效率部分负荷特性

的流量和压力关系符合弗留格尔公式，也就是其处于阻塞流动状态；而一拖一工况下其流量系数随进口压力增大而增大不满足弗留格尔公式，说明其未达到阻塞状态。




图 3.20 高压缸流量系数部分负荷特性

以高压缸等熵效率 η_{ht} 与其进口压力 $p_{ht,in}$ 的关系的数据联合分布为依据，可人工标注其退化状态样本，其分界线为图 3.19 中虚线表示的退化基准线 η_{ht}^* 所示。健康状态的数据点分布于虚线 η_{ht}^* 上方，等熵效率高于同工况下的基准值，而退化状态的数据点则位于虚线下方，表现为在相同工况下更低的等熵效率 η_{ht} 。

将实际等熵效率 $\eta_{ht}(p_{ht,in})$ 与同进口压力下的退化基准线 $\eta_{ht}^*(p_{ht,in})$ 做差对比，可以在部分负荷下评估高压缸的退化程度。如图 3.21 所示为高压缸在 2024 年 4 月至 2025 年 4 月之间的退化程度变化趋势。可以看到 2024 年 9 月秋检之前实际等熵效率 $\eta_{ht}(p_{ht,in})$ 显著低于基准值约 1 至 2 个百分点，而秋检之后则高于基准值 1% 至 5%。进一步分析退化趋势可以发现，在秋检之后的两个月中退化程度快速增加，

等熵效率 $\eta_{ht}(p_{ht,in})$ 由高于基准等熵效率 $\eta_{ht}^*(p_{ht,in})$ 约 5 个百分点快速下降至约 1 个百分点，此后的退化速率则显著放缓，直至 2025 年春检之前仅下降约 1 个百分点。退化程度的结果分析表明，秋检的维护恢复了高压缸的退化并短期提升了约 5 个百分点的等熵效率，长期而言在半年年的时间尺度上相比秋检前恢复约 2 个百分点的等熵效率下降。与压气机进气滤网的退化趋势有较大差异，压气机进气滤网退化速率呈现逐渐加速的特征，而高压缸效率退化的速率则呈现逐渐减速的特征。



图 3.21 高压缸效率退化历史趋势

图 3.22 通过高压缸流量系数 F_{ht} 展示了其通流能力退化的变化趋势，可以看到秋检前后对比高压缸流量系数 F_{ht} 提升了约 5 单位，说明高压缸的退化造成了其通流能力的下降，并且经过秋检得到一定程度的恢复，此外在 2024 年 7 月至 9 月可以明显观察到流量系数逐渐下降的趋势，说明在秋检之前的夏季高压缸的通流能力退化速率较快。根据上述现象分析，退化造成效率和通流能力的下降，推断造成高压缸退化的原因以结垢为主。




图 3.22 高压缸通流能力退化历史趋势

3.5.2.4 退化状态识别模型精度评估

将根据上述高压缸部分负荷特性人工判断的实际的历史退化状态作为基准,也就是 $\eta_{ht}(p_{ht,in}) < \eta_{ht}^*(p_{ht,in})$ 时判断为退化状态并标注相应的历史数据,用于评估本章所提退化状态识别方法建立的模型的精度。标注得到的高压缸退化状态与模型判断结果的对比如图 3.23 所示,横坐标表示时间,上方红色区间为基于机理方法标注的退化状态,下方的蓝色较深区间为模型识别的退化状态。可以看到模型的判断与机理方法标注的结果基本一致,训练数据和测试数据上都能够相对准确识别退化状态。同样证实了模型的识别结果较为合理,在高压缸退化状态识别的问题中也能够有效应用。




图 3.23 高压缸退化状态识别模型识别结果与人工标注退化状态对比

3.6 小结

本章针对联合循环生产运行环境状态信息不完备条件下的设备退化状态识别问题,提出一种基于自适应训练的正-无标签学习 (SatPU) 的状态识别方法,在公开数据集上验证了该方法的状态识别能力和对抗状态信息不完备问题的鲁棒性,并在实际联合循环机组运行数据上应用,实现了对两台压气机进气滤网退化以及汽轮机高压缸结垢退化的状态识别。本章的主要结论如下:

(1) 在公开数据集上的实验表明,对比的现有数据驱动方法对训练数据的设备状态准确标注和数据分布假设有较高的依赖性。

在仿真数据集 A 上当未标注样本比例 p_u 从 0% 增至 80% 时,监督基线方法的 F1 分数由 95.77% 降至 31.71%; 半监督学习方法在满足完全随机抽取假设的数据集 A 上识别效果受到状态标注不足影响较小,其 F1 分数仅降低约 5 个百分点,但在不满足该假设的实际数据集 B 上识别效果显著下降, F1 分数降低约 20 至 30 个百分点。

(2) 通过自适应学习与伪标签技术可以降低数据驱动方法对训练数据状态标注量和数据分布假设的依赖性。

本章所提自适应学习与伪标签 (SatPU) 的状态识别方法在仿真数据集 A 上,在不同 p_u 下均保持 95% 以上的 F1 分数,在 $p_u = 80\%$ 时 F1 分数达 95.91%,与全

监督基线性能相当，并且优于 DistPU、nnPU 等现有方法，说明其对训练数据标注量依赖较低；在实际传感器数据集 B 上，在 $p_u = 25\%$ 时取得 46.99% 的 F1 分数，高于其他对比方法（最高 21.58%），且精确率优于多数方法；当 p_u 升高时，SatPU 性能下降幅度最小，表现出对完全随机抽取假设的依赖性较低。消融研究进一步证实：锐化伪标签与动态重加权两项改进对保证算法的鲁棒性具有必要性，二者协同作用可有效平衡判别性能与确认偏误；时序平滑滤波作为可选增强可带来额外性能增益。

（3）通过自适应学习与伪标签技术，可以在不依赖准确的设备部分负荷特性的条件下，建立联合循环运行机组部分设备和部件的退化状态识别模型，识别压气机进气滤网退化和汽轮机高压缸结垢退化。

在实际联合循环运行机组的压气机进气滤网和汽轮机高压缸结垢退化识别的案例中，所提方法通过仅标注了少量退化状态为健康的历史数据，建立了退化识别模型，并且能够识别训练集和测试集数据相应的退化状态。结合压气机进气滤网和汽轮机高压缸的部分负荷特性分析，压气机进气滤网的退化呈现加速趋势，滤网在约 2 至 4 个月的一轮更新周期内，退化造成的总差压增大在 5Pa 至 8Pa，冬季高负荷和空气污染高的环境下最大退化可使差压 20Pa；结合汽轮机高压缸的部分负荷特性分析，推断高压缸的退化主要因为结垢，长期退化的使得通流能力和等熵效率均有下降，高压缸的退化呈现减速趋势，在维护后 2 个月内等熵效率下降 5 个百分点而后下降速率显著放缓，半年以上的长周期尺度上高压缸等熵效率退化约 2 个百分点。使用人工标注的实际退化状态校验模型识别的退化状态，测试集的结果显示模型达到合理的退化识别效果，F1 分数分别为 1 号燃机 72.65% 和 2 号燃机 68.47%，说明本章所提 SatPU 方法能够可以在不依赖准确的设备部分负荷特性的条件下建立退化识别模型。

第4章 基于概率正-无标签学习的联合循环设备退化状态识别方法

4.1 引言

上一章内容在联合循环机组退化状态识别问题中,针对现有数据驱动方法拟合过程对历史数据准确标注依赖性强的不足,提出了基于自适应学习与伪标签的状态识别方法,降低了对历史数据标注量和数据分布假设的依赖性,从而能够利用联合循环机组设备在检修后处于健康状态的信息,标注部分历史数据为正例,从而建立在线状态识别模型。本章在此基础上进一步研究如何利用设备运行维护记录和定性知识提供的其他形式的设备状态信息,建立更准确的状态识别模型。

联合循环的运行维护记录是判断设备历史退化状态的重要依据,运行维护记录可以视为一系列由时间和结论成对构成的单条记录构成的信息列表,包含如系统告警、控制指令在内的系统运行记录,叶片结垢检查、润滑油液检查等检查记录,压气机过滤器更换、压气机水洗等维护记录。这些运行维护记录大多以人工的方式记录,据此推断的设备状态存在随机不确定性与认知不确定性,对含不确定性的历史数据标注的利用是数据驱动方法的挑战,也是数据驱动方法提升工程应用实用性的重要发展方向。随机不确定性包含运维记录中的随机误差,如记录时间存在的延迟、模糊和错误,比如通过周期性停机检查时发现的结垢、磨损退化现象可以判断相应的退化加速发生在此次检查之前和上一次检查或维修之后,但退化加速时刻在此时间段之内的准确时刻存在模糊性,此外由于人工记录的错误或者精度不足也会带来设备状态判定结果的随机不确定性。认知不确定性指来源于信息不足或模型不准确的误差,比如通过压气机水洗或者滤网更换可以推断此刻后的设备退化状态为健康状态,但是由于维修前没有检查相应部件的退化程度,因此对此时刻前的设备退化状态存在认知不确定性。

现有数据驱动方法大多无法利用含不确定性的历史数据标注作为模型训练的输入,针对这一不确定性标注的利用问题,正-无标签学习方法发展出了通过先验概率描述无标注训练集中正例比例的方法^[99,122],但是局限于使用单一概率变量描述整体无标注训练集,难以适用于联合循环机组生产运行环境下的运行维护记录的复杂不确定性问题。

针对上述问题,本章提出一种基于概率正-无标签学习(PPU)的联合循环设备退化状态识别方法。该方法通过定义概率标签,将定性的先验知识转化为设备状态后验概率的不确定性定量表示;再通过一种具有高鲁棒性的基于后验概率的

正-无标签学习算法，接收概率标签作为不确定性标注，建立状态识别模型；并能够使用建立的状态识别模型对联合循环设备的退化状态进行在线识别。

本章后续内容组织如下：4.2节阐述方法的流程与实现；4.3节通过数学推导和数值实验证明所提后验概率的正-无标签（postPU）风险估计器支持多层次后验概率标签作为数据标注，并且对标注误差具有鲁棒性；4.4节通过公开数据集上的状态识别任务，评估本章所提基于概率正-无标签学习的状态识别方法在状态信息不完备条件下的识别性能，验证该方法相对现有方法，对历史数据状态信息随机不确定性和认知不确定性都具有更高鲁棒性；4.5节通过联合循环运行机组的压气机进气滤网退化和汽轮机高压缸结垢退化的状态识别案例，验证该方法在联合循环生产环境下对设备和部件的退化状态识别的应用效果；4.6节总结本章内容。

4.2 概率正-无标签学习算法设计

4.2.1 算法整体流程

为解决联合循环生产环境中的设备状态信息存在的不确定性问题，本章设计一种基于概率标签的正-无标签学习算法（Probabilistic Positive-Unlabeled Learning）。所提算法的整体流程如图 4.1 所示，由三个顺序执行的模块构成：概率标签生成、基于后验概率的正-无标签学习与在线状态识别。该算法能够利用联合循环生产实际中包含确定性故障记录和有限领域先验知识的状态标注信息，实现设备的退化状态识别，而无需获取完全准确的退化状态标注。


概率标签生成：此模块的核心任务是将定性知识与运维记录结合，转化为模型可学习的量化的设备状态，为每个训练样本 $\mathbf{x}_i$ 估计一个后验目标状态的后验概率 $\pi_i \in [0, 1]$ 。

基于后验概率的正-无标签学习：为利用概率标签进行模型训练，本模块设计了一种新的学习算法。该算法的关键设计原则是对概率标签的噪声具有鲁棒性，其理论依据是所构建的风险估计器能够处理监督信息中的不确定性。这一特性使得算法能够有效应对目标早期异常 S 与记录故障 F 之间常见的时间偏移、误报及漏报等不一致性问题。


在线状态识别：在线阶段部署训练好的模型对实时数据进行预测。为保证与训练阶段的一致性，在线处理采用与离线训练阶段完全相同的数据预处理流程与模型参数。该阶段接收近期时间序列，输出二值报警信号 $s \in \{s_f, s_n\}$ ，实现在线的状态识别。

本节后续内容将具体描述上述方法的计算流程。

① 基于故障记录和先验知识的概率标签构建



② 基于后验概率的正-无标签学习



③ 在线状态识别




图 4.1 基于概率标签的正-无标签学习算法整体流程

4.2.2 基于运维记录和定性先验知识的概率标签构建

传统正-无标签学习框架依赖确定性的二值正例标签，难以建模标注中的不确定性。为此，本章提出一种基于不确定性量化的标注方案，为每个训练样本 $\mathbf{x}_i$ 赋予一个连续的概率标签 $\pi_i = P(y_i = 1 | \mathbf{x} = \mathbf{x}_i)$ ，用以量化其属于目标设备状态类别的可能性。该方案的核心在于从含噪声的运维记录和定性先验知识中推导相对可靠的 π_i 。以下阐述两种核心实现途径，分别针对两类典型的状态信息不确定性问

题：运维记录本身存在误差导致的随机不确定性，以及运维记录与隐含设备状态关联模式未知导致的认知不确定性。

4.2.2.1 运维记录本身存在误差导致的随机不确定性

此途径针对运维记录中存在的记录延迟等时间随机不确定性问题。定义 τ_i^* 为真实故障发生时间， τ_i 为记录时间，其偏差 $\Delta\tau_i = \tau_i - \tau_i^*$ 常呈现系统性模式，如维护周期、响应延迟导致的数天滞后。基于此假设，可在记录点 τ_i 之前定义一个高置信度窗口 ΔT ，并假设 τ_i^* 以较高概率落在此窗口内，示例如图 4.2 (a) 所示。据此，采用分段函数为不同时刻样本生成对比性概率标签：

$$\hat{y}_t = \begin{cases} p_1, & \forall i, \tau_i - \Delta T < t < \tau_i, \\ p_0, & \text{其他情况,} \end{cases} \quad (4.1)$$

其中 $p_1 > p_0$ ，反映窗口内样本的退化状态发生概率更高。窗口长度 ΔT 与概率值 p_1, p_0 可根据历史数据预先设定。

4.2.2.2 运维记录与隐含设备状态关联模式未知导致的认知不确定性

该途径用于处理隐含设备状态与运维记录的停机/检查/维护事件之间存在系统性偏差的场景。这类偏差的一个典型场景是周期性的人工设备检修发现的设备退化，此时希望被早期识别的退化开始时刻 S 处于检修时刻 F 之前。两者之间存在时间上的因果关联，但并非同时发生，这导致了运维记录 F 退化开始时刻 S 之间的系统偏差，而这一系统偏差通常无法获取，进而导致了设备状态信息的认知不确定性。

为建立 S 与 F 之间的定量关系，一种可行的方法是对历史数据集进行统计，计算条件概率 $P(S(t) | F(t + \Delta t))$ ，即在未来 $t + \Delta t$ 时刻 F 检出设备退化的条件下，当前 t 时刻为退化状态的概率。如图 4.2 (b) 所示，该条件概率曲线呈现出明确的规律：其在 $\Delta t = 0$ 时取得最大值，并随着时间偏移量 $|\Delta t|$ 的增大而单调递减。这一统计规律为从离散的运维记录 F 反推连续时间内退化状态 S 发生的概率估计提供了经验依据。

基于上述经验概率曲线 $P(\Delta t)$ ，本方法构建了一种分段恒定的概率标签近似方案。具体而言，将时间轴依据 Δt 划分为多个连续的区间。对于落在同一区间内的所有训练样本，为其分配一个相同的后验概率值 π_i ，该值取为此区间内经验概率曲线的一个代表值（例如，区间中点对应的概率值或区间内的平均概率）。图 4.2 (b) 中的蓝色虚线示意了这种分段近似。通过这种操作，连续的先验知识被转化为适用于模型训练的离散概率标签集。图 4.2 (c) 则从一个具体训练样本序列的视角，

展示了由此生成的时序概率标签。

与传统正-无标签学习方法中将故障点附近样本简单标记为正例（如图 4.2 (b) 中红色虚线所示）的确定性二值策略相比，本方法生成的概率标签包含了一个从高到低的可能性梯度。这种设计使得模型能够学习到异常状态并非在故障记录点突然出现，而是随着时间临近而概率递增的动态过程，从而更细致地反映已知的关于设备退化演化的假设。该概率标签框架具有扩展性，其所依赖的先验概率 $P(\Delta t)$ 不仅可来自历史数据统计，也可来源于定性知识给出的确定性规则。通过将各种形式的不确定性先验编码为统一的设备状态概率的不确定性量化标注，增强了这一数据驱动方法在状态信息不确定的生产环境下的适用性。




图 4.2 概率标签生成示意图

4.2.3 基于后验概率标签的风险估计器

为求解概率正-无标签学习问题，本节设计了一个新的风险估计器。该估计器在通过已知的正例比例间接估计负例风险的无偏正-无标签风险估计器基础上改进，将其扩展至概率标签场景，提出如下经验风险估计量：

$$\mathcal{R} = \underbrace{\max \left[0, \sum_{i=1}^m \lambda_i^+ \mathcal{R}_i^+ \right]}_{\text{正类经验风险}} + \underbrace{\max \left[0, \sum_{i=1}^m \lambda_i^- \mathcal{R}_i^- \right]}_{\text{负类经验风险}}. \quad (4.2)$$

其中， λ_i^+ 和 λ_i^- 为风险权重，它们在训练开始前基于已知的后验概率 π_i 计算确定。这些权重的确定需满足一系列约束，具体由方程 4.4、4.5 及 4.7 规定。

约束一：风险估计器 $\mathcal{R}$ 的优化方向必须与真实风险一致。为此，要求其梯度 $\partial \mathcal{R} / \partial \theta$ 与真实误分类风险 $\mathcal{R}_+^+ = \mathbb{E}_{X \sim p^+} [l(g(\theta, X), y^+)]$ 及 $\mathcal{R}_-^- = \mathbb{E}_{X \sim p^-} [l(g(\theta, X), y^-)]$ 的梯度符号相同。将估计风险对模型参数 θ 求导，可得：

$$\begin{aligned} \frac{\partial \mathcal{R}}{\partial \theta} &= \sum_{i=1}^m \lambda_i^+ \frac{\partial \mathcal{R}_i^+}{\partial \theta} + \sum_{i=1}^m \lambda_i^- \frac{\partial \mathcal{R}_i^-}{\partial \theta} \\ &= \sum_{i=1}^m \lambda_i^+ \left[\pi_i \frac{\partial \mathcal{R}_+^+}{\partial \theta} + (1 - \pi_i) \left(1 - \frac{\partial \mathcal{R}_+^+}{\partial \theta} \right) \right] \\ &\quad + \sum_{i=1}^m \lambda_i^- \left[\pi_i \left(1 - \frac{\partial \mathcal{R}_+^+}{\partial \theta} \right) + (1 - \pi_i) \frac{\partial \mathcal{R}_-^-}{\partial \theta} \right]. \end{aligned} \quad (4.3)$$

为使估计风险梯度与真实风险梯度方向一致，需施加以下约束：

$$\text{s. t.} \quad \sum_{i=1}^m \lambda_i^+ (1 - \pi_i) = 0, \quad \sum_{i=1}^m \lambda_i^- \pi_i = 0, \quad \sum_{i=1}^m \lambda_i^+ \pi_i > 0, \quad \sum_{i=1}^m \lambda_i^- (1 - \pi_i) > 0. \quad (4.4)$$

约束二：不准确的类别先验估计可能导致基于先验的 PU 学习方法在数据不平衡时失效，特别是当误差超过一定阈值时。实践中发现类别平衡的风险估计器对不平衡数据更具鲁棒性，因此，本节引入类别平衡约束 $\partial \mathcal{R} / \partial \mathcal{R}_+^+ = \partial \mathcal{R} / \partial \mathcal{R}_-^-$ 。结合公式 4.3 可得：

$$\begin{cases} \sum_{i=1}^m \lambda_i^+ \pi_i = \frac{1}{2}, \\ \sum_{i=1}^m \lambda_i^- (1 - \pi_i) = \frac{1}{2}. \end{cases} \quad (4.5)$$

约束三：来自不同子集的概率标签的可靠性可能存在显著差异，这会影响模

型训练的稳定性。通过估计风险的期望方差来评估这种稳定性：

$$\begin{aligned} \text{Var}(\hat{\mathcal{R}}) = & \sum_{i=1}^m \frac{(\lambda_i^+)^2}{|\mathcal{X}_i|} \sum_{X \in \mathcal{X}_i} \text{Var}[l(g(X), y^+)] \\ & + \sum_{i=1}^m \frac{(\lambda_i^-)^2}{|\mathcal{X}_i|} \sum_{X \in \mathcal{X}_i} \text{Var}[l(g(X), y^-)]. \end{aligned} \quad (4.6)$$

定义 $\sigma_i^2 = \sum_{X \in \mathcal{X}_i} (\text{Var}[l(g(X), y^+)] + \text{Var}[l(g(X), y^-)]) / |\mathcal{X}_i|$ 为训练集标签的可靠性度量。可靠性越低， σ_i^2 值越高。实践中，该参数可根据经验观察进行粗略估计。通过最小化以下目标函数，可以优化风险估计的稳定性：

$$\sum_{i=1}^m [(\lambda_i^+)^2 \sigma_i^2 + (\lambda_i^-)^2 \sigma_i^2]. \quad (4.7)$$

综合上述三个约束，所提基于概率标签的正-无标签学习（PPU）方法的离线训练流程归纳如下：

（1）数据预处理：对历史传感器测量值进行参数选择、归一化、时间窗分割及数据清洗，得到规范化训练集 $\mathcal{X}$ 。

（2）构建概率标签：融合运维记录与领域知识，将训练集 $\mathcal{X}$ 划分为若干个子集 $\mathcal{X}_i$ ，每个子集对应不同的后验概率 $\pi_i = P(y(X) = y^+ | X \in \mathcal{X}_i)$ 。

（3）估计可靠性度量：估计所获软概率标签的可靠性度量 σ_i^2 。较高的 σ_i^2 对应较低的可靠性。

（4）计算风险权重：通过求解以下优化问题确定风险权重 λ_i^+ 和 λ_i^- ：

$$\begin{aligned} \min_{\lambda^+, \lambda^-} & \sum_{i=1}^m [(\lambda_i^+)^2 + (\lambda_i^-)^2] \sigma_i^2 \\ \text{s.t.} & \sum_{i=1}^m \lambda_i^+ (1 - \pi_i) = 0, \quad \sum_{i=1}^m \lambda_i^- \pi_i = 0, \\ & \sum_{i=1}^m \lambda_i^+ \pi_i = \sum_{i=1}^m \lambda_i^- (1 - \pi_i) = \frac{1}{2}. \end{aligned} \quad (4.8)$$

（5）模型训练：利用已获得的权重 $\lambda_i^\pm$ 和概率标签 π_i ，通过梯度下降法迭代最小化以下经验风险，训练异常检测模型 $g(\theta, X)$ ：

$$\hat{\mathcal{R}} = \max \left[0, \sum_{i=1}^m \lambda_i^+ \frac{1}{|\mathcal{X}_i|} \sum_{X \in \mathcal{X}_i} l(g(\theta, X), y^+) \right] + \max \left[0, \sum_{i=1}^m \lambda_i^- \frac{1}{|\mathcal{X}_i|} \sum_{X \in \mathcal{X}_i} l(g(\theta, X), y^-) \right]. \quad (4.9)$$

（6）模型保存：当训练损失收敛或达到预设的迭代次数时，终止训练，保存最终的模型参数 θ^* 。

4.2.4 在线设备状态识别

在线设备状态识别阶段依据离线训练确定的参数与流程，对实时传感器数据进行处理并输出设备状态识别结果。该阶段流程如图 4.1 所示，具体执行步骤如下。

首先，对持续采集获得的近期传感器测量值进行预处理。此过程完全复现离线训练阶段的数据处理步骤：采用相同的滑动窗口长度与步长对数据进行分割，并利用离线阶段计算得到的均值与标准差进行标准化。处理完成后，形成一个与训练样本同构的多元时间序列样本 X_t ，作为分类模型的输入。

随后，将预处理样本 X_t 输入至已完成训练的分类模型 $g(\cdot)$ 中。模型加载离线阶段得到的最优参数 θ^* ，进行前向传播计算，输出一个目标设备状态似然分数 $\hat{y}_t$ ，即 $\hat{y}_t = g(\theta^*, X_t)$ ，其中 $\hat{y}_t \in [0, 1]$ 。该分数直接给出了当前时刻观测样本 X_t 被判定为目标设备状态的概率估计值。

最后，为抑制分数序列 $\{\hat{y}_t\}$ 中的瞬时噪声与偶发尖峰，降低误报率，需对原始分数进行后处理。标准后处理流程依次包含一个滑动最大滤波与一个滑动均值滤波。滑动最大滤波器首先提取局部窗口内的分数最大值，以凸显持续存在的异常信号；滑动均值滤波器随后对结果进行平滑。当经过两级滤波处理后的最终分数值超过预设的报警阈值 γ 时，系统触发报警信号 $s(t)$ ，标识设备进入退化状态。在线阶段与离线训练阶段在数据预处理、模型结构及核心参数上保持完全一致，从而确保了从模型开发到部署应用的一致性。

4.2.5 分类器模型选择

分类器模型 g 定义了从输入样本 X_t 到目标设备状态的似然分数 $\hat{y}_t$ 的映射关系，即 $\hat{y}_t = g(\theta^*, X_t)$ 。该模型以前述风险估计器提供的概率标签 π_i 作为训练目标，从数据中学习特征表示与决策边界，最终输出设备处于目标状态的可能性值。所提概率正-无标签学习框架不强限制定分类模型 g 的具体结构，具备模型灵活性。在实际应用中，可根据具体任务的数据规模、问题复杂度与可用计算资源，选择合适的分类器架构。

在下一节数值实验所采用的时间序列设备状态识别案例中，模型的输入为传感器信号构成的多元时间序列。此类数据具有强时序依赖性，其设备状态的模式通常隐含于状态参数的动态演化过程中。长短期记忆网络（Long Short-Term Memory, LSTM）通过其门控机制，能够有效捕捉时间序列中的长期依赖关系，因此本节选用 LSTM 作为的分类器模型。

4.3 理论证明

本节从理论上分析概率标签（即类概率估计）误差对风险估计器的影响，并通过数值实验进行验证。

4.3.1 风险估计器等价性证明

postPU 方法和 nnPU 方法的经验风险估计都是用类别绝对经验风险 $\mathcal{R}_i^-$ 的加权和来表示整体经验风险 $\mathcal{R}$ 估计：

$$\mathcal{R} = \sum_{i=1}^m \lambda_i^+ \mathcal{R}_i^+ + \sum_{i=1}^m \lambda_i^- \mathcal{R}_i^- \quad (4.10)$$

在理论分析中，需引入在真实正类与负类分布上的风险 $\mathcal{R}^+$ 和 $\mathcal{R}^-$ 。由于训练集不含显式负类标签，这两个值在实际计算中不可直接获得，但可用于理论推导。

绝对风险 $\mathcal{R}_i^+$ 与 $\mathcal{R}_i^-$ 可进一步表示为真实风险 $\mathcal{R}^+$ 和 $\mathcal{R}^-$ 的线性组合。因此，postPU 风险估计器 $\mathcal{R}_{postPU}$ 可表达为如下关于真实风险的线性形式

$$\mathcal{R}_{postPU} = \mathcal{R}_{postPU}^+ + \mathcal{R}_{postPU}^- \quad (4.11)$$

$$= k^+ \mathcal{R}_+^+ + k^- \mathcal{R}_-^- + C \quad (4.12)$$

最后定义有效类权重 $\bar{r} = k^+/(k^+ + k^-)$ 为真实正类风险在总风险中的比例。下述定理阐明了该权重如何主导最优分类器的决策边界：

定理 4.1： 令 g_1^* 与 g_2^* 为在同一数据分布 p 上分别最小化两个风险函数的分类器： $g_c^* = \arg \min_{g \in \mathcal{G}} \mathcal{R}_c(g, p)$, $\mathcal{R}_c(g, p) = k_1^+ \mathcal{R}_+^+(g, p) + k_1^- \mathcal{R}_-^-(g, p) + c_1 (k_1^+ > 0, k_1^- > 0), c \in \{1, 2\}$ 。若 $k_1^+/k_1^- = k_2^+/k_2^-$ ，则 $g_1^* = g_2^*$ 。

首先定义子集上的真实风险 $\mathcal{R}_i^+$ 和 $\mathcal{R}_i^-$ 表示训练集第 i 个子集上正样本和负样本的风险估计。在公式 (4.10) 中，绝对风险均可表示为多个子集的真实风险的线性组合：

$$\begin{aligned} \mathcal{R}_i^+ &= \pi_i \mathcal{R}_+^+ + (1 - \pi_i)(1 - \mathcal{R}_-^-), \\ \mathcal{R}_i^- &= \pi_i(1 - \mathcal{R}_+^+) + (1 - \pi_i)\mathcal{R}_-^-, \end{aligned} \quad (4.13)$$

其中 π_i 为第 i 个子集的真实类后验概率。联立式 (4.13) 与式 (4.10)，可将风险估计器表达为真实风险的线性组合：

$$\mathcal{R}_{postPU}^+ = \mathcal{R}_+^+ \sum_{i=1}^m \lambda_i^+ \pi_i - \mathcal{R}_-^- \sum_{i=1}^m \lambda_i^+(1 - \pi_i) + \sum_{i=1}^m \lambda_i^+(1 - \pi_i), \quad (4.14a)$$

$$\mathcal{R}_{postPU}^- = -\mathcal{R}_+^+ \sum_{i=1}^m \lambda_i^- \pi_i + \mathcal{R}_-^- \sum_{i=1}^m \lambda_i^-(1 - \pi_i) + \sum_{i=1}^m \lambda_i^- \pi_i, \quad (4.14b)$$

在风险函数 $\mathcal{R}_1$ 与 $\mathcal{R}_2$ 之间可建立线性变换 $f(\mathcal{R}_2) = \frac{k_2^+}{k_1^+}(\mathcal{R}_1 - c_1) + c_2$, 其中 $\frac{k_2^+}{k_1^+} = \frac{k_2^-}{k_1^-} > 0$ 。由 $\mathcal{R}_1(g_1^*, p) = \min(\mathcal{R}_1(g, p))$ 可得 $\mathcal{R}_2(g_1^*, p) = f[\mathcal{R}_1(g_1^*, p)] = \min_{g \in \mathcal{G}} f[\mathcal{R}_1(g_1^*, p)] = \min_{g \in \mathcal{G}} \mathcal{R}_2(g, p)$ 。同理可证 $\mathcal{R}_1(g_2^*, p) = \min \mathcal{R}_1(g, p)$ 。

根据定理 4.1 及关系式 $\frac{k^+}{k^-} = \frac{\bar{r}}{1-\bar{r}}$ 可知, 风险估计器 $\mathcal{R}$ 所诱导的最优分类器 g^* 由有效类别权重 $\bar{r}$ 唯一决定。因此, 具有相同 $\bar{r}$ 值的风险估计器在决策边界意义下是等价的。

4.3.2 概率标签误差下的鲁棒性分析

式 (4.11) 中的权重 λ_i^+, λ_i^- 由估计的类别概率标签 π_i 确定。假设估计的类后验概率存在误差, 即 $\hat{\pi}_i = \pi_i + \delta_i$, 其中 δ_i 为估计误差, 真实类概率为 π_i 。则真实的 $\bar{r}$ 值 $\hat{\bar{r}}$ 由下式给出:

$$\hat{\bar{r}}(\boldsymbol{\pi}) = \left(\sum_{i=1}^m \lambda_i^+ \pi_i - \sum_{i=1}^m \lambda_i^- \pi_i \right) / \left[\sum_{i=1}^m \lambda_i^+ \pi_i - \sum_{i=1}^m \lambda_i^- \pi_i - \sum_{i=1}^m \lambda_i^+ (1 - \pi_i) + \sum_{i=1}^m \lambda_i^- (1 - \pi_i) \right] \quad (4.15)$$

类概率估计误差对有效类权重的影响可由 $e(\hat{\boldsymbol{\pi}}, \boldsymbol{\pi}) = \hat{\bar{r}}(\boldsymbol{\pi}) - \hat{\bar{r}}(\hat{\boldsymbol{\pi}})$ 量化。有如下结论:

定理 4.2: 对于式 (4.15) 定义的真实有效类别权重 $\hat{\bar{r}}(\boldsymbol{\pi})$, $\forall \boldsymbol{\pi} \in D, \hat{\bar{r}}(\boldsymbol{\pi}) = \hat{\bar{r}}(\hat{\boldsymbol{\pi}})$ 成立的充要条件是 $\sum_{i=1}^m \lambda_i^+ - \lambda_i^- = 0$ 。

充分性证明可由式 (4.15) 定义出发, 计算 $\hat{\bar{r}}$ 的偏导数:

$$\frac{\partial \hat{\bar{r}}}{\partial \pi_j} = - \frac{(\lambda_j^+ - \lambda_j^-) \sum_{i=1}^m (\lambda_i^+ - \lambda_i^-)}{\left[\sum_{i=1}^m (2\pi_i - 1)(\lambda_i^+ - \lambda_i^-) \right]^2} \quad (4.16)$$

条件 $\forall \boldsymbol{\pi} \in D, \hat{\bar{r}}(\boldsymbol{\pi}) = \hat{\bar{r}}(\hat{\boldsymbol{\pi}})$ 表明, 函数 $\hat{\bar{r}}(\cdot)$ 在定义域 D 上为常值函数。因此, 其在 D 内任一点关于任一 π_j 的偏导数均为零。令式 (4.16) 对所有 j 成立, 即得 $\sum_{i=1}^m \lambda_i^+ - \lambda_i^- = 0$ 。

必要性证明中, 令向量 $\boldsymbol{v} = (\lambda_1^+ - \lambda_1^-, \lambda_2^+ - \lambda_2^-, \dots, \lambda_m^+ - \lambda_m^-)$, 则真实风险系数 k^+ 和 k^- 可表示为内积形式:

$$\begin{aligned} k^+(\boldsymbol{\pi}) &= \sum_{i=1}^m (\lambda_i^+ - \lambda_i^-) \pi_i = \langle \boldsymbol{v}, \boldsymbol{\pi} \rangle, \\ k^-(\boldsymbol{\pi}) &= \sum_{i=1}^m (\lambda_i^+ - \lambda_i^-) (\pi_i - 1) = \langle \boldsymbol{v}, \boldsymbol{\pi} \rangle - \langle \boldsymbol{v}, \mathbf{1} \rangle. \end{aligned} \quad (4.17)$$

条件 $\sum_{i=1}^m \lambda_i^+ - \lambda_i^- = 0$ 等价于 $\langle \boldsymbol{v}, \mathbf{1} \rangle = 0$, 此时有 $k^+ = k^-$ 。由于 $\boldsymbol{\pi} \in D$ 保证 $\langle \boldsymbol{\pi}, \mathbf{1} \rangle \neq 0$, 结合 $\forall \boldsymbol{\pi} \in D, k^+(\boldsymbol{\pi}) = k^-(\boldsymbol{\pi})$ 与 $\bar{\pi} = k^+/(k^+ + k^-)$, 可得 $\forall \boldsymbol{\pi} \in D, \hat{\bar{\pi}}(\boldsymbol{\pi}) = \frac{1}{2} = \hat{\bar{\pi}}(\hat{\boldsymbol{\pi}})$ 。

结合定理 4.1 与定理 4.2 可证得如下定理 4.3。

定理 4.3: 给定由式 (4.11) 定义的后验 PU 风险估计器 $\mathcal{R}_{postPU}(g, p, \lambda, \pi)$ 。设 $g^*(\mathbf{x})$ 为使用子集估计后验概率 $\hat{\pi}$ 时满足 $g^*(\mathbf{x}) = \arg \min_{g \in \mathcal{G}} \mathcal{R}_{postPU}(g, p, \lambda, \hat{\pi})$ 的最优分类器， $g_o^*(\mathbf{x})$ 为使用子集真实后验概率 π 时满足 $g_o^*(\mathbf{x}) = \arg \min_{g \in \mathcal{G}} \mathcal{R}_{postPU}(g, p, \lambda, \pi)$ 的理想最优分类器。若系数满足 $\sum_{i=1}^m \lambda_i^+ - \lambda_i^- = 0$ ，则 $\forall \pi \in D$ ，有 $g^* = g_o^*$ 。

定理 4.3 表明，满足类平衡加权条件的风险估计器能够抵抗类别概率标签估计不准确的影响。具体而言，该定理指出，使用包含显著估计误差的类别概率训练分类器的 postPU 风险估计器，与使用真实类概率的理想最优风险估计器具有等效的性能。通过调节 λ 的幅值，可将定理 4.3 转化为类别平衡约束（式4.5）。

4.3.3 数值案例

本节在一个构造的数值案例上，分析概率估计误差的影响。案例的真实类标签与理想决策边界如图 4.3(a) 所示。图4.3(b) 显示了训练时给定的训练标签，分为 $m = 2$ 个子集，其中红色为正样本集，全部为正样本 ($\pi_1 = 1$)；灰色样本为未标注样本集，其中有 π 比例为正样本，但输入算法的正样本比例 $\hat{\pi} = \pi + \delta$ 含有误差。




图 4.3 nnPU 与 postPU 关于类别概率估计误差鲁棒性的对比实验

表 4.1 列出了 nnPU 与 postPU 方法中对应的风险估计系数 λ_i^+ 与 λ_i^- 。相应的有效类别权重 $\bar{r}$ 见表最后一列。nnPU 的 $\bar{r}$ 是估计误差 δ 的函数，而 postPU 的 $\bar{r}$ 恒为 1/2。两者随 $\hat{\pi}$ 的变化趋势如图 4.3(c) 所示。图 4.3(d) 展示了两种方法在不同 $\hat{\pi}$ 值（0.1 至 0.9）下的 F1 分数。postPU（实线）的分类 F1 分数曲线较为平坦，表明其对类概率估计误差具有鲁棒性。

表 4.1 正-无标签风险估计器在概率标签估计误差下的鲁棒性比较

	π_i	$\hat{\pi}_i$	λ_i^+	λ_i^-	k^+	k^-	$\pi + \delta$	$\bar{r}$
nnPU(P)	π	$\pi + \delta$	0	1	$\pi + 2\delta$	$1 - \pi - \delta$	$(\pi/2, 1)$	$\frac{\pi + 2\delta}{1 + \delta}$
nnPU(U)	1	1	$\pi + \delta$	$1 - \pi - \delta$				
postPU(P)	π	$\pi + \delta$	0	$\frac{1}{2(1-\pi-\delta)}$	1/2	1/2	$(0, 1)$	1/2
postPU(U)	1	1	1/2	$\frac{\pi + \delta}{2(1-\pi-\delta)}$				

在先验 PU 学习（ $m = 2$ ）的设定下，若类先验估计值 $\hat{\pi}$ 小于真实值 π 的一半，根据表 4.1，nnPU 的风险系数 k^+ 将为负。此时，风险最小化过程将失效，分类器会退化为恒预测正类的平凡解。选择满足式 (4.5) 的样本权重可同时解决此问题。该现象在图 4.3(d) 中被验证：当 nnPU 训练的 $\hat{\pi} < 0.5\pi$ 时（红色虚线），正类的 F1 分数为零。

以上理论推导和数值案例验证了传统无偏估计正-无标签学习方法（nnPU）在概率标签存在误差时，会导致经验风险估计出现偏差，进而影响模型性能；而本章所提 postPU 方法具有对抗概率标签误差更强的鲁棒性。

4.4 实验验证与分析

本节通过公开数据集上的数值实验，验证所提基于后验概率的正-无标签学习方法在训练数据含高度状态不确定性的条件下的识别性能，并与现有方法进行定量对比。4.4.1 节在模式识别基准数据集上评估所提状态识别方法的核心环节的 postPU 算法本身作为一种正-无标签学习方法的分类能力；4.4.2 节则进一步评估本章所提状态识别算法在设备状态信息存在随机不确定性条件下的识别能力；4.4.3 节评估算法在设备状态信息认知不确定性下的状态识别能力。

4.4.1 基准数据集上的算法分类能力评估

本节在两个模式识别基准数据集上评估所提状态识别方法的核心环节的 postPU 算法的分类能力，为后续验证本章所提方法退化状态识别能力提供基础。

4.4.1.1 数据集与问题设置

本节在 CIFAR-10^[123] 与 Fashion-MNIST (F-MNIST)^[124] 两个模式识别基准数据集上, 对所提基于后验概率的正-无标签学习 (posterior-based Positive-Unlabeled learning, postPU) 算法的分类性能进行评估, 具体评估该方法在标准正-无标签学习问题中的基本有效性, 并检验其在使用含噪声概率标签时的泛化能力。CIFAR-10 与 F-MNIST 是两个广泛用于模式识别任务评估的基准数据集, 原始数据包含 10 个类别 (0 至 9)。为构造正-无标签学习任务, 将类别 0 至 6 重新定义为正例, 类别 7 至 9 重新定义为负例。随后构建两个互斥的训练集: 一个标注准确但规模较小的正样本训练集 $\mathcal{X}_p$, 以及一个规模较大的无标注训练集 $\mathcal{X}_U$, 其中无标注训练集的正样本先验比例 π_p 设定为 40%。正样本训练集通过完全随机抽取 (Select Completely At Random, SCAR) 获得。测试集独立于训练集生成, 其正样本比例同样为 40%。各数据集的具体样本数量统计如表 4.2 所示。

表 4.2 基准数据集样本数量统计

数据集	无标签训练集		正样本训练集	测试集	
	样本数	正例比例 (%)	样本数	样本数	正例比例 (%)
CIFAR-10	25000	40	204	5000	40
F-MNIST	30000	40	631	5000	40

为模拟实际应用中存在的含不确定性的先验知识, 在无标签集 $\mathcal{X}_U$ 引入一个额外的先验证据 V , 该证据可视为一种补充性的含严重噪声的训练标签。满足证据 V 的样本, 其属于正例的后验概率为 $P(y = y^+ | V \wedge \mathbf{x} \in \mathcal{X}_U) = \pi_1 = 50\%$, 此值高于无标签集的整体正例先验 $\pi_p = 40\%$ 。定义 $r = P(V | y = y^+ \wedge \mathbf{x} \in \mathcal{X}_U)$ 为无标签集中能够被证据 V 识别出的真实正例比例, 则仍有比例为 $1 - r$ 的真实正例未被 V 标注。

基于此证据, 无标签集 $\mathcal{X}_U$ 被划分为两个子集: 满足证据的子集 $\{\mathbf{x} | V \wedge \mathbf{x} \in \mathcal{X}_U\}$ 与不满足证据的子集 $\{\mathbf{x} | \neg V \wedge \mathbf{x} \in \mathcal{X}_U\}$ 。该设置使得可以利用后验概率对 $\mathcal{X}_U$ 进行比单一先验概率更精细的表征。

实验选取了 5 种前沿的正-无标签学习方法作为对比基线。其中, nnPU^[99] 与 ImbPU^[119] 属于原生经验风险最小化 (Empirical Risk Minimization, ERM) 方法。这类方法, 包括监督学习基线及所提 postPU 方法, 均通过梯度下降直接优化一个构建的风险估计函数。nnPU 采用非负风险估计器作为损失函数, 是广泛使用的基准方法。ImbPU 在 nnPU 的损失函数中引入了类别平衡系数以处理类别不平衡。其余三种对比方法 (LaGAM^[125]、robustPU^[118]、DistPU^[117]) 则采用了元学习或自

学习机制。实验均使用各对比方法作者提供的开源代码实现。为确保比较的公平性，所有方法采用相同的分类器 $\mathcal{G}$ 架构。该分类器由 2 个卷积层和 2 个全连接层构成，使用 ReLU 激活函数。统一的训练超参数包括：学习率为 1×10^{-4} ，批次大小为 2048，最大训练轮数为 100。每个实验配置均独立重复运行 10 次，最终结果统计其均值与标准差，以确保统计可靠性。

4.4.1.2 正-无标签学习条件下的识别性能验证

本实验将 postPU 与现有方法在标准正-无标签学习任务下进行定量对比，主要评价指标为分类 F1 分数，结果汇总于表 4.3。

表 4.3 基准数据集上正-无标签学习条件下对比实验 F1 分数结果

数据集	原生经验风险最小化方法			基于元学习的方法		
	postPU	ImbPU	nnPU	LaGAM	robustPU	DistPU
CIFAR-10	64.4 $\pm$ 0.5	55.2 $\pm$ 1.9	34.5 $\pm$ 7.5	57.0 $\pm$ 2.3	55.4 $\pm$ 0.2	49.1 $\pm$ 2.6
F-MNIST	94.7 $\pm$ 0.1	94.4 $\pm$ 0.1	93.5 $\pm$ 0.1	79.7 $\pm$ 6.5	88.7 $\pm$ 0.1	91.7 $\pm$ 0.3

在两个模式识别基准数据集上的各项分类性能指标的详细数据见表 4.4。

表 4.4 基准数据集上正-无标签学习条件下的识别性能详细指标

数据集	指标 (%)	postPU	ImbPU	nnPU	LaGAM	robustPU	DistPU
CIFAR-10	F1	64.4 $\pm$ 0.5	55.2 $\pm$ 1.9	34.5 $\pm$ 7.5	57.0 $\pm$ 2.3	55.4 $\pm$ 0.2	49.1 $\pm$ 2.6
	准确率	67.0 $\pm$ 0.4	66.1 $\pm$ 0.5	66.0 $\pm$ 1.2	65.3 $\pm$ 1.5	71.5 $\pm$ 0.0	64.5 $\pm$ 0.4
	精确率	56.7 $\pm$ 0.7	58.6 $\pm$ 1.2	75.7 $\pm$ 4.0	56.5 $\pm$ 1.9	73.9 $\pm$ 0.2	57.5 $\pm$ 0.4
	召回率	74.7 $\pm$ 2.4	52.5 $\pm$ 4.4	22.9 $\pm$ 6.4	57.7 $\pm$ 4.1	44.3 $\pm$ 0.3	42.9 $\pm$ 4.2
F-MNIST	F1	94.7 $\pm$ 0.1	94.4 $\pm$ 0.1	93.5 $\pm$ 0.1	79.7 $\pm$ 6.5	88.7 $\pm$ 0.1	91.7 $\pm$ 0.3
	准确率	95.8 $\pm$ 0.1	95.6 $\pm$ 0.0	95.0 $\pm$ 0.1	84.9 $\pm$ 5.1	91.4 $\pm$ 0.0	93.2 $\pm$ 0.3
	精确率	95.1 $\pm$ 0.5	96.1 $\pm$ 0.2	96.3 $\pm$ 0.5	86.9 $\pm$ 9.2	94.1 $\pm$ 0.2	89.1 $\pm$ 0.9
	召回率	94.3 $\pm$ 0.4	92.8 $\pm$ 0.2	90.9 $\pm$ 0.6	74.0 $\pm$ 6.5	83.8 $\pm$ 0.3	94.4 $\pm$ 0.4

基准数据集上的实验结果表明，在 CIFAR-10 和 F-MNIST 的模式识别基准数据集上，postPU 的 F1 分数均高于其他对比方法。与同为原生 ERM 方法的 nnPU 和 ImbPU 相比，postPU 的性能提升更为显著。同时，postPU 也优于采用了元学习等复杂增强技术的 LaGAM、robustPU 和 DistPU 方法。这一结果说明，postPU 能够有效利用由证据 $\mathcal{V}$ 所提供的辅助信息来提升分类性能。值得注意的是，证据 $\mathcal{V}$

本身提供的区分度有限，其对应的后验概率 $\pi_1 = 50\%$ 仅略高于随机猜测水平（先验 $\pi_p = 40\%$ ）。表 4.4 中的详细指标显示，postPU 在保持较高召回率的同时，获得了相对均衡的精确率，表明其能够较好地平衡误报与漏报。

4.4.1.3 概率标签误差鲁棒性验证

定理 4.3 从理论上保证了 postPU 对类别后验概率估计误差具有鲁棒性。为对此结论进行数值实验检验，本节评估当后验概率 π_i 仅为粗略估计时 postPU 的分类性能。假设根据某种带有不确定性的证据可将训练样本划分为较高概率负例、模糊样本和较高概率正例三个子集，其真实的正例后验概率满足 $\pi_1 < \pi_2 < \pi_3$ 。实验采用多组粗略猜测的后验概率估计值 $(\hat{\pi}_1, \hat{\pi}_2, \hat{\pi}_3)$ 来替代真实值，训练 postPU 模型并评估其 F1 分数，结果如表 4.5 所示。


表 4.5 使用粗略猜测后验概率时 postPU 的 F1 分数性能指标

$(\hat{\pi}_1, \hat{\pi}_2, \hat{\pi}_3)$	(.3, .6, .9)	(.25, .5, .75)	(0, .5, 1)	(0, .25, .5)	(.5, .75, 1)	(.33, .5, 1)
CIFAR-10	64.6 $\pm$ 0.5	64.7 $\pm$ 0.4	64.6 $\pm$ 0.5	64.7 $\pm$ 0.3	64.4 $\pm$ 0.5	64.4 $\pm$ 0.5
F-MNIST	95.1 $\pm$ 0.4	95.0 $\pm$ 0.7	94.9 $\pm$ 0.3	95.3 $\pm$ 0.3	95.0 $\pm$ 0.4	95.7 $\pm$ 0.1

由表 4.5 展示的结果可见，在不同组合的猜测后验概率下，postPU 在两个数据集上的分类性能均保持稳定，波动范围很小。这一结果验证了定理 4.3 的结论，即 postPU 的性能并不依赖于后验概率估计值的绝对精度，而是能够有效地利用其相对大小关系（即 $\pi_1 < \pi_2 < \pi_3$ 所蕴含的排序信息）。各子集后验概率估计值之间的差异大小，反映了模糊标签信息的质量，差异越明显，所提供的信息价值通常越高。

此外，本节通过补充实验分析了关键参数对 postPU 性能的影响。图 4.4 展示了标签比例 r 的变化对 F1 分数的影响。当 r 从 0.01 逐渐增大至 0.9 时，postPU 的性能呈现平缓的上升趋势。

综合以上实验结果，在模式识别基准数据集上，所提 postPU 算法在标准正-无标签学习任务中表现出了优于对比方法的模式识别分类能力。同时，实验证实了该方法对概率标签的估计误差具有鲁棒性，能够在不依赖精确后验概率的情况下，有效利用含有高度不确定性的排序信息提升识别效果，从而为本章的基于概率正-无标签学习的联合循环设备退化状态识别方法能够利用含不确定性的状态信息提供了基础。

图 4.4 postPU 参数 r 的敏感性分析

4.4.2 设备状态信息随机不确定性下的状态识别能力评估

在验证核心分类算法的模式识别能力之后，进一步在与联合循环运行数据模式相近的传感器时间序列公开数据集上验证本章所提状态识别方法在状态信息不确定性条件下的识别能力，并与现有的正-无标签学习方法和其它具有利用不确定性标注能力的半监督方法进行定量对比。数值实验通过不向算法输入准确的设备状态标注，而输入由运维记录间接推断的设备状态信息，以模拟实际工程中因人工复核成本高昂而难以获取准确状态标注的情况。具体开展两组实验，分别模拟了运维记录含随机不确定性和运维记录与目标设备状态之间的关系存在认知不确定性的场景。

4.4.2.1 状态信息随机不确定性的模拟

在联合循环设备状态的获取依赖传感器测量数据和运维记录，其中运维记录是从大量测量数据发现设备退化和设备故障等异常状态的重要线索，运维记录中的重要结论也是判断设备状态的关键依据。但是设备的在线状态识别方法有一定的时效性要求，需要通过分钟级或秒级的测量数据识别当前的设备状态，以服务于依赖设备状态识别结果的运行优化等功能模块，此时运维记录提供的设备状态的标注信息无法达到与之相匹配的时效性要求。如压气机进气预过滤器能够支持设备运行状态下的在线更换，更换周期为 2 至 6 个月，更换后会立即改变燃气轮机的设备性能，但是其更换记录由人工记录而非系统判断，仅精确到月。在利用该更换记录作为设备状态标注信息时，由于更换记录的时效性不足，无法准确反映当前设备状态，造成了设备状态信息的随机不确定性。人工运维记录的错误、延迟响应等其它因素也会是产生状态信息随机不确定性的来源。为了满足数据驱动的状态识别方法对历史数据准确设备状态的标注，往往需要结合具体测量数据（如滤网差压、压气机压比等）人工校核才能够确定精确的维护时间，既需要校核人员了

解具体设备特性相关的专业知识，还需要对大量历史数据逐段进行人工校核，导致数据标注成本高昂，严重制约了数据驱动方法在实际生产环境中的应用。因此研究不依赖人工校核标注历史数据的数据驱动方法对工程应用具有重要价值，这一研究方向下现有研究发展出了对标注数据量依赖较小的半监督学习方法以及进一步对标注丰富程度依赖较低的正-无标签学习方法，可以大幅降低人工标注的数据量，使数据驱动方法向工程应用进一步迈进。但是现有方法对标注的精度和确定性要求较高，在上述存在状态信息不确定性的生产环境下通常难以达到。本章所提基于概率正-无标签学习的状态识别方法能够利用含不确定性的运维记录作为历史数据设备状态标注，从而可以几乎完全避免人工校核历史数据，直接利用精度不足的运维记录，降低人工校核成本。本节首先针对运维记录含随机不确定性的问题，验证所提方法在该条件下的状态识别能力，并与现有的半监督学习方法和正-无标签学习方法进行对比。具体使用含系统告警记录的传感器时间序列公开数据集 C ，通过人为注入随机噪声获得含延迟误差的训练标注，模拟设备状态信息的随机不确定性。

数据集 C 为含传感器时间序列与系统内超限告警记录的公开数据集^[126]。具体包含两部分：第一部分是从 2014 年 1 月至 2016 年 12 月，为期两年的发电运行数据，数据来自于传感器时间序列，共包含 49027 个带时间戳的数据点；第二部分为记录了设备状态转换（如紧急停机）和特定部件早期警告的事件日志，其中包含 213 个设备异常状态事件。

实验以电气部件励磁错误引发的停机记录作为算法识别目标的设备异常状态，通过人为注入随机噪声获得含延迟误差的训练标注。令 τ_i 表示第 i 个目标状态的真实发生时间， d_i 为服从均匀分布 $\mathcal{U}(0, D)$ 的随机延迟量，则获得的带噪声时间戳为 $\hat{\tau}_i = \tau_i + d_i$ ；为模拟实际工程中人工复核成本高昂的约束，仅有一小部分事件的真实时间 τ_i 可用于参考。对于大多数异常事件，模型训练只能获取带噪声的时间戳 $\hat{\tau}_i$ 及其可能的最大延迟范围 D ，迫使待监测的算法依赖不确定的设备状态标注 $\hat{\tau}_i$ 。时间逻辑关系满足 $\tau_i \in (\hat{\tau}_i - D, \hat{\tau}_i)$ ，表明实际故障发生于带噪声标注之前的一个时间窗内。因此，位于区间 $(\hat{\tau}_i - D, \hat{\tau}_i)$ 内的训练样本被标记为概率异常样本；那些经过人工核验的样本则被标记为确定性目标状态样本；其余数据视为正常样本。

数据预处理流程包括：首先移除设备处于非运行状态期间的数据；随后，对所有特征进行归一化处理；最后，将连续时间序列数据分割为长度一小时的片段。为缓解因标注样本稀缺导致的类别不平衡问题，采用合成少数类过采样技术对训练集中的少数类样本进行扩充。为控制模型结构带来的变量影响，所有对比实验均使用相同的分类器架构 $\mathcal{G}$ 进行训练。将正常运行状态定义为正例，异常状态定

义为负例。类别先验概率则根据每个数据集中实际标签分布进行配置。为避免训练集和测试集之间的信息泄露，将数据集按时间顺序划分：2014年1月5日至10月20日的用于训练，2014年10月20日至12月31日的用于测试。

对于对照组的有监督算法，所有概率异常样本被直接视为确定性异常样本进行训练。对于需要预设正例比例的无偏正-无标签学习方法，其先验概率 π_l 基于时间窗 D 进行估算，计算公式为 $\pi_l = P(t \notin (\tau_i - D_w, \tau_i + D_w) \mid t \in (\hat{\tau}_i - D, \hat{\tau}_i)) = (D - D_w)^2 / D^2$ ，其中 $D_w = 180$ 分钟，定义为有效的异常标注窗口长度。传统无偏正-无标签学习方法受限于使用一个同质的无标注集，因此需要将确定性异常样本与概率异常样本合并，并赋予一个统一的先验概率。所提的基于后验概率的正-无标签学习方法支持为不同可靠性的样本分配不同的概率标签。在此实验中，正常样本、确定性异常样本和概率异常样本分别被赋予概率标签 0、1 和 π_l 。为了在训练中反映标注可靠性的差异，概率异常样本的可靠性度量 σ^2 被设置为正常或确定性异常样本的 20 倍。

4.4.2.2 对比方法

将所提的概率标签学习方法将与一系列现有的能够利用不确定性标注能力的半监督方法和正-无标签学习方法进行全面对比。对比方法可分为以下三类：

处理不确定性标注的正-无标签学习方法：此类方法能够利用与标签不确定性样本相关的先验知识或后验概率。此类方法包括所提方法及已有的正-无标签学习方法。可进一步细分为：第一类无偏估计正-无标签学习算法，基于先验概率直接估计误分类风险，如非负估计正-无标签学习算法（nnPU）^[99]，以及在其基础上改进的不平衡估计正-无标签学习算法（ImbPU）^[119]；第二类元学习增强的正-无标签学习方法，例如采用对比学习进行标签消歧的 LaGAM^[125]、通过匹配预测分布与先验统计量以对齐标签分布的 DistPU^[117]，以及利用自监督学习动态筛选可靠负样本的 robustPU^[118]。不处理不确定性标注的方法：此类为不纳入概率标签的半监督方法，以生成式方法 NNG-Mix^[92] 为代表，该方法仅从少量已确认的正例中合成异常样本。对照组基线方法：作为对照组的有监督方法将所有概率异常样本视为确定性异常样本用于训练，在记录的故障事件时间戳前后标记一个固定的宽时间窗口，并将其内所有样本均标注为异常。在标注误差较大的实验设置下，此策略预期将导致较高的误报率。

4.4.2.3 结果与分析

概率标签 π 的构造方式如图 4.5 上半部分所示，蓝色阴影区域对应于根据带噪声时间戳 $\hat{\tau}_i$ 和最大延迟 D 推导出的可能异常区间 $(\hat{\tau}_i - D, \hat{\tau}_i)$ ，该区间内的样本

被赋予概率标签 π_l 。图 4.5 最底部的红色区域展示了监督学习基线模型的检测结果，该模型将概率异常样本直接作为确定异常训练，导致了较高的误报警率。





图 4.5 训练标注构造示意图及监督基线模型检测结果

模型性能对标签噪声的鲁棒性如图 4.6 所示。随着最大延迟 D 的增加，监督学习基线的 F1 分数呈现单调下降趋势，这证实了训练标签中的噪声对监督模型性能具有显著的负面影响。当延迟范围 D 扩大至 1-6 天时，其 F1 分数下降至无延迟理想情况下的 30% 以下。作为对照，NNG-Mix 方法不利用不确定的标签信息，仅使用少量手动确认的确定性异常样本，因此其性能不受注入的标签噪声影响，但也因此未能充分利用所有可用的监督信号，其整体性能低于能够处理标签不确定性的方法。

与基线相比，各类正-无标签学习方法通过在经验风险最小化框架中显式地建模了标注不确定性，有效抑制了错误报警。在对比的多种 PU 学习方法中，所提方法取得了最优的综合性能。nnPU、ImbPU 等传统方法及 DistPU、robustPU 等元学习方法，均受限于其正样本集与无标注集的二分假设，无法对具有不同置信度的样本进行差异化建模。所提方法通过引入灵活的概率标签，为正常、确定性异常及概率异常样本分配了不同的概率标签作为监督信息，实现了更精细的损失加权，

图 4.6 不同最大延迟 D 下各方法的 F1 分数对比

最终有效降低了误报。图 4.6 的定量结果表明，所提方法在面对不同程度的标注延迟时，均保持了较高的 F1 分数，表现出对抗训练标注延迟误差良好的鲁棒性。

图 4.7 展示了在极端标注延迟条件下（最大延迟 $D = 1.5$ 天）各模型在测试集上的预测结果。图中最上方的绿色谱线表示真实的异常时段。监督基线模型（底部谱线）产生了大量与真实异常不匹配的检测报警（深红色区域），误报率极高。现有的正-无标签学习方法（中间谱线）虽然抑制了部分误报，但其检测结果中仍存在较明显的噪声。相比之下，本章所提方法（第二行谱线）的检测报警与真实异常时段吻合度最高，显著降低了误报和漏报。该可视化结果进一步实证了所提方法在严重标注误差条件下的高鲁棒性优势。

此外，观察图 4.7 中本章所提 PPU 方法的检测结果可见，其报警信号集中且清晰，与正常背景区分明显。这一特性表明，所提方法不仅能够进行异常状态识别，其输出还可用于对注入噪声前的、真实的异常发生时间进行估计，实现了在一定程度上恢复被噪声掩盖的原始标注信息。从而验证了所提状态识别算法，能够利用含随机不确定性的运行记录作为设备状态的间接标注，并建立状态识别模型实现在线状态识别，这一能力有利于该方法应用于信息不完备条件下的联合循环运行数据状态识别问题中。




图 4.7 极端标注延迟条件下各模型识别结果对比

4.4.3 设备状态信息认知不确定性下的状态识别能力评估

上一节的实验通过对运行记录人为注入随机噪声模拟设备状态信息随机不确定性的情况，验证了所提方法在处理标注噪声方面的鲁棒性。在利用联合循环机组运维记录推断设备状态时还存在认知不确定性的情况，也就是运维记录与目标设备状态之间的关联关系为间接且无法准确获取的隐含关系情况。这在设备性能退化状态评估的问题中较为常见，设备的退化是长期且逐渐缓慢变化的过程，而其退化速率、退化趋势通常是未知的，无法通过某一时刻的设备退化状态准确推断出此前或此后的设备退化状态。其原因在于，一方面退化的影响因素复杂，工况和环境因素都可能会影响退化速率，如空气质量影响压气机进气滤网的退化速率，同样型号设备收到安装和运行方式的差异影响也会影响其退化速率，因此难以通过退化机理准确地给出退化趋势；另一方面，退化机理和退化模型本身也是难以获取的，退化模型的研究需要长时间的数据积累有较高的成本，并且对于将设备维护作为重要收益来源的设备厂商而言，其退化模型是受到保护的商业机密，特别是非国产的燃气轮机。上述因素导致设备的退化状态往往是难以准确判定的隐含状态，即便通过离线的检查如润滑油成分分析等能够得到某一时刻的与设备退化状态有关的准确定量结果，但由于其与实际运行状态之间的关联关系复杂，因此难以推断出此前或此后的设备退化状态，无法直接用于历史运行数据的退化状态准确标注以支撑传统的数据驱动方法。同样的，对设备历史数据对应的退化状态进行准确校核也更加依赖校核人员对具体设备特性和退化特性的了解，需要更

高的人工成本。进而，不依赖人工校核退化状态的数据驱动方法对生产环境的应用有更大的工程实用价值，但也面对更大的状态信息认知不确定性。此外上一节所描述的人工检查和维修操作固有的周期性和滞后性也同时存在，因此直接使用未被校核的运维记录所导致的设备状态信息的随机不确定性也会叠加存在，与认知不确定性同时干扰数据驱动方法对数据的利用。

4.4.3.1 状态信息认知不确定性的模拟

本节的实验以数据集 C 为基础模拟状态信息存在认知不确定性的场景。本节实验采用可能造成冷却故障的冷却部件退化的作为目标异常状态，但状态识别算法的训练过程不直接使用该退化的发生时间标注。取而代之的是，将系统因过热而触发停机的运行记录作为构造训练标注的依据。此设定模拟了生产环境中一种常见的情况：仅能获取设备最终失效的停机记录，而无法直接获得预示性早期退化的准确标注。如图 4.8 前两行的谱线所示，停机事件与目标异常在时间上存在一定的相关性，但并非所有早期退化都会最终发展为停机。图 4.2 (b) 中对条件概率 $P(\Delta t) = P[S(t) | F(t + \Delta t)]$ 的统计分析显示了一个单峰分布，即在停机时刻附近，早期退化出现的概率最高，这与设备退化演化的经验认知相符。在本实验中，所有对比方法均在没有真实异常标注直接监督的情况下进行训练，它们仅能利用由停机记录和上述相关性先验 $P(\Delta t)$ 所构造的、含有较大误差的概率化训练标注。

图 4.2 (b) 对比了三种标注方式的等价概率标注形式。作为对照组的有监督学习等价于为正样本分配 $p = 100\%$ 的概率标注，将无标签样本视为负样本并分配 $p = 0\%$ 的概率标签，即图 4.2 中的绿色阶跃虚线所示。可见，这种确定性的二分标签与真实的条件概率分布 $P(\Delta t)$ （黄色曲线）存在显著偏差。现有无偏估计正-无标签学习框架通过引入一个恒定的先验概率 π ，其等价概率标签为一个二段分段函数（图 (b) 红色阶跃虚线），它在无标签集中考虑了假阴性的存在，因而对 $P(\Delta t)$ 的逼近优于监督基线，但其正样本侧仍为 100% 的确定性标签，且分段数固定为二，逼近能力仍受限。

本章所提方法的概率标签则不受上述限制。该方法既不要求正样本标签为 100% 确定，也不限定只能将数据划分为两个子集，从而能够更好地逼近目标频率分布。因此，该方法能够使用更灵活的分段函数来逼近先验分布 $P(\Delta t)$ 。考虑到实际工程中难以获得精确的连续概率曲线，本节实验采用一个简单的三段分段函数（图 (b) 蓝色阶跃虚线）作为概率标签的生成依据。该设定在不需要过于精细的先验知识的前提下，提供了比传统方法更好的逼近效果。当能够获取更准确的先验分布时，所提方法可直接支持使用更复杂的分段或函数形式进行逼近。

4.4.3.2 结果与分析

训练后各模型的状态识别输出以时间谱线形式展示于图 4.8。图中最上方绿色谱线表示真实的早期退化时段。监督基线模型（最下方谱线）的识别结果更倾向于识别停机事件本身或其临近模式，而非目标的早期退化模式，这表明其未能有效学习到真正的异常特征。传统 PU 方法（中间若干谱线）的识别结果有所改善，但仍包含较多散乱报警。




图 4.8 真实设备状态与模型识别结果对比

本章所提方法的识别结果如图 4.8 中第四行谱线所示。可以看出，其报警时段与真实的早期退化时段（绿色区域）具有较高的重合度，成功识别到了目标异常模式，而非简单的停机事件模式。这一结果实证了所提方法能够在没有任何直接异常标注的情况下，仅依据退化-停机相关性的先验知识构建概率化训练标注，并据此训练出有效的早期退化识别模型。

表 4.6 具体列出了本实验的定量性能指标，包括准确率、精确率、召回率和 F1 分数等多个指标。所提方法的综合指标优于其他对比的正-无标签学习方法。这一优势源于其灵活的基于后验概率的学习框架，该框架能够更准确地逼近真实的异常后验概率分布 $P(\Delta t)$ ，从而实现了先验知识与含噪声的标注信息的更有效的融

合。上述结果验证了所提状态识别算法能够利用含认知不确定性的运维记录作为设备早期退化状态的间接标注，并建立退化状态识别模型实现在线状态识别，这一能力有利于该方法应用于信息不完备条件下的联合循环运行数据退化状态识别问题中。

表 4.6 无直接状态标注条件下各对比算法状态识别性能定量指标

方法	准确率 (%)	精确率 (%)	召回率 (%)	F1 分数 (%)
本章算法	77.1 ± 1.2	50.9 ± 1.7	76.9 ± 1.9	61.2 ± 1.1
LaGAM	67.6 ± 6.8	40.1 ± 6.1	68.5 ± 4.6	50.2 ± 4.5
robustPU	54.4 ± 22.6	25.6 ± 15.1	51.4 ± 39.4	32.5 ± 14.2
DistPU	29.1 ± 5.8	24.7 ± 1.3	97.8 ± 2.6	39.4 ± 1.5
ImbPU	70.0 ± 2.5	42.4 ± 2.4	76.8 ± 1.0	54.6 ± 1.9
nnPU	26.7 ± 3.0	24.3 ± 0.8	99.9 ± 0.2	39.0 ± 1.0
对照组	58.5 ± 2.5	34.4 ± 1.4	84.5 ± 1.7	48.9 ± 1.3

4.5 联合循环设备性能退化状态识别应用案例

在上一节中通过公开的传感器时间序列数据集，检验了本章所提的基于概率正-无标签学习的状态识别算法的性能和鲁棒性，验证了算法能够利用含不确定性的状态标注训练状态识别模型。本节利用所提算法的能力，在联合循环设备的退化状态识别问题中应用，利用运维记录和定性假设构建含不确定性的设备状态标注，并实现压气机进气滤网和高压缸的退化状态识别。

首先通过本章所提方法基于历史数据、运维记录和定性假设构建状态识别模型，并识别设备的历史退化状态；再在识别结果的基础上，结合设备的部分负荷特性，对退化状态进行评估，并对退化趋势和退化原因进行分析；最后用结合了部分负荷特性对设备退化状态的人工判断，与模型的识别结果对比来验证模型的识别效果。

4.5.1 压气机进气滤网性能退化状态识别

本节所用案例与3.5.1节所用案例相同，包含压气机滤网约1年的历史数据作为状态识别训练数据。人工判定退化状态所用的依据与3.5.1.3节基于整体滤网差压 Δp_2 与压比 π_c 的历史数据分布构建的判定标准相同。

4.5.1.1 基于运维记录的压气机进气滤网退化状态不确定性标注

在3.5.1节中仅利用了2025年1月预过滤器更换后设备退化状态为健康的假设构建了历史数据标注,进一步可以合理假设预过滤器更换前其退化状态有较高可能性为已退化,3.5.1.3节中的性能退化评估的历史数据分析也验证了这一假设的合理性。本章所提基于概率正-无标签学习的状态识别算法适用不确定性标注的能力使得这一假设能够进一步被利用。从而在实际训练中,模型可以不依赖于精确的设备状态标注,而是采用一种结合进气滤网设备更换记录与定性退化知识的模糊标注方法。

具体的滤网设备更换记录如表4.7所示。基于“滤网性能随运行时间累积而逐渐退化,且在不进行更换或清洗的情况下无法自行恢复”这一退化规律,可做出以下假设:滤网更换后的一段时间内,设备大概率处于非异常状态;而更换前的一段时间内,设备则大概率处于异常状态;其余时间段的设备状态则视为未知。

表4.7 燃气轮机进气滤网设备维护记录

时间	维护内容
2025-01-05	更换预过滤器 G3 滤棉
2025-04-20	更换预过滤器 G3 滤棉
2025-05-30	更换预过滤器 G3 滤棉
2025-09-30	更换预过滤器 G3 滤棉
2025-12-15	更换预过滤器 G3 滤棉

根据此假设,具体的定性标注规则如表4.8所示。规则中设定了一个25天的时间窗口。概率标签 π_i 是对该类别样本为退化状态的后验概率的一种定性估计:类别1的0.1%表示几乎确定的健康状态;类别3的90%表示高度怀疑的退化状态;类别2的20%则表示在无先验信息时,赋予一个较低但非零的退化状态概率。

表4.8 基于更换时间的进气滤网退化状态定性标注规则

类别 i	设备状态描述	标注规则	概率标签 π_i
1	高概率为健康状态	滤网更换后 25 天内	0.1%
2	健康状态未知	除类别 1 和类别 3 外的状态	20%
3	概率为退化状态	滤网更换前 25 天内, 且不属于类别 1	90%

将归一化后的输入参数与对应的概率标签输入至一个全连接神经网络,并采用本章提出的基于后验概率标签的风险估计器(postPU)进行训练。该神经网络包

含四层全连接层，节点数配置为 (7, 28, 28, 1)。分别为 1 号燃机和 2 号燃机独立训练一个进气滤网性能异常识别模型。训练过程中，正类经验风险 R^+ 、负类经验风险 R^- 以及总经验风险 R 随训练轮次 (Epoch) 的变化趋势如图 4.9 所示。

图中显示，各项经验风险均平滑地下降至 2×10^{-2} 以下。风险曲线的平滑下降表明优化过程稳定，未出现明显的梯度爆炸或消失现象；其最终降至较低水平说明模型收敛。





图 4.9 模型训练过程经验风险变化趋势

4.5.1.2 识别结果和分析


训练集上的状态识别模型输出如图 4.10(a) 和 (b) 下方的蓝色谱线所示，色彩深度代表了模型输出的类别分数，分数越高表示模型判断该样本为退化状态可能性越大。将该谱线与图上方的红色训练标签对比可见，模型并未完全依赖训练标签而导致过拟合，而是将标签信息与输入数据的特征相结合，共同判断压气机进气滤网的退化状态。

将模型在测试集上的输出与人工标注的实际退化状态进行对比，结果如图 4.11 所示。图中左侧 2025 年 5 月之前的数据为训练集，右侧 2025 年 5 月之后的数据为测试集。对比下方代表模型输出的蓝色谱线与上方代表人工标注的橙色谱线，可见两者具有较高的匹配度。这表明，在不依赖人工标注的精确设备状态信息或精确的滤网部分负荷特性曲线的条件下，该模型仅通过基于滤网更换时间的间接标注和部件退化模式的定性知识，即可有效识别出滤网的性能退化状态。

模型的定量评估指标如表 4.9 所示，两个机组的模型在测试集上均取得了有效的识别性能。与 3.5.1 节的识别性能相比，测试集上的 F1 分数 1 号燃机提升 4.78%，2 号燃机提升 2.26%，说明使用本章所提方法通过利用预过滤器在更换前退化状态有更高可能性为已退化的额外假设提升了状态识别性能。此外，模型的训练时间均在 15 秒以内，表明该方法计算开销较小。




(a) 1号燃机训练集状态识别模型输出




(b) 2号燃机训练集状态识别模型输出

图 4.10 训练集状态识别模型输出



(a) 1号燃机状态识别模型输出



(b) 2号燃机状态识别模型输出

图 4.11 状态识别模型输出与人工标注对比

4.5.2 汽轮机高压缸性能退化状态识别

本节所用案例与3.5.2节所用案例相同，包含高压缸约半年的历史数据作为状态识别训练数据。人工判定实际退化状态所用的依据与3.5.2.3节利用等熵效率 η_{ht} 与其进口压力 $p_{ht,in}$ 的历史数据分布构建的判定标准相同。

表 4.9 压气机进气滤网状态识别模型性能指标

模型指标	1 号燃机	2 号燃机
F1 分数 (%)	77.43	70.69
准确率 (%)	78.94	72.45
精确率 (%)	99.68	79.12
召回率 (%)	63.30	63.89
训练时间 (s)	9.782	12.07

4.5.2.1 基于运维记录的高压缸退化状态不确定性标注

在3.5.2节中仅利用了 2024 年 9 月秋检维护后高压缸退化状态为健康的假设构建了历史数据标注，使用与上一节利用压气机滤网更换记录类似的思路，对汽轮机高压缸也可以合理假设秋检维护前其退化状态有较高可能性为已退化，3.5.2.3 节中的性能退化评估的历史数据分析同样验证了这一假设的合理性。同样使用本章所提基于概率正-无标签学习的状态识别算法，基于其适用不确定性标注的能力利用上述假设。

由于汽轮机的维护周期相较于进气滤网更换周期更长，在所用的 2024 年 4 月至 2025 年 4 月的数据中仅含有一次 2024 年 9 月秋检的维护记录，因此仅利用该记录进行不确定性标注，标注规则如表4.10所示。规则中设定了一个向后 50 天和向前半年的时间窗口，概率标签 π_i 是对该类别样本为退化状态的后验概率的一种定性估计：类别 1 的 1% 表示几乎确定的健康状态；类别 3 的 80% 表示高度怀疑的退化状态；类别 2 的 5% 则表示在维护后更长的时间内无法确定其退化状态因此赋予一个较低但非零的退化状态概率。训练集标注的设备退化状态标注与实际退化状态的对比如图上方的红色谱线所示，颜色由深到浅分别表示类别 3、类别 2 和类别 1，可以看到在秋检后约两个月的时间段内被标注为类别 1 高概率为健康状态，此后的时间被标注为类别 2 健康状态未知，而秋检前被标注为类别 3 概率为退化状态。

类别 i	设备状态描述	标注规则	概率标签 π_i
1	高概率为健康状态	汽轮机维护后 50 天内	1%
2	健康状态未知	除类别 1 和类别 3 外的状态	5%
3	概率为退化状态	汽轮机前半年内，且不属于类别 1	80%

表 4.10 基于维护时间的高压缸退化状态定性标注规则

将归一化后的表3.6中的输入参数与对应的概率标签输入至一个全连接神经网络，并采用本章提出的基于后验概率标签的风险估计器（postPU）进行训练。神经网络模型结构为四层全连接层，节点数配置为 (9, 28, 28, 1)。

4.5.2.2 识别结果和分析

训练集上的状态识别模型输出如图 4.12 下方的蓝色谱线所示，色彩深度代表了模型输出的类别分数，分数越高表示模型判断该样本为退化状态可能性越大。将该谱线与图上方的红色的训练标注对比可见，在 2024 年 11 月之后的区间模型并未完全依赖训练标签而导致过拟合而误判退化状态。




图 4.12 高压缸退化状态训练集标注及识别结果

将模型在全部数据集上的识别结果与人工标注的实际退化状态进行对比，结果如图 4.13 所示。图中左侧 2025 年 2 月之前的数据为训练集，右侧 2025 年 2 月之后的数据为测试集。对比下方代表模型输出的蓝色谱线与上方代表实际退化状态的红色谱线，可见首先模型成功识别了 2025 年 9 月秋检以前的退化状态，秋检后大部分被模型识别为健康状态，其中 2024 年 9 月 10 月存在部分误报警，而 2025 年 3 月至 5 月识别结果介于秋检前的确定为退化与其它时段的健康状态之间。




图 4.13 高压缸退化状态识别模型识别结果和实际退化状态对比

具体观察如图4.14的高压缸每月的平均退化程度变化趋势可以看到，2025 年 3 月至 5 月的效率相比于 2 月出现了进一步下降，模型的识别结果与其相符。通过人工标注的实际退化状态验证模型识别精度，其定量结果的 F1 分数为 89.08%。以上结果说明在不依赖人工标注的准确设备状态信息或精确的高压缸部分负荷特性曲线的条件下，该模型仅通过基于汽轮机维护时间的间接标注和高压缸退化趋势的定性知识，即可有效识别出汽轮机高压缸结垢造成的性能退化状态，并给出表征退化程度的可能性指标。




图 4.14 高压缸效率退化程度每月变化趋势分析

4.6 小结

本章针对联合循环生产运行环境状态信息不完备条件下的设备退化状态识别问题，提出一种基于概率正-无标签学习的联合循环设备退化状态识别方法，通过数学推导和数值实验证明其中的后验概率的正-无标签（postPU）风险估计器具备基于含误差的不确定性概率标注学习状态识别模型的能力，在公开数据集上验证了该方法的状态识别能力和对抗状态信息随机不确定性和认知不确定性的鲁棒性，并在实际联合循环机组运行数据上应用，利用设备运行维护记录构建含不确定性的退化状态标注，实现了对两台压气机进气滤网退化以及汽轮机高压缸结垢退化的状态识别并提升了识别精度。本章的主要结论如下：

（1）在公开数据集上的实验表明，基于概率正-无标签学习的状态识别方法相对现有方法，对历史数据状态信息随机不确定性具有更高鲁棒性。

在公开数据集 C 上随着标签噪声水平增加，监督基线 F1 分数单调下降，当最大延迟时间 D 扩大至 1-6 天时，降至无延迟理想情况的 30% 以下；而本章所提方法在极端延迟（6 天）情况下识别性能相对控制组仅下降 11 个百分点，识别性能优于其他可利用不确定性标注的现有算法，显著降低误报漏报，表现出对高随机不确定性的训练标签良好鲁棒性。

（2）在公开数据集上的实验表明，基于概率正-无标签学习的状态识别方法相对现有方法，对历史数据状态信息认知不确定性具有更高鲁棒性。

在仅能利用停机时间作为间接状态标注实验设定中，所提状态识别方法能够利用不确定性量化的概率标签，克服停机记录与目标异常状态之间的认知不确定性，综合指标优于其他正-无标签学习方法，并能够恢复准确的目标设备状态。

（3）通过基于概率正-无标签学习技术，可以在不依赖准确的设备部分负荷特性和准确的设备退化状态历史标注的条件下，建立联合循环运行机组部分设备和部件的退化状态识别模型，识别了压气机进气滤网退化和汽轮机高压缸结垢退化。

在实际联合循环运行机组的压气机进气滤网和汽轮机高压缸结垢退化识别的案例中，所提方法利用设备运行维护记录构建含不确定性的退化状态标注，实现了对两台压气机进气滤网退化以及汽轮机高压缸结垢退化的状态识别并提升了识别精度。识别过程基于设备维护记录和退化规律构造概率标签，通过不确定性定量表示将定性知识融入训练标注。实验结果表明：在训练集上，模型风险曲线平滑下降并收敛至较低水平，建模过程稳定；在测试集上，模型输出与人工判定的实际退化状态具有较高匹配度，能够较为准确地识别退化状态。模型识别结果与人工标注的实际退化状态对比和定量评估显示，两个燃机机组的压气机进气滤网退化状态模型在测试集上均取得有效识别性能，F1 分数分别达到 77.43% 和 70.69%。该方法在仅依赖运维记录的间接标注和基于退化发展假设的定性知识的条件下，实现了对压气机进气滤网和汽轮机高压缸退化状态的有效识别，验证了所提方法在状态信息不完备条件下的实用性和鲁棒性。

第5章 基于联合学习的非完备信息下燃机性能退化评估

5.1 引言

第二章至第四章分别针对非完备信息问题中测量信息不完备与状态信息不完备的子问题开展方法研究,提出了相应方法,实现了在仅存在单一类型不完备信息的条件下对联合循环系统的建模或特定设备的异常识别。然而,生产环境中多种非完备信息往往同时存在,要求建模与性能退化评估方法具备同时应对多种不完备信息的能力。本章针对上述综合性挑战,结合前述章节方法,基于实际联合循环机组开展应用研究。

本章提出一种基于联合学习的联合循环燃气轮机性能退化评估方法。该方法通过定义协同损失函数,实现特性模型回归与性能退化状态识别任务的协同训练,融合前文提出的意外函数与概率正-无标签学习方法,分别处理建模过程中的测量信息不完备与状态信息不完备问题。本章后续内容安排如下:5.2节描述所提基于联合学习的性能退化评估方法的理论基础和方法流程,5.3节基于实际联合循环机组案例开展应用,完成两台燃气轮机的基准健康状态建模与性能退化评估,5.4节概述本文相关内容在实际联合循环机组上的工程应用与程序实现。

5.2 方法描述

为应对多种非完备信息共存的问题,本章提出一种基于联合学习的燃气轮机性能退化评估方法。在单一类型信息不完备的条件下,可以通过其它途径获取的信息进行推算,如测量缺失而设备知识与退化状态完备时可通过设备模型推算,设备知识缺失而测量完备且假设设备状态不发生变化的条件下可以通过数据拟合其部分负荷特性。但在多种类型信息不完备的情况下,则需要合理设计含迭代的计算方法,以充分利用可获取但不完备的信息,包括来自设备知识、传感器测量以及由运行维护记录推断的设备退化状态信息,以综合评估燃气轮机性能退化程度。

本节介绍基于联合学习的联合循环性能退化评估方法,及其涉及的联合学习理论基础。

5.2.1 联合学习

统计与深度学习领域的研究者发现,当多个任务存在关联时,同时学习多个任务相较于单独学习每个任务可获得更优性能^[127-129]。联合学习范式据此提出,其

核心思想在于利用任务间的相关性，通过信息共享提升模型的泛化能力与数据效率^[130]。信息共享机制等效于一种隐式正则化，在数据量少或数据稀疏的场景下有助于降低过拟合风险^[131]。

联合学习的实现主要包含模型参数共享与损失函数协同两个方面。

模型参数共享可分为硬共享模式与软共享模式。硬共享模式中，不同任务共用一部分相同的模型参数^[132]；软共享模式则通过正则化项约束不同任务模型参数之间的相似性，而不直接共享参数。

硬共享模型的典型数学形式为：

$$\mathbf{y}_t = f_t[g(\mathbf{x}_s), \mathbf{x}_t], \quad t = 1, \dots, |T| \quad (5.1)$$

其中 $\mathbf{y}_t$ 表示第 t 个任务的输出， $g(\cdot)$ 为任务间共享参数的模型， $\mathbf{x}_s$ 为共享输入， f_t 为任务专属的模型部分， $\mathbf{x}_t$ 为额外输入。

损失函数协同的基础形式为各任务损失函数的加权和：

$$L_{\text{total}} = \sum_{t=1}^{|T|} w_t L_t \quad (5.2)$$

其中 w_t 为第 t 个任务的权重。也有研究者发现加权求和方式可能导致任务间梯度不平衡问题^[133-134]，进而提出自适应损失函数协同方法，通过动态调整任务权重来平衡不同任务的学习进度与重要性。

5.2.2 方法流程

本节针对联合循环性能退化评估任务，构建包含基准健康状态性能模型拟合与退化识别两个子任务的联合学习框架。基准健康状态性能模型拟合以物理方程、约束条件满足及拟合精度为优化目标；退化识别则以准确判别各数据样本对应时刻的设备退化状态为目标。

两个任务通过硬共享模式实现参数共享：将基准健康状态性能模型作为退化评估的前置步骤，退化评估直接基于该模型输出的基准健康状态下设备特性与出力等性能参数进行计算，从而使退化评估过程具备物理依据与可解释性。

5.2.2.1 基准健康状态设备建模

基准健康状态设备建模采用基于物理方程与经验公式相结合的灰箱模型。其中物理方程部分及其假设与第二章性能预测模型一致，经验公式部分用于描述效率等无法由物理方程直接表征的参数。模型的输入参数与输出参数也与第二章性能预测模型保持一致。

基准健康状态设备模型可表示为：

$$\mathbf{y}^* = \mathbf{M}^*(\mathbf{x}_s) \quad (5.3)$$

其中， $\mathbf{x}_s$ 为控制参数与输入参数向量，包含压比、环境温度等变量； $\mathbf{M}^*$ 为基准健康状态下设备性能模型； $\mathbf{y}^*$ 为模型输出的基准健康状态性能参数向量，包括出力、热效率等。

退化评估模型定义为：

$$w = S(\mathbf{y}^*, \mathbf{y}) \quad (5.4)$$

式中， $\mathbf{y}$ 为由实际测量数据计算得到的出力、效率等性能参数； S 为第二章定义的意外函数之和，用于度量性能参数对若干约束条件的满足程度，其数值越大表示偏离基准健康状态的程度越高。

5.2.2.2 协同损失定义

在上述参数硬共享基础上，通过定义协同损失实现性能建模与退化评估任务的联合学习。协同损失包含以下两部分：

基准状态性能偏离损失：定义基准状态性能偏离损失为：

$$l_r = R_{\text{postPU}}(\tilde{w}, \pi) \quad (5.5)$$

其中， R_{postPU} 为第四章提出的基于后验概率的正-无标签经验风险估计器，输入为模型预测类别分数 $\tilde{w}$ 与概率标签 π 。 $\tilde{w}$ 由 w 经如下映射函数得到：

$$\tilde{w} = \log(w) + \gamma w \quad (5.6)$$

该映射函数通过控制 w 在不同取值范围内的梯度变化，使得当 w 较小时 $\tilde{w} \approx w$ ，从而引导梯度下降过程优先拟合接近基准健康状态的数据；而当 w 较大（对应退化程度较高）时，映射后梯度较小，模型自动降低对该类数据的拟合程度。

退化工况解耦损失：定义工况解耦损失为：

$$l_d = \max [\text{Corr}(\mathbf{x}_s, \mathbf{y}_d - \mathbf{y}_d^*)] \quad (5.7)$$

式中， $\mathbf{y}_d - \mathbf{y}_d^*$ 为实际性能参数相对于基准模型值的残差，下标 d 表示选取用于计算退化指标的部分性能参数； $\max[\text{Corr}(\cdot)]$ 为皮尔逊相关系数矩阵中所有非对角线元素的最大值。该损失引导学习过程使退化指标与工况参数的相关性尽可能小，从而实现退化与工况的解耦。

5.3 应用案例

本节在联合循环实际运行数据基础上，以两台燃气轮机为研究对象，使用本章所提基于联合学习的燃气轮机性能退化评估方法，在测量信息、设备部分负荷特性知识和设备历史退化状态信息不完备的条件下，构建基准健康状态下热效率模型，并对燃气轮机性能退化的程度和趋势进行评估。

5.3.1 数据基础

本节使用与2.3.2.1节相同联合循环机组的数据，在生产环境下存在多种非完备信息问题。其一，测量条件存在缺失和不确定性，如燃烧室内温度和压力损失无法测量，排气流量因排气管道的截面积较大导致测量不准确；其二，由于所用燃气轮机为进口型号，因此无法获取其准确的部分负荷效率特性，造成设备知识的缺失；其三，燃气轮机的退化状态是隐含参数无法直接测量或通过显式方法计算得到，导致其历史退化状态不确定。

5.3.1.1 数据来源与参数筛选

本节案例的研究对象为中国北方某燃气-蒸汽联合循环热电联供电厂，额定负荷约为700 MW，采用两台燃气轮机一台汽轮机配合三台发电机、二拖一布置。研究数据源自该电厂实际运行过程中现场传感器测量的历史数据，时间范围为该厂燃机和汽轮机改造后（2024年10月）至2025年5月。经数据清洗后共获得17928条样本，数据示例如图5.1所示。



图 5.1 联合电厂运行期间汽轮机和两台燃气轮机（GT1,GT2）发电功率历史数据

本节以两台燃气轮机为对象进行性能评估。由公式 $\eta_{gt} = \dot{W}_{e,gt}/(\dot{m}_f LHV)$ 计算得到的燃气轮机热效率历史数据分布如图5.2所示。从图5.2中可以看到燃机的热效率 η_{gt} 约在 20% 至 40% 之间，且与工况强相关，随压比增大而增大。在构建整机热效率模型时，根据热力学原理选取与热效率相关的参数，包括压比、环境温度、环境压力和燃料流量。图5.2展示了压比和环境温度对热效率的影响，横坐标为压

比, 最大值 16.5 对应额定工况下的压比, 此时整机热效率约为 38%; 散点颜色表示环境温度 (摄氏温度)。




图 5.2 运行历史数据中两台燃气轮机热效率与压比关系

5.3.1.2 设备健康状态定性标注

在燃气轮机性能退化中, 进气滤网堵塞和压气机结垢是主要因素, 随运行时间增加, 此类退化必然发生并对性能产生影响。联合循环机组运行维护中, 通过定期或不定期更换进气滤网及压气机水洗实现退化恢复。

在燃气轮机性能评估中, 设备健康状态是客观存在但隐含的参数, 无法直接测量或显式推算, 这是状态信息不完备的主要原因。为此, 引入定性的先验知识作为假设: 设备退化恢复后的一段时间内, 有高概率处于健康状态; 而退化恢复前的一段时间内, 则有概率处于退化状态。基于此假设, 结合设备维护记录, 以压气机水洗和进气滤网更换时间为退化恢复时间, 进而对退化恢复前后的数据进行定性标注。

该联合循环电厂压气机水洗于每年 4 月和 9 月进行, 进气滤网更换记录见表 5.1。基于此, 定义如表 5.2 的标注规则。将清洗后的历史数据按与退化恢复时间的关系分为三个类别, 类别 1 至 3 所代表的退化可能性依次增大, 对应概率标签满足 $\pi_1 < \pi_2 < \pi_3$ 。

基于该规则标注的历史数据如图 5.3 所示, 图中横坐标为时间, 红色由浅至深分别表示类别 1 至类别 3, 纯白色表示设备停机无数据。

5.3.2 基准健康状态识别结果与特性曲线重建

将每一时刻的历史测量数据作为样本, 以测量参数为样本特征 X , 设备健康状态定性标注的概率标签 π 为样本标签, 输入本章所提联合学习算法, 同时得到基准健康状态识别结果及其对应的热效率部分负荷特性模型。结果如下:

表 5.1 燃气轮机进气滤网设备维护记录

时间	维护内容
2023-04	更换 2 台机粗滤
2023-09	更换 2 台机粗滤
2024-09	升级 2 台机滤网
2025-01	更换预过滤器 G3 滤棉
2025-04	更换预过滤器 G3 滤棉
2025-05	更换预过滤器 G3 滤棉
2025-09	更换预过滤器 G3 滤棉
2025-12	更换预过滤器 G3 滤棉

表 5.2 基于退化恢复时间的设备健康状态定性标注规则

类别 i	描述	标注规则	概率标签 π_i
1	高概率为健康状态	退化恢复后 25 天内	0%
2	健康状态未知	除类别 1 和类别 3 外的状态	1%
3	概率为退化状态	退化恢复前 25 天内，且不属于类别 1	5%




图 5.3 燃气轮机设备健康状态定性标注结果

5.3.2.1 基准健康状态识别

算法识别的设备健康状态标签如图5.4(a) 和 (b) 下方的蓝色谱线所示，蓝色深浅表示类别分数高低，深色谱线对应的时间被识别为较大程度偏离健康状态。浅色谱线对应的样本作为基准健康状态，用于热效率特性模型重建。图5.4中红色谱线为相应的训练标签。

5.3.2.2 基准健康状态特性曲线重建

基准健康状态下的热效率特性模型如图5.5所示，图中实线表示不同环境温度下整机热效率随压比变化的趋势，颜色表示环境温度（摄氏温度）。




图 5.4 算法对两台燃气轮机历史健康状态识别结果




图 5.5 算法对两台燃气轮机部分负荷下热效率特性曲线的建模结果

图5.6展示了建模得到的基准热效率与实际热效率的关系。图中大部分数据点位于红色虚线 $\hat{\eta}_{gt} = \eta_{gt}$ 上方，表明基准热效率高于实际热效率，即这些数据点对应的设备健康状态相对于基准健康状态存在退化，且热效率指标上有所体现。

作为对照，在不使用健康状态定性标注和本章联合学习方法的情况下，直接拟合全部数据得到的热效率特性曲线如图5.7所示。图中数据点较为均匀地分布在红色虚线 $\hat{\eta}_{gt} = \eta_{gt}$ 两侧，表明直接建模得到的特性是不同健康状态特性的混合平均结果，无法准确表征某一特定健康状态下的热效率特性，也难以进行后续的退化评估。

基准健康状态的物理意义是通过现场退化恢复手段（如进气滤网更换和压气机水洗）可达到的设备健康状态，该状态与设备设计状态或出厂状态不同，但接近于实际运行中存在的最优健康状态，适合作为设备退化评估的基准。




图 5.6 两台燃气轮基准状态热效率与实际热效率的关系




图 5.7 使用全部数据建模时模型热效率与实际热效率的关系

5.3.3 燃气轮机性能退化评估


上一节中建立了两台燃气轮机热效率在基准健康状态下的部分负荷特性模型，本节在此基础上将实际热效率与基准健康状态热效率对比，并构建表征性能退化程度的退化系数，分析两台燃气轮机的退化趋势。

5.3.3.1 燃气轮机退化对性能影响程度计算


定义表征燃气轮机退化对其性能的影响程度的退化系数 γ_{gt} 为实际热效率 η_{gt} 与基准热效率 $\hat{\eta}_{gt}$ 的比值，即 $\gamma_{gt} = \eta_{gt} / \hat{\eta}_{gt}$ 。该系数表征燃气轮机整机退化程度及其

对性能的定量影响，具有实际物理意义：例如 $\gamma_{gt} = 100\%$ 表示热效率与基准健康状态相同， $\gamma_{gt} = 90\%$ 表示相同燃料输入下发电功率降低 10%。

两台燃气轮机退化在对其热效率的影响随时间变化趋势如图5.8所示。图中显示， γ_{gt} 在退化恢复操作后的长时间内呈下降趋势，其中 1 号燃机退化最为明显，表明燃气轮机退化程度在 2 至 4 个月的维护周期内随运行时间累积而增加。退化导致的热效率下降达到 10%，对应热效率下降约 0.7 个百分点。



(a) 1 号燃机



(b) 2 号燃机

图 5.8 两台燃气轮机退化在对其热效率的影响随时间变化趋势

5.4 工程应用和程序开发

基于本文所提的方法和所建立的设备模型，开发了联合循环性能评估与负荷分配优化程序，在实际联合循环机组现场应用，在线计算并将结果反馈至电厂的综合系统中显示，为运行人员提供实时性能评估和负荷分配优化建议。

程序基于 Python 语言 3.10 版本开发，本节具体描述该程序的实现方式。

5.4.1 性能评估模块

性能评估模块根据测量数据，实时计算联合循环机组的性能参数，并计算各关键部件的效率，为运行人员提供实时性能评估。

测量数据收集：程序的输入为联合循环机组安装的传感器实时测量值，借助电厂已部署的数据收集平台在电厂内部服务器中记录和保存，并通过电厂内网络通过约定的 Json 格式将最新的传感器测量值组传输给程序的性能评估模块。

由于现场测量条件和工况变化等，测量值常出现部分的缺失，为此性能评估模块内部设有关键测量参数的历史统计量，在部分参数缺失时基于历史统计量进行估算，以保证程序的基础功能对现场复杂条件有一定适应性。

计算流程：性能评估模块为实时计算模块，每分钟计算一轮。模块基于热力学方程和设备部分负荷特性计算如燃气轮机压气机等熵效率、余热锅炉换热效率等联合循环设备和部件的性能参数；所使用的热力学方程和设备部分负荷特性具体参见2.3.1节对各设备部件的描述。

程序计算中涉及的物性计算通过 Python 中现有的物性计算库实现。底循环的工质为水和水蒸气，通过 iapws 模块实现，该模块的热力学性质计算依据 IAPWS-IF97 工业标准，绝大多数的蒸汽状态参数通过温度和压力两个独立变量确定，该标准的完整推导与验证基于 IAP^[135]的内容章节。水蒸气的焓值零点选取方式为规定三相点饱和水 $u=0, s=0$ ，进而推导得的基准三相点基准焓值 $h \approx 0.611783 \text{ kJ/kg}$ 。焓值零点选取不影响性能计算，实际计算中均通过焓差计算，如汽轮机进出口、供热进出口焓差。

空气、燃气及其他气体物质的热物理性质通过开源库 CoolProp^[136]的 Python 接口计算，气体的焓值零点选取方式为理想气体在 100 K, 1 bar 处规定 $h=0, s=0$ 。

联合循环性能评估模块输出的性能参数如表5.3所示。

表 5.3 性能评估模块输出的性能参数

参数描述	所属子模块	单位
#1 燃机压气机耗功	燃机性能评估	MW
#1 燃机压气机等熵效率	燃机性能评估	%
#1 燃机压气机等熵损失	燃机性能评估	MW
#1 燃机燃烧室燃烧温度推算	燃机性能评估	K
#1 燃机透平做功	燃机性能评估	MW
#1 燃机透平等熵效率	燃机性能评估	%
#1 燃机透平等熵损失	燃机性能评估	MW

续表 5.3 性能评估模块输出的性能参数

参数描述	所属子模块	单位
#1 燃机透平焓效率	燃机性能评估	%
#1 燃机热效率	燃机性能评估	%
#1 燃机热耗	燃机性能评估	MW
#2 燃机压气机耗功	燃机性能评估	MW
#2 燃机压气机等熵效率	燃机性能评估	%
#2 燃机压气机等熵损失	燃机性能评估	MW
#2 燃机燃烧室燃烧温度推算	燃机性能评估	K
#2 燃机透平做功	燃机性能评估	MW
#2 燃机透平等熵效率	燃机性能评估	%
#2 燃机透平等熵损失	燃机性能评估	MW
#2 燃机透平焓效率	燃机性能评估	%
#2 燃机热效率	燃机性能评估	%
#2 燃机热耗	燃机性能评估	MW
#1 炉主蒸汽吸热量	余热锅炉性能评估	MW
#1 炉再热蒸汽吸热量	余热锅炉性能评估	MW
#1 炉低压主蒸汽吸热量	余热锅炉性能评估	MW
#1 炉高压蒸发器换热效率	余热锅炉性能评估	%
#1 炉高压蒸发器换热温差	余热锅炉性能评估	°C
#1 炉高压蒸发器吸热功率	余热锅炉性能评估	MW
#1 炉高压蒸发器换热性能系数	余热锅炉性能评估	W/K
#1 炉中压蒸发器换热效率	余热锅炉性能评估	%
#1 炉中压蒸发器换热温差	余热锅炉性能评估	°C
#1 炉中压蒸发器吸热功率	余热锅炉性能评估	MW
#1 炉中压蒸发器换热性能系数	余热锅炉性能评估	W/K
#2 炉主蒸汽吸热量	余热锅炉性能评估	MW
#2 炉再热蒸汽吸热量	余热锅炉性能评估	MW
#2 炉低压主蒸汽吸热量	余热锅炉性能评估	MW
#2 炉高压蒸发器换热效率	余热锅炉性能评估	%
#2 炉高压蒸发器换热温差	余热锅炉性能评估	°C
#2 炉高压蒸发器吸热功率	余热锅炉性能评估	MW

续表 5.3 性能评估模块输出的性能参数

参数描述	所属子模块	单位
#2 炉高压蒸发器换热性能系数	余热锅炉性能评估	W/K
#2 炉中压蒸发器换热效率	余热锅炉性能评估	%
#2 炉中压蒸发器换热温差	余热锅炉性能评估	°C
#2 炉中压蒸发器吸热功率	余热锅炉性能评估	MW
#2 炉中压蒸发器换热性能系数	余热锅炉性能评估	W/K
#2 余热锅炉换热效率	余热锅炉性能评估	%
#2 余热锅炉焓效率	余热锅炉性能评估	%
#2 余热锅炉烟气热量	余热锅炉性能评估	MW
高压缸做功	汽轮机性能评估	MW
高压缸等熵效率	汽轮机性能评估	%
高压缸焓效率	汽轮机性能评估	%
中压缸做功	汽轮机性能评估	MW
中压缸等熵效率	汽轮机性能评估	%
中压缸焓效率	汽轮机性能评估	%
低压缸做功	汽轮机性能评估	MW
低压缸等熵效率	汽轮机性能评估	%
低压缸焓效率	汽轮机性能评估	%
联合循环能量效率	联合循环性能评估	%
联合循环发电效率	联合循环性能评估	%
联合循环热耗	联合循环性能评估	MW
联合循环焓效率	联合循环性能评估	%

经过现场测试，性能评估模块的每轮计算时间在 1 分钟以内，能够实现联合循环机组现场的在线性能评估。

程序输出：性能评估结果以 Json 格式输出，图5.9展示了其中一组的程序输出的一部分，计算结果通过电厂内网络传输至电厂的生产监控系统显示。图5.10展示了性能评估提供的部分功能，比如图5.10(a)是程序计算的燃烧室温度的历史结果绘制的曲线，运行人员可以根据其趋势判断燃机运行情况；图5.10(b)是监控系统根据该程序计算的一台余热锅炉三路不同压力蒸汽的吸热功率的占比绘制的饼图，显示了余热锅炉的能量利用情况；图5.10(c)是监控系统根据该程序计算的汽轮机


各缸出力对燃料热量的利用比例绘制的饼图，显示了底循环的能量利用情况。

```

{"timestamp": "2026-03-19T19:20:09.517276", "level": "INFO", "logger": "app", "message": "正在计算j
yrd热网回水参数 热力参数"}
{"timestamp": "2026-03-19T19:20:09.526249", "level": "INFO", "logger": "app", "message": "wrapper e
xecuted in 1.0231 seconds"}
[{"varname": "SKY.GT1.CMP.HG_MW", "timestamp": "2025-12-11 06:33:00", "value": 164.343447558637, "p
eriod": 1}, {"varname": "SKY.GT1.CMP.DSXL_100", "timestamp": "2025-12-11 06:33:00", "value": 85.108
07067962979, "period": 1}, {"varname": "SKY.GT1.COMB.T3_K", "timestamp": "2025-12-11 06:33:00", "va
lue": 1211.725813962621, "period": 1}, {"varname": "SKY.GT1.TURB.ZG_MW", "timestamp": "2025-12-11 0
6:33:00", "value": 342.24814155863737, "period": 1}, {"varname": "SKY.GT1.TURB.DSXL_100", "timestam
p": "2025-12-11 06:33:00", "value": 87.91658723623429, "period": 1}, {"varname": "SKY.GT1.TURB.YXL
_100", "timestamp": "2025-12-11 06:33:00", "value": 96.71289930775936, "period": 1}, {"varname": "SK
Y.GT1.RXL_100", "timestamp": "2025-12-11 06:33:00", "value": 31.686377013406616, "period": 1}, {"var
name": "SKY.GT1.RH_MW", "timestamp": "2025-12-11 06:33:00", "value": 561.4548293884401, "period":
1}, {"varname": "SKY.GT2.CMP.HG_MW", "timestamp": "2025-12-11 06:33:00", "value": 163.8834202864915
, "period": 1}, {"varname": "SKY.GT2.CMP.DSXL_100", "timestamp": "2025-12-11 06:33:00", "value": 85
.31737439113807, "period": 1}, {"varname": "SKY.GT2.COMB.T3_K", "timestamp": "2025-12-11 06:33:00",
"value": 1211.551716303799, "period": 1}, {"varname": "SKY.GT2.TURB.ZG_MW", "timestamp": "2025-12-
11 06:33:00", "value": 341.3240482864916, "period": 1}, {"varname": "SKY.GT2.TURB.DSXL_100", "timesta
mp": "2025-12-11 06:33:00", "value": 87.85264964751933, "period": 1}, {"varname": "SKY.GT2.TURB.Y
XL_100", "timestamp": "2025-12-11 06:33:00", "value": 96.70046855047101, "period": 1}, {"varname":

```

图 5.9 性能评估模块的程序输出案例



(a) 2号燃机燃烧室温度计算结果

(b) 2号余热锅炉吸热功率比例计算结果

(c) 汽轮机各缸出力比例计算结果

图 5.10 性能评估模块的输出案例

5.4.2 负荷分配优化模块

负荷分配优化模块根据测量数据判断当前的热电负荷需求和大气温度等环境条件，结合本文2.3节的联合循环性能模型和优化方法，求解最优负荷分配方案，输出负荷分配调节方案的相关参数的调节建议到电厂的生产监控系统显示，为运行人员提供实时的负荷分配优化建议。

测量数据收集：负荷分配优化模块的输入与性能评估模块类似，同样为联合循环机组安装的传感器实时测量值，通过电厂内网络通过约定的 Json 格式将最新的传感器测量值组传输给程序的负荷分配优化模块。

经过现场测试，负荷分配优化模块的每轮计算时间在 3 分钟以内，能够实现联合循环机组现场稳定工况下的在线负荷分配优化计算。

计算流程：负荷分配优化模块首先使用单目标优化方法求解2.5节所定义的优

化问题，即根据实测参数确定当前的发电负荷需求，以及大气温度大气压力的边界调节，将联合循环机组内部约束、负荷需求约束条件和燃料消耗率最小化的目标都以第二章中的意外函数的形式合成在最终优化问题的目标函数中。求解收敛得到最优的负荷分配方案，再计算最优方案下相应设备性能的参数，如果需要偏置负荷则给出偏置方向的建议。

程序输出：负荷分配优化模块的输出结果同样以 Json 格式输出，图5.11展示了其中一组的程序输出的一部分，计算结果通过电厂内网络传输至电厂的生产监控系统显示。

```

{"timestamp": "2026-03-19T20:25:24.515525", "level": "INFO", "logger": "app", "message": "优化模型预测出力:\n powerGTCC Qheat\n0 43 1.538557 431.023666"}
{"timestamp": "2026-03-19T20:25:24.515849", "level": "INFO", "logger": "app", "message": "优化后目标函数:\n20.890593162855446"}
{"timestamp": "2026-03-19T20:25:24.616909", "level": "INFO", "logger": "app", "message": "wrapper executed in 51.6949 seconds"}
{"varname": "SKY_LOAD.OPT.FuelSave_100", "timestamp": "2025-01-01 00:00:00", "value": 0.6516998036503179, "period": 1}, {"varname": "SKY_LOAD.OPT.GT2_LOAD_D_M_W", "timestamp": "2025-01-01 00:00:00", "value": -50.93730088990971, "period": 1}, {"varname": "SKY_LOAD.OPT.ST_LOAD_D_M_W", "timestamp": "2025-01-01 00:00:00", "value": 50.93730088990971, "period": 1}, {"varname": "SKY_LOAD.OPT.FUEL_d_kgs", "timestamp": "2025-01-01 00:00:00", "value": -0.8138816805871585, "period": 1}, {"varname": "SKY_LOAD.OPT.CMP_DSXL_100", "timestamp": "2025-01-01 00:00:00", "value": 88.88365037482777, "period": 1}, {"varname": "SKY_LOAD.OPT.CMP_DSXL_100", "timestamp": "2025-01-01 00:00:00", "value": 84.9708155048456, "period": 1}, {"varname": "SKY_LOAD.OPT.GT2_TURB_DSXL_100", "timestamp": "2025-01-01 00:00:00", "value": 92.6152777823454, "period": 1}, {"varname": "SKY_LOAD.OPT.GT1_TURB_DSXL_100", "timestamp": "2025-01-01 00:00:00", "value": 88.2940220666107, "period": 1}, {"varname": "SKY_LOAD.OPT.GT2_TURB_DSXL_100", "timestamp": "2025-01-01 00:00:00", "value": 85.6894825552837, "period": 1}, {"varname": "SKY_LOAD.OPT.GT1_TURB_DSXL_100", "timestamp": "2025-01-01 00:00:00", "value": 90.92359275562487, "period": 1}, {"varname": "SKY_LOAD.OPT.COMB_T3_C", "timestamp": "2025-01-01 00:00:00", "value": 1200.7259156682144, "period": 1}, {"varname": "SKY_LOAD.OPT.COMB_T3_C", "timestamp": "2025-01-01 00:00:00", "value": 1153.8847905159464, "period": 1}, {"varname": "SKY_LOAD.OPT.COMB_T3_C", "timestamp": "2025-01-01 00:00:00", "value": 1196.3452455339998, "period": 1}, {"varname": "SKY_LOAD.OPT.GT1_QHL_kgkj", "timestamp": "2025-01-01 00:00:00", "value": 1240.2209905087925, "period": 1}, {"varname": "SKY_LOAD.OPT.GT1_QHL_kgkj", "timestamp": "2025-01-01 00:00:00", "value": 0.3345450544543013, "period": 1}, {"varname": "SKY_LOAD.OPT.GT2_QHL_kgkj", "timestamp": "2025-01-01 00:00:00", "value": 0.3988263759081037, "period": 1}, {"varname": "SKY_LOAD.OPT.GT2_QHL_kgkj", "timestamp": "2025-01-01 00:00:00", "value": 0.32163621900409156, "period": 1}, {"varname": "SKY_LOAD.OPT.GT1_RXL_100", "timestamp": "2025-01-01 00:00:00", "value": 32.02467712821281, "period": 1}, {"varname": "SKY_LOAD.OPT.GT1_RXL_100", "timestamp": "2025-01-01 00:00:00", "value": 26.863061223934665, "period": 1}, {"varname": "SKY_LOAD.OPT.GT2_RXL_100", "timestamp": "2025-01-01 00:00:00", "value": 33.309984139575654, "period": 1}, {"varname": "SKY_LOAD.OPT.GT2_RXL_100", "timestamp": "2025-01-01 00:00:00", "value": 37.15727614229784, "period": 1}, {"varname": "SKY_LOAD.OPT.GT2_PR", "timestamp": "2025-01-01 00:00:00", "value": 13.780607678278565, "period": 1}, {"varname": "SKY_LOAD.OPT.Suggestion", "timestamp": "2025-01-01 00:00:00", "value": "2\\u53f7\\u71c3\\u673

```

图 5.11 负荷分配优化模块的程序输出案例

图5.10展示了负荷分配优化模块的部分功能，比如图5.12(a)是程序计算的两台燃机的性能对比结果，可作为运行人员是否执行偏置负荷分配的依据；图5.12(b)是程序给出的负荷分配建议在生产监控系统中的展示，为运行人员提供直接的建议；图5.12(c)是程序给出的最优负荷分配方案的详细性能参数，如调节前后两台燃机压气机和透平各自等熵效率的差异，为负荷分配优化提供了更具体的分析依据。



(a) 两台燃机的性能对比结果 (b) 负荷分配的操作建议文字 (c) 优化前后性能参数对比

图 5.12 负荷分配优化模块的输出案例

5.5 小结

本章针对联合循环运行机组生产环境下多种非完备信息共存的问题,提出了基于联合学习的联合循环燃气轮机性能退化评估方法。该方法融合前文提出的意外函数与概率正-无标签学习方法,分别处理建模过程中的测量信息不完备与状态信息不完备问题,通过定义协同损失函数,实现特性模型回归与性能退化状态识别任务的协同训练。在联合循环为期约一年的生产运行数据上应用,建立了两台燃气轮机在基准健康状态下的热效率部分负荷特性模型,并评估了性能退化的程度与退化趋势。本章的主要结论如下:

(1) 基于联合学习的燃气轮机性能退化评估方法能够在非完备信息条件下,建立燃气轮机热效率的基准健康状态模型,并评估性能退化程度。

在为期约一年的生产运行数据基础上,结合滤网更换和压气机水洗等退化恢复记录作为含不确定性和系统偏差的状态信息,通过本章所提基于联合学习的性能退化评估方法,构建燃气轮机热效率的基准健康状态模型。进而计算得到退化系数作为燃气轮机热效率的退化指标,该指标具有明确物理意义,并在历史数据中评估了两台燃气轮机的性能退化程度与退化趋势。

(2) 联合循环机组的燃气轮机受到压气机结垢和滤网堵塞退化的影响,会在数月的维护周期内出现热效率的下降。

基于联合循环机组实际运行数据的分析,在压气机水洗和进气滤网更换的周期内,相对健康基准状态的燃气轮机,其热效率受到退化影响下降约 10%,对应约 0.7 个百分点的热效率损失。

(3) 本文相关联合循环性能评估与负荷分配优化方法能够完成程序实现,并能够在实际生产环境的在线运行中执行。

开发的程序包含性能评估与负荷分配优化模块,目前在一台联合循环机组上完成部署,并能够根据实时的测量参数和内置模型实现性能评估和负荷分配优化,分别在 1 分钟和 3 分钟以内完成计算并给出评估结果和优化策略等输出,借助电厂的生产监控系统向运行维护人员提供运行辅助。

第6章 总结与展望

6.1 本文的主要内容及研究成果

从仿真与实验室条件下的方法研究向工程应用推进的过程中,技术和方法不可避免地面临实际适用条件偏离理想状态的问题。其中,非完备信息问题是以动力设备模型为基础的识别、评估与优化等方法在工程落地中面临的主要障碍之一。本文以燃气-蒸汽联合循环为研究对象,围绕非完备信息问题提出一系列解决方法,并在实际联合循环生产数据与公开的基准数据集上开展验证。研究成果为应对联合循环生产环境下的非完备信息问题提供了理论指导与应用示范。具体研究内容包括针对不同非完备信息子问题的处理方法,以及综合多种方法以应对多种非完备信息并存场景的应用方法:

研究内容一:针对测量信息不完备问题,提出基于意外函数的不确定性建模与优化方法,适用于测量缺失和测量不准确的场景,能够结合基于物理方程的设备模型实现不确定性量化的部分负荷下的性能建模。在实际联合循环汽轮机、燃气轮机和余热锅炉生产运行数据上对所提方法进行验证,评估了其精度和鲁棒性,及其推算缺失的测量参数和校正不准确的测量参数的能力。在此基础上进一步研究了多拖一联合循环系统的负荷分配优化问题。结果表明,在已知多台燃气轮机存在效率差异的条件下,采用偏置分配方案可提升整厂热效率,理论计算得到该电厂年燃料节约潜力约为0.3%。

研究内容二:针对联合循环生产环境下的状态信息不完备问题,分析了联合循环退化状态识别任务中现有数据驱动方法受制于历史数据标注量不足和数据分布假设弱的局限性,并提出一种基于自适应学习与伪标签的联合循环设备退化状态识别方法。设计了一种退化状态识别算法,改进自适应训练框架,引入锐化伪标签生成与动态样本重加权技术,利用中间模型预测逐步校准训练标签,缓解确认偏差与收敛至平凡解的风险,实现在少量健康状态标注与大量无标注样本条件下的状态识别。基于多个公开数据集开展了数值实验,与现有方法定量比较了状态识别效果,验证了该方法对历史数据状态标注量的依赖性更低,以及对历史数据标注的数据分布假设的依赖性更低;通过消融实验验证了该方法各改进环节的必要性。在联合循环运行机组的实际数据上应用了该方法,利用低成本数据标注,建立了压气机进气滤网退化和汽轮机高压缸结垢退化的状态识别模型,识别了部件退化状态。进一步结合设备部分负荷特性,分析了压气机进气滤网和高压缸结垢退化对设备性能的影响,其退化速率、退化趋势以及退化原因,并验证了模型的

识别精度。为缺少准确的设备部分负荷特性且历史退化状态标注稀缺条件下的联合循环运行机组设备退化状态识别提供了新的思路，降低了建模对历史数据和人工标注的依赖性，降低了数据驱动退化识别方法的建模成本从而提升了其工程适用性。

研究内容三：针对联合循环生产环境下的状态信息不完备问题，分析了联合循环机组运行维护记录对推断设备历史退化状态的重要价值，及其蕴含的不确定性对数据驱动算法的挑战，并提出一种基于概率正-无标签学习的联合循环设备退化状态识别方法。设计了通过结合联合循环机组运行维护记录与定性假设推断设备历史退化状态，并通过后验概率标签实现退化状态不确定性定量标注的思路，能够以概率标签为中介，将定性的先验知识转化为可量化的退化状态标注信息。同时设计了一种基于后验概率的正-无标签风险估计器（postPU），改进了正-无标签学习方法对多层次概率标签的适用性和对标注误差的鲁棒性，并通过理论推导与数值实验验证了该特性。基于多个公开的数据集开展了数值实验，验证了所提方法在利用运行维护记录时分别面对退化状态随机不确定性和认知不确定性的情况下的有效性；与现有的可利用不确定性标注的数据驱动方法定量对比，并验证了所提方法在识别精度和鲁棒性上的优越性。在联合循环运行机组的实际数据上应用了该方法，实现了对压气机进气滤网和汽轮机高压缸结垢退化状态的识别，验证了模型的识别精度。为缺少准确的设备部分负荷特性且设备历史退化状态不确定的条件下的联合循环运行机组设备退化状态识别提供了新的思路，设计并验证了一种利用联合循环机组运行维护记录标注设备历史退化状态的方案，降低建模对历史数据和人工标注的依赖性的同时提升了退化状态模型的识别精度，进一步提升了数据驱动退化识别方法在联合循环运行机组生产环境下的工程适用性。

研究内容四：针对多种非完备信息共存问题，提出基于联合学习的性能退化评估方法。该方法适用于同时存在测量信息不完备与状态信息不完备条件下的设备性能退化评估，能够建立设备在基准健康状态下的性能特性模型，并输出具有物理意义的性能退化指标。基于实际联合循环生产环境数据验证了该方法的可行性。该研究成果为联合循环生产环境下的性能退化评估提供了应用示范。

6.2 本文的主要创新点

本文的主要创新点如下：

(1) 提出了基于意外函数的不确定性建模与优化方法。该方法通过意外函数近似不确定性概率分布，将概率分布上的运算转化为实数算术，实现了与确定性优化求解器的直接结合。其建模性能与拉格朗日法求解相比，具有更高的鲁棒性

和精度；在测量不完备条件下建立联合循环机组的性能预测模型。

(2) 提出了基于自适应学习与伪标签的压气机进气滤网退化状态识别方法。该方法在自适应训练框架中引入伪标签生成与动态重加权技术，降低了数据驱动的退化状态识别算法对历史数据标注量的高依赖；利用中间模型预测逐步校准训练标签，有效缓解确认偏差与收敛至平凡解的风险，降低了数据驱动的状态识别算法对历史数据标注的数据分布假设的依赖，提升了数据驱动状态识别方法在联合循环运行机组生产环境下的工程应用实用性。

(3) 提出了基于概率正-无标签学习的状态识别方法。该方法设计了后验概率风险估计器，将损失函数扩展至概率标签设定，对状态信息的随机不确定性与认知不确定性具有高鲁棒性，能够恢复被噪声标注掩盖的真实状态信息。通过概率标签将定性知识与测量数据进行信息融合，利用先验知识补偿状态信息的不完备性，从而能够利用含不确定性的运维记录作为设备状态信息的间接标注，降低了历史数据的人工校核成本，提升了数据驱动状态识别方法在联合循环机组运行机组生产环境下的工程应用实用性。

6.3 研究展望

本文针对燃气-蒸汽联合循环生产环境下的非完备信息问题，提出了一系列解决方法，并在实际联合循环生产数据与公开基准数据集上开展验证。这些方法为应对生产环境下的非完备信息问题提供了理论指导与应用示范。然而，燃气-蒸汽联合循环生产环境下的非完备信息问题仍然是一个复杂且具有挑战性的问题，本文研究内容的不足和未来研究可以进一步探讨的方向如下：

(1) 本文对多拖一构型燃气蒸汽联合循环的偏置运行策略仍处于理论层面，工程实践中可以通过逐步增大偏置量的方式，验证偏置运行的可行性和经济性。

(2) 本文对联合循环设备的退化状态识别局限于退化较为明显的部分设备和部件，对于退化不明显或退化缓慢的设备部件的识别会有更高的难度，如何识别微小退化或缓慢退化，是有挑战性的研究方向。

(3) 本文对联合循环设备的数据驱动退化状态识别方法局限于识别退化程度，如何通过数据驱动方法进一步实现对于退化原因的分类是未来的研究方向。

(4) 本文对联合循环燃气轮机的退化建模局限于热效率这一单一的性能参数，对充分表征设备的退化仍然不足，可以增加对压气机和透平部件效率以及通流能力等细节的建模，获取更全面的燃气轮机退化模型。

参考文献

- [1] 国务院. 国务院关于完整准确全面贯彻新发展理念做好碳达峰碳中和工作的意见[R/OL]. 北京, 2021[2025-06-30]. https://www.gov.cn/zhengce/2021-10/24/content_5644613.htm.
- [2] 程晓青. “双碳”背景下我国电力行业发展策略研究[J]. 中国经贸导刊, 2025(10): 82-84.
- [3] 阎城. 燃气-蒸汽联合循环汽水系统性能变化与故障诊断[D]. 东南大学, 2021.
- [4] 蒋洪德, 任静, 李雪英, 等. 重型燃气轮机现状与发展趋势[J]. 中国电机工程学报, 2014(29): 5096-5102.
- [5] McKinsey & Company. Global energy perspective 2024[R/OL]. McKinsey & Company, 2023 [2025-06-30]. <https://www.mckinsey.com/industries/energy-and-materials/our-insights/global-energy-perspective>.
- [6] 余晓钟, 刘梦薇, 邱湖淼, 等. 我国天然气产业高质量发展路径探讨[J]. 中国工程科学, 2024, 26(4): 63-71.
- [7] 闫晶, 申涛. “双碳”目标下一谈我国天然气行业发展机遇与挑战[J]. 当代化工研究, 2022(3): 162-164.
- [8] 国家能源局. “十四五”现代能源体系规划[R/OL]. 北京, 2022[2025-06-25]. <https://www.gov.cn/zhengce/zhengceku/2022-03/23/5680759/files/ccc7dffca8f24880a80af12755558f4a.pdf>.
- [9] 周伟伟. 燃气-蒸汽联合循环供热机组调峰能力分析[D]. 华北电力大学, 2018.
- [10] 杨承, 黄志峰, 马晓茜. 联合循环机组中燃气轮机部件劣化对功率效率的敏感性分析[J]. 中国电机工程学报, 2015(22): 5803-5810.
- [11] 梁绍华, 黄磊, 顾海明, 等. 燃气-蒸汽联合循环机组调峰特性试验研究[C]//2017 年电站热工自动化技术交流会议论文集. 西安: 南京工程学院 and 江苏方天电力技术有限公司, 2017: 302-305.
- [12] 隆飞. 1000MW 火电机组深度调峰对汽轮机转子寿命损耗影响分析[J]. 电力设备管理, 2025(1): 58-60.
- [13] 皇甫泽玉, 胥建群, 孙剑, 等. 基于损拆分理论的联合循环机组性能研究[J]. 汽轮机技术, 2019, 61(5): 350-354, 391.
- [14] 蔡雨, 赵丽娟, 丁勇能, 等. S109FA 燃气-蒸汽联合循环机组 D10 型汽轮机性能诊断分析[J]. 华电技术, 2017, 39(6): 28-31.
- [15] 吴振廷. 能源运维系统设备故障预测性维护风险管控[C]//2025 工程技术与材料应用学术交流会论文集. 北京: 浙江朝泰科技有限公司, 2025: 1-3.
- [16] 工业和信息化部. “十四五”现代能源体系规划[R/OL]. 北京, 2021[2025-06-30]. <http://www.gov.cn/zhengce/zhengceku/2021-12/28/5664996/files/a22270cdb0504e518a7630fa318dbcd8.pdf>.
- [17] Wei D, Zhao Y, Liu H, et al. Where will china's shale gas industry go? a scenario analysis of socio-technical transition[J/OL]. Energy Strategy Reviews, 2022, 44: 100990. <https://www.sciencedirect.com/science/article/pii/S2211467X22001845>. DOI: <https://doi.org/10.1016/j.esr.2022.100990>.

- [18] 张晓声, 丁涛, 曲明, 等. 考虑燃气-蒸汽联合循环机组的机组组合建模综述[J]. 中国电机工程学报, 2023, 43(3): 969-986.
- [19] Diakunchak I S. Performance deterioration in industrial gas turbines[J/OL]. *Journal of Engineering for Gas Turbines and Power*, 1992, 114(2): 161-168. <https://doi.org/10.1115/1.2906565>.
- [20] Marner W, Suitor J. A survey of gas-side fouling in industrial heat-transfer equipment: NASA-CR-173469[R/OL]. Washington, D.C.: National Aeronautics and Space Administration, 1984 [2025-07-01]. <https://ntrs.nasa.gov/citations/19840013935>.
- [21] Zwebek A, Pilidis P. Degradation effects on combined cycle power plant performance: a part i: Gas turbine cycle component degradation effects[J/OL]. *Journal of Engineering for Gas Turbines and Power*, 2003, 125(3): 651-657. <https://doi.org/10.1115/1.1519271>.
- [22] Zaidan M A, Harrison R F, Mills A R, et al. Bayesian hierarchical models for aerospace gas turbine engine prognostics[J/OL]. *Expert Systems with Applications*, 2015, 42(1): 539-553. <https://www.sciencedirect.com/science/article/pii/S0957417414004837>. DOI: <https://doi.org/10.1016/j.eswa.2014.08.007>.
- [23] Zaidan M A, Mills A R, Harrison R F, et al. Gas turbine engine prognostics using bayesian hierarchical models: A variational approach[J/OL]. *Mechanical Systems and Signal Processing*, 2016, 70-71: 120-140. <https://www.sciencedirect.com/science/article/pii/S0888327015004094>. DOI: <https://doi.org/10.1016/j.ymssp.2015.09.014>.
- [24] Vatani A, Khorasani K, Meskin N. Turbo expo: Volume 6: Ceramics; controls, diagnostics and instrumentation; education; manufacturing materials and metallurgy; honors and awards health monitoring and degradation prognostics in gas turbine engines using dynamic neural networks[C/OL]. 2015: V006T05A030. <https://doi.org/10.1115/GT2015-44101>.
- [25] 沙俊辉, 章焰, 章恂. 9F 燃气轮机性能劣化的分析[J]. 燃气轮机技术, 2014(3): 56-59,65.
- [26] Li Y, Nilkitsaranont P. Gas turbine performance prognostic for condition-based maintenance [J/OL]. *Applied Energy*, 2009, 86(10): 2152-2161. <https://www.sciencedirect.com/science/article/pii/S0306261909000506>. DOI: <https://doi.org/10.1016/j.apenergy.2009.02.011>.
- [27] Daroogheh N, Meskin N, Khorasani K. A novel particle filter parameter prediction scheme for failure prognosis[C/OL]//2014 American Control Conference. 2014: 1735-1742. DOI: 10.1109/ACC.2014.6859021.
- [28] Cao Q, Chen S, Zheng Y, et al. Classification and prediction of gas turbine gas path degradation based on deep neural networks[J/OL]. *INTERNATIONAL JOURNAL OF ENERGY RESEARCH*, 2021, 45(7): 10513-10526. DOI: 10.1002/er.6539.
- [29] 项博超. S109FA 联合循环机组汽轮机性能变化和故障诊断[D]. 东南大学, 2023.
- [30] 孙跃武. 燃气轮机性能退化及趋势预测技术研究[D]. 哈尔滨工程大学, 2014.
- [31] 白云山, 田鑫, 石永锋, 等. 燃气轮机进气系统全寿命周期成本计算模型研究[J]. 汽轮机技术, 2018, 60(6): 423-426.
- [32] 华心果. 燃气-蒸汽联合循环机组汽水系统建模与故障诊断[D]. 东南大学, 2020.
- [33] Tsoutsanis E, Meskin N. Derivative-driven window-based regression method for gas turbine performance prognostics[J/OL]. *Energy*, 2017, 128: 302-311. <https://www.sciencedirect.com/science/article/pii/S0360544217305686>. DOI: <https://doi.org/10.1016/j.energy.2017.04.006>.

- [34] 房友龙, 刘东风, 刘永葆, 等. 燃气轮机结垢性能退化特征提取和剩余寿命预测[J]. 海军工程大学学报, 2018, 30(2): 100-104.
- [35] 刘东风, 房友龙, 刘永葆, 等. 船用三轴燃气轮机性能退化指标体系的构建[J]. 燃气轮机技术, 2019, 32(1): 26-33.
- [36] Massardo; S C T F. Heat recovery steam generator performance and degradation in a 400 mw combined cycle[J/OL]. Proceedings of the Institution of Mechanical Engineers, Part A: Journal of Power and Energy, 2009, 223(4): 369-378. <http://dx.doi.org/10.1243/09576509JPE695>.
- [37] Simon D, Simon D L. Aircraft turbofan engine health estimation using constrained kalman filtering[J/OL]. Journal of Engineering for Gas Turbines and Power, 2005, 127(2): 323-328. <https://doi.org/10.1115/1.1789153>.
- [38] Giantomassi A, Ferracuti F, Benini A, et al. International design engineering technical conferences and computers and information in engineering conference: Volume 3: 2011 asme/iecc international conference on mechatronic and embedded systems and applications, parts a and b hidden markov model for health estimation and prognosis of turbofan engines[C/OL]. 2011: 681-689. <https://doi.org/10.1115/DETC2011-48174>.
- [39] 白玉金, 康英伟, 黄伟, 等. 基于局部敏感哈希-双层随机森林的燃气轮机剩余使用寿命预测[J]. 科学技术与工程, 2021, 21(15): 6297-6304.
- [40] 曹启威, 陈时熠, 向文国. 数据驱动的燃气轮机联合循环机组退化分析与预测[J]. 中国电机工程学报, 2025, 45(6): 2243-2250.
- [41] Que Z J, Xiong Y, Xu Z G. A semi-supervised approach for steam turbine health prognostics based on gan and pf[C/OL]//2019 IEEE International Conference on Industrial Engineering and Engineering Management (IEEM). 2019: 1476-1480. DOI: 10.1109/IEEM44572.2019.8978717.
- [42] Carstens H, Xia X, Yadavalli S. Measurement uncertainty in energy monitoring: Present state of the art[J/OL]. Renewable and Sustainable Energy Reviews, 2018, 82: 2791-2805. <https://www.sciencedirect.com/science/article/pii/S1364032117313825>. DOI: <https://doi.org/10.1016/j.rser.2017.10.006>.
- [43] 王桐, 田亮. 基于均匀设计的供热机组安全运行区的计算方法[J]. 华北电力大学学报(自然科学版), 2016, 43(5): 88-93,104.
- [44] Pinelli M, Spina P R. Gas turbine field performance determination: Sources of uncertainties[J/OL]. Journal of Engineering for Gas Turbines and Power, 2000, 124(1): 155-160. <https://doi.org/10.1115/1.1413464>.
- [45] Sun S, Shan K, Wang S. Data-driven model-based flow measurement uncertainty quantification for building central cooling systems using a probabilistic approach[J/OL]. Science and Technology for the Built Environment, 2023, 29(3): 297-310. <https://doi.org/10.1080/23744731.2023.2170683>.
- [46] Xue H, Zhang M, Yu P, et al. A novel multi-sensor fusion algorithm based on uncertainty analysis[J/OL]. Sensors, 2021, 21(8). <https://www.mdpi.com/1424-8220/21/8/2713>. DOI: 10.3390/s21082713.

- [47] Vemulapalli S, Venkata S K. Soft sensor for an orifice flowmeter in presence of disturbances [J/OL]. *Flow Measurement and Instrumentation*, 2022, 86: 102178. <https://www.sciencedirect.com/science/article/pii/S0955598622000577>. DOI: <https://doi.org/10.1016/j.flowmeasinst.2022.102178>.
- [48] 田亮, 王桐. 供热机组汽轮机低压缸排汽流量软测量[J]. *系统仿真学报*, 2018, 30(5): 1803-1811.
- [49] 刘佳. 基于运行数据的燃气轮机性能评估方法[J]. *热力透平*, 2022, 51(4): 261-264.
- [50] Colera M, Ángel Soria, Ballester J. A numerical scheme for the thermodynamic analysis of gas turbines[J/OL]. *Applied Thermal Engineering*, 2019, 147: 521-536. <https://www.sciencedirect.com/science/article/pii/S135943111831295X>. DOI: <https://doi.org/10.1016/j.applthermaleng.2018.10.103>.
- [51] Kim S. Generating a virtual physical model through measurement data and reverse engineering: Applying a performance prediction model for an industrial gas turbine during start-up[J/OL]. *Applied Thermal Engineering*, 2023, 232: 120927. <https://www.sciencedirect.com/science/article/pii/S1359431123009560>. DOI: <https://doi.org/10.1016/j.applthermaleng.2023.120927>.
- [52] Sadrian V, Lakzian E, Kim H D. Optimization of operating conditions in the stage of steam turbine by black-box method[J/OL]. *International Communications in Heat and Mass Transfer*, 2024, 155: 107499. <https://www.sciencedirect.com/science/article/pii/S0735193324002616>. DOI: <https://doi.org/10.1016/j.icheatmasstransfer.2024.107499>.
- [53] Liu C Y, Senftle T P. Finding physical insights in catalysis with machine learning[J/OL]. *Current Opinion in Chemical Engineering*, 2022, 37: 100832. <https://www.sciencedirect.com/science/article/pii/S2211339822000429>. DOI: <https://doi.org/10.1016/j.coche.2022.100832>.
- [54] Estrada-Flores S, Merts I, De Ketelaere B, et al. Development and validation of “grey-box” models for refrigeration applications: A review of key concepts[J/OL]. *International Journal of Refrigeration*, 2006, 29(6): 931-946. <https://www.sciencedirect.com/science/article/pii/S0140700706000983>. DOI: <https://doi.org/10.1016/j.ijrefrig.2006.03.018>.
- [55] Sahakyan M, Aung Z, Rahwan T. Explainable artificial intelligence for tabular data: A survey [J/OL]. *IEEE Access*, 2021, 9: 135392-135422. DOI: 10.1109/ACCESS.2021.3116481.
- [56] 孟成. 含供气环节的重型燃气轮机仿真及性能退化预估[D]. 上海交通大学, 2015.
- [57] 秦祖志, 董纯涛, 严志远, 等. 环境温度对 PG9351FA 燃气轮机及联合循环性能影响的研究[J]. *发电设备*, 2024, 38(6): 335-340.
- [58] Wang Z, Zhang Y, Zeng B, et al. Data-driven modeling of aero-derivative gas turbine start-up [J/OL]. *Journal of Thermal Science*, 2025, 34: 1750-1757. DOI: 10.1007/s11630-025-2165-7.
- [59] Ying Y, Li J. An improved performance diagnostic method for industrial gas turbines with consideration of intake and exhaust system[J/OL]. *Applied Thermal Engineering*, 2023, 222: 119907. <https://www.sciencedirect.com/science/article/pii/S1359431122018373>. DOI: <https://doi.org/10.1016/j.applthermaleng.2022.119907>.
- [60] 王一丰, 翟春华, 黄庆, 等. 大功率燃气轮机联合循环机组三压再热余热锅炉建模及变负荷运行规律研究[J]. *热力发电*, 2023, 52(12): 79-89.

-
- [61] Li C, Li S, Feng Y, et al. Small data challenges for intelligent prognostics and health management: a review[J/OL]. *Artificial Intelligence Review*, 2024, 57(8): 214. DOI: 10.1007/s10462-024-10820-4.
- [62] Shohet R, Kandil M S, Wang Y, et al. Fault detection for non-condensing boilers using simulated building automation system sensor data[J/OL]. *Advanced Engineering Informatics*, 2020, 46: 101176. <https://www.sciencedirect.com/science/article/pii/S1474034620301476>. DOI: <https://doi.org/10.1016/j.aei.2020.101176>.
- [63] Li W, Li H, Gu S, et al. Process fault diagnosis with model- and knowledge-based approaches: Advances and opportunities[J/OL]. *Control Engineering Practice*, 2020, 105: 104637. <https://www.sciencedirect.com/science/article/pii/S0967066120302070>. DOI: <https://doi.org/10.1016/j.conengprac.2020.104637>.
- [64] Zhu Y, Zhao S, Zhang Y, et al. A review of statistical-based fault detection and diagnosis with probabilistic models[J/OL]. *Symmetry*, 2024, 16(4). <https://www.mdpi.com/2073-8994/16/4/455>. DOI: 10.3390/sym16040455.
- [65] Tidriri K, Chatti N, Verron S, et al. Bridging data-driven and model-based approaches for process fault diagnosis and health monitoring: A review of researches and future challenges [J/OL]. *Annual Reviews in Control*, 2016, 42: 63-81. <https://www.sciencedirect.com/science/article/pii/S1367578816300669>. DOI: <https://doi.org/10.1016/j.arcontrol.2016.09.008>.
- [66] DENG W, NGUYEN K T, MEDJAHHER K, et al. Physics-informed machine learning in prognostics and health management: State of the art and challenges[J/OL]. *Applied Mathematical Modelling*, 2023, 124: 325-352. <https://www.sciencedirect.com/science/article/pii/S0307904X23003086>. DOI: <https://doi.org/10.1016/j.apm.2023.07.011>.
- [67] Sekine Y, Akimoto Y, Kunugi M, et al. Fault diagnosis of power systems[J/OL]. *Proceedings of the IEEE*, 1992, 80(5): 673-683. DOI: 10.1109/5.137222.
- [68] Yang X, Zhu C. Industrial expert systems review: A comprehensive analysis of typical applications[J/OL]. *IEEE Access*, 2024, 12: 88558-88584. DOI: 10.1109/ACCESS.2024.3419047.
- [69] Huang J M, Chai M J, Zhang R Y. Fault diagnosis expert system applied on machinery industry [J/OL]. *Applied Mechanics and Materials*, 2013, 347-350: 461-465. <http://dx.doi.org/10.4028/www.scientific.net/amm.347-350.461>.
- [70] Cortes C, Vapnik V. Support-vector networks[J/OL]. *Machine Learning*, 1995, 20(3): 273-297. <http://dx.doi.org/10.1007/bf00994018>.
- [71] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks [J/OL]. *Science*, 2006, 313(5786): 504-507. <https://www.science.org/doi/abs/10.1126/science.1127647>.
- [72] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J/OL]. *Commun. ACM*, 2017, 60(6): 84-90. <https://doi.org/10.1145/3065386>.
- [73] Bernieri A, Betta G, Pietrosanto A, et al. A neural network approach to instrument fault detection and isolation[J/OL]. *IEEE Transactions on Instrumentation and Measurement*, 1995, 44(3): 747-750. DOI: 10.1109/19.387323.

- [74] Renders J, Goosens A, de Viron F, et al. A prototype neural network to perform early warning in nuclear power plant[J/OL]. *Fuzzy Sets and Systems*, 1995, 74(1): 139-151. <https://www.sciencedirect.com/science/article/pii/016501149500015D>. DOI: [https://doi.org/10.1016/0165-0114\(95\)00015-D](https://doi.org/10.1016/0165-0114(95)00015-D).
- [75] Zhao R, Wang D, Yan R, et al. Machine health monitoring using local feature-based gated recurrent unit networks[J/OL]. *IEEE Transactions on Industrial Electronics*, 2018, 65(2): 1539-1548. DOI: 10.1109/TIE.2017.2733438.
- [76] Ma Y, Jia X, Bai H. A new fault diagnosis method based on convolutional neural network and compressive sensing[J/OL]. *Journal of Mechanical Science and Technology*, 2019, 33(11): 5177-5188. DOI: 10.1007/s12206-019-1007-5.
- [77] He W, Lin L, Fu S, et al. Differential contrast guidance for aeroengine fault diagnosis with limited data[J/OL]. *Journal of Intelligent Manufacturing*, 2025, 36: 1409-1427. DOI: 10.1007/s10845-023-02305-y.
- [78] Ren Z, Han H, Cui X, et al. Novel data-pulling-based strategy for chiller fault diagnosis in data-scarce scenarios[J/OL]. *Energy*, 2023, 279: 128019. <https://www.sciencedirect.com/science/article/pii/S0360544223014135>. DOI: <https://doi.org/10.1016/j.energy.2023.128019>.
- [79] Pang G, Shen C, Cao L, et al. Deep learning for anomaly detection: A review[Z]. 2020.
- [80] Jiang Q, Yan X, Huang B. Performance-driven distributed pca process monitoring based on fault-relevant variable selection and bayesian inference[J/OL]. *IEEE Transactions on Industrial Electronics*, 2016, 63(1): 377-386. DOI: 10.1109/TIE.2015.2466557.
- [81] Dong Y, Qin S J. A novel dynamic pca algorithm for dynamic data modeling and process monitoring[J/OL]. *Journal of Process Control*, 2018, 67: 1-11. <https://www.sciencedirect.com/science/article/pii/S095915241730094X>. DOI: <https://doi.org/10.1016/j.jprocont.2017.05.002>.
- [82] Chen Z, Ding S X, Peng T, et al. Fault detection for non-gaussian processes using generalized canonical correlation analysis and randomized algorithms[J/OL]. *IEEE Transactions on Industrial Electronics*, 2018, 65(2): 1559-1567. DOI: 10.1109/TIE.2017.2733501.
- [83] Martin, E. B, Morris, et al. Process performance monitoring using multivariate statistical process control[J]. *Control Theory and Applications*, IEE Proceedings -, 1996.
- [84] Tang X, Zeng S, Yu F, et al. Self-supervised anomaly pattern detection for large scale industrial data[J/OL]. *Neurocomputing*, 2023, 515: 1-12. <https://www.sciencedirect.com/science/article/pii/S0925231222011572>. DOI: <https://doi.org/10.1016/j.neucom.2022.09.069>.
- [85] Deng Z, Chen X, Xie S, et al. Semi-supervised discriminative projective dictionary pair learning and its application to industrial process[J/OL]. *IEEE Transactions on Industrial Informatics*, 2023, 19(3): 3119-3132. DOI: 10.1109/TII.2022.3168300.
- [86] Zhang J, Xu Y, Chen H, et al. A novel building heat pump system semi-supervised fault detection and diagnosis method under small and imbalanced data[J/OL]. *Engineering Applications of Artificial Intelligence*, 2023, 123: 106316. <https://www.sciencedirect.com/science/article/pii/S0952197623005006>. DOI: <https://doi.org/10.1016/j.engappai.2023.106316>.

- [87] Miao J, Deng Z, Deng C, et al. Boosting efficient attention assisted cyclic adversarial auto-encoder for rotating component fault diagnosis under low label rates[J/OL]. *Engineering Applications of Artificial Intelligence*, 2024, 133: 108499. <https://www.sciencedirect.com/science/article/pii/S0952197624006572>. DOI: <https://doi.org/10.1016/j.engappai.2024.108499>.
- [88] Zhang J, Cheng L, Yang Z, et al. An enhanced semi-supervised learning method with self-supervised and adaptive threshold for fault detection and classification in urban power grids [J/OL]. *Energy and AI*, 2024, 17: 100377. <https://www.sciencedirect.com/science/article/pii/S2666546824000430>. DOI: <https://doi.org/10.1016/j.egyai.2024.100377>.
- [89] Fan C, Liu X, Xue P, et al. Statistical characterization of semi-supervised neural networks for fault detection and diagnosis of air handling units[J/OL]. *Energy and Buildings*, 2021, 234: 110733. <https://www.sciencedirect.com/science/article/pii/S0378778821000177>. DOI: <https://doi.org/10.1016/j.enbuild.2021.110733>.
- [90] Sun G, Pan X, Liang Q, et al. Dynamic balanced teacher: A semi-supervised object detection algorithm for train faults[J/OL]. *Engineering Applications of Artificial Intelligence*, 2024, 138: 109407. <https://www.sciencedirect.com/science/article/pii/S0952197624015653>. DOI: <https://doi.org/10.1016/j.engappai.2024.109407>.
- [91] Tan X, Qi J, Gan J Q, et al. Multi-filter semi-supervised transformer model for fault diagnosis [J/OL]. *Engineering Applications of Artificial Intelligence*, 2023, 124: 106498. <https://www.sciencedirect.com/science/article/pii/S0952197623006826>. DOI: <https://doi.org/10.1016/j.engappai.2023.106498>.
- [92] Dong H, Frusque G, Zhao Y, et al. Nng-mix: Improving semi-supervised anomaly detection with pseudo-anomaly generation[J/OL]. *IEEE Transactions on Neural Networks and Learning Systems*, 2025, 36(6): 10635-10647. DOI: 10.1109/TNNLS.2024.3497801.
- [93] Lee S, Kim D, Noh M, et al. Propeller fault-detection method for electric-propulsion aircraft using motor signals and generative model-based semi-supervised learning[J/OL]. *Engineering Applications of Artificial Intelligence*, 2025, 162: 112301. <https://www.sciencedirect.com/science/article/pii/S0952197625023097>. DOI: <https://doi.org/10.1016/j.engappai.2025.112301>.
- [94] Chen X, Chen Z, Guo L, et al. Pseudo-label assisted semi-supervised adversarial enhancement learning for fault diagnosis of gearbox degradation with limited data[J/OL]. *Mechanical Systems and Signal Processing*, 2025, 224: 112108. <https://www.sciencedirect.com/science/article/pii/S0888327024010069>. DOI: <https://doi.org/10.1016/j.ymssp.2024.112108>.
- [95] Lu L, Wang J, Huang W, et al. Dual contrastive learning for semi-supervised fault diagnosis under extremely low label rate[J/OL]. *IEEE Transactions on Instrumentation and Measurement*, 2023, 72: 1-12. DOI: 10.1109/TIM.2023.3284954.
- [96] Yang J, Zhao C. Addressing the label dilemma: A self-semi-supervised step-wise complementary label boosting strategy for industrial anomaly detection[J/OL]. *Reliability Engineering & System Safety*, 2025, 264: 111369. <https://www.sciencedirect.com/science/article/pii/S0951832025005708>. DOI: <https://doi.org/10.1016/j.ress.2025.111369>.
- [97] Chen W, Qiu Y, Feng Y, et al. Diagnosis of wind turbine faults with transfer learning algorithms [J/OL]. *Renewable Energy*, 2021, 163: 2053-2067. <https://www.sciencedirect.com/science/article/pii/S0960148120316931>. DOI: 10.1016/j.renene.2020.10.121.

-
- [98] Zhao W, Li W, Du Y. Adaptive wind turbine blade surface defect detection based on deep learning and transfer learning[J/OL]. *Structural Health Monitoring*, 2025. <https://doi.org/10.1177/14759217251349118>.
 - [99] Kiryo R, Niu G, du Plessis M C, et al. Positive-unlabeled learning with non-negative risk estimator[C]//Guyon I, Luxburg U V, Bengio S, et al. *Advances in Neural Information Processing Systems*: Vol. 30. Curran Associates, Inc., 2017.
 - [100] Helton J, Johnson J, Oberkampf W. An exploration of alternative approaches to the representation of uncertainty in model predictions[J/OL]. *Reliability Engineering & System Safety*, 2004, 85(1): 39-71. <https://www.sciencedirect.com/science/article/pii/S0951832004000511>. DOI: <https://doi.org/10.1016/j.ress.2004.03.025>.
 - [101] Wilson A G, McNamara L A, Wilson G D. Information integration for complex systems[J/OL]. *Reliability Engineering & System Safety*, 2007, 92(1): 121-130. <https://www.sciencedirect.com/science/article/pii/S0951832006001529>. DOI: <https://doi.org/10.1016/j.ress.2006.07.003>.
 - [102] Uzhga-Rebrov O, Kuleshova G. Some approaches to combining probabilistic and fuzzy uncertainties[J/OL]. *Information Technology and Management Science*, 2012, 15(1). DOI: 10.2478/v10313-012-0030-7.
 - [103] RAMER A. Conditional possibility measures[M/OL]//Dubois D, Prade H, Yager R R. *Readings in Fuzzy Sets for Intelligent Systems*. Morgan Kaufmann, 1993: 233-240. <https://www.sciencedirect.com/science/article/pii/B9781483214504500237>. DOI: <https://doi.org/10.1016/B978-1-4832-1450-4.50023-7>.
 - [104] Mei W, Li M, Cheng Y, et al. The sigma-max system induced from randomness and fuzziness [J/OL]. *CoRR*, 2021, abs/2110.07722. <https://arxiv.org/abs/2110.07722>.
 - [105] Neumaier A. Fuzzy modeling in terms of surprise[J/OL]. *Fuzzy Sets and Systems*, 2003, 135(1): 21-38. <https://www.sciencedirect.com/science/article/pii/S0165011402002488>. DOI: [https://doi.org/10.1016/S0165-0114\(02\)00248-8](https://doi.org/10.1016/S0165-0114(02)00248-8).
 - [106] Ji X, Lu X, Yan J. Survey of experimental data and assessment of calculation methods of properties for the air-water mixture[J/OL]. *Applied Thermal Engineering*, 2003, 23(17): 2213-2228. <https://www.sciencedirect.com/science/article/pii/S1359431103001911>. DOI: [https://doi.org/10.1016/S1359-4311\(03\)00191-1](https://doi.org/10.1016/S1359-4311(03)00191-1).
 - [107] Meher-Homji C B, Bromley A F. Gas turbine axial compressor fouling and washing.[C/OL]// *Proceedings of the 30th Turbomachinery Symposium*. 2004. <https://api.semanticscholar.org/CorpusID:17820172>.
 - [108] Kurz R, Brun K. Degradation of gas turbine performance in natural gas service[J/OL]. *Journal of Natural Gas Science and Engineering*, 2009, 1(3): 95-102. <https://www.sciencedirect.com/science/article/pii/S1875510009000250>. DOI: <https://doi.org/10.1016/j.jngse.2009.03.007>.
 - [109] Zhang B, Zuo W. Learning from positive and unlabeled examples: A survey[C/OL]//2008 *International Symposiums on Information Processing*. 2008: 650-654. DOI: 10.1109/ISIP.2008.79.
 - [110] Elkan C, Noto K. Learning classifiers from only positive and unlabeled data[C/OL]// *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2008: 213-220. DOI: 10.1145/1401890.1401920.

- [111] Downs J, Vogel E. A plant-wide industrial process control problem[J/OL]. *Computers & Chemical Engineering*, 1993, 17(3): 245-255. <https://www.sciencedirect.com/science/article/pii/0098135493800181>. DOI: [https://doi.org/10.1016/0098-1354\(93\)80018-I](https://doi.org/10.1016/0098-1354(93)80018-I).
- [112] Quiñones-Grueiro M, Prieto-Moreno A, Verde C, et al. Data-driven monitoring of multimode continuous processes: A review[J/OL]. *Chemometrics and Intelligent Laboratory Systems*, 2019, 189: 56-71. <https://www.sciencedirect.com/science/article/pii/S0169743918306774>. DOI: <https://doi.org/10.1016/j.chemolab.2019.03.012>.
- [113] Rieth C A, Amsel B D, Tran R, et al. Issues and advances in anomaly detection evaluation for joint human-automated systems[C/OL]//*Advances in Human Factors in Robots and Unmanned Systems*. 2017. <https://api.semanticscholar.org/CorpusID:67434155>.
- [114] Melo A, Câmara M M, Clavijo N, et al. Open benchmarks for assessment of process monitoring and fault diagnosis techniques: A review and critical analysis[J/OL]. *Computers & Chemical Engineering*, 2022, 165: 107964. <https://www.sciencedirect.com/science/article/pii/S0098135422003003>. DOI: <https://doi.org/10.1016/j.compchemeng.2022.107964>.
- [115] Bartyś M, Patton R, Syfert M, et al. Introduction to the damadics actuator fdi benchmark study [J/OL]. *Control Engineering Practice*, 2006, 14(6): 577-596. <https://www.sciencedirect.com/science/article/pii/S0967066105001796>. DOI: <https://doi.org/10.1016/j.conengprac.2005.06.015>.
- [116] Zeng X, Zhong Y, Lin W, et al. Predicting disease-associated circular rnas using deep forests combined with positive-unlabeled learning methods[J/OL]. *Briefings in Bioinformatics*, 2019, 21(4): 1425-1436. <https://doi.org/10.1093/bib/bbz080>.
- [117] Jiang Y, Xu Q, Zhao Y, et al. Positive-unlabeled learning with label distribution alignment [J/OL]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023, 45(12): 15345-15363. DOI: 10.1109/TPAMI.2023.3319431.
- [118] Zhu Z, Wang L, Zhao P, et al. Robust positive-unlabeled learning via noise negative sample self-correction[C/OL]//*KDD '23: Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. New York, NY, USA: Association for Computing Machinery, 2023: 3663-3673. <https://doi.org/10.1145/3580305.3599491>.
- [119] Su G, Chen W, Xu M. Positive-unlabeled learning from imbalanced data[C/OL]//*International Joint Conference on Artificial Intelligence*. 2021. <https://api.semanticscholar.org/CorpusID:237100572>.
- [120] Qian M, Wu H, Li Y F. Wind turbine blade early fault detection with faulty label unknown and labeling bias[J/OL]. *IEEE Transactions on Industrial Informatics*, 2023, 19(7): 8116-8126. DOI: 10.1109/TII.2022.3216816.
- [121] Salih Hasan B M, Abdulazeez A M. A review of principal component analysis algorithm for dimensionality reduction[J/OL]. *Journal of Soft Computing and Data Mining*, 2021, 02(01). <http://dx.doi.org/10.30880/jscdm.2021.02.01.003>.
- [122] Plessis M, Niu G, Sugiyama M. Analysis of learning from positive and unlabeled data[J]. *Advances in Neural Information Processing Systems*, 2014, 1: 703-711.
- [123] Krizhevsky A. Learning multiple layers of features from tiny images[R]. Toronto University, 2009.

-
- [124] Xiao H, Rasul K, Vollgraf R. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms[EB/OL]. (2017-08-28).
 - [125] Long L, Wang H, Jiang Z, et al. Positive-unlabeled learning by latent group-aware meta disambiguation[C/OL]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 23138-23147. DOI: 10.1109/CVPR52733.2024.02183.
 - [126] Leahy K, Hu R L, Konstantakopoulos I C, et al. Diagnosing wind turbine faults using machine learning techniques applied to operational data[C/OL]//2016 IEEE International Conference on Prognostics and Health Management (ICPHM). 2016: 1-8. DOI: 10.1109/ICPHM.2016.7542860.
 - [127] Arora N, Allenby G M, Ginter J L. A hierarchical bayes model of primary and secondary demand[J]. Marketing Science, 1998, 17(1): 29-44.
 - [128] Crawshaw M. Multi-task learning with deep neural networks: A survey[J/OL]. CoRR, 2020, abs/2009.09796. <https://arxiv.org/abs/2009.09796>.
 - [129] Evgeniou T, Pontil M. Regularized multi-task learning[C/OL]//KDD '04: . New York, NY, USA: Association for Computing Machinery, 2004: 109-117. <https://doi.org/10.1145/1014052.1014067>.
 - [130] Yang P, Huang K, Hussain A. A review on multi-task metric learning[J/OL]. Big Data Analytics, 2018, 3(1): 3. DOI: 10.1186/s41044-018-0029-9.
 - [131] Sloman S J, Bharti A, Martinelli J, et al. Bayesian active learning in the presence of nuisance parameters[A/OL]. 2024. arXiv: 2310.14968. <https://arxiv.org/abs/2310.14968>.
 - [132] Vandenhende S, Georgoulis S, Van Gansbeke W, et al. Multi-task learning for dense prediction tasks: A survey[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(7): 3614-3633. DOI: 10.1109/TPAMI.2021.3054719.
 - [133] Zhang W, Wang K, Wang Y, et al. A loss-balanced multi-task model for simultaneous detection and segmentation[J/OL]. Neurocomputing, 2021, 428: 65-78. <https://www.sciencedirect.com/science/article/pii/S0925231220318105>. DOI: <https://doi.org/10.1016/j.neucom.2020.11.024>.
 - [134] Liang S, Zhang Y. A simple general approach to balance task difficulty in multi-task learning[J/OL]. CoRR, 2020, abs/2002.04792. <https://arxiv.org/abs/2002.04792>.
 - [135] Iapws industrial formulation 1997 for the thermodynamic properties of water and steam [M/OL]//International Steam Tables: Properties of Water and Steam Based on the Industrial Formulation IAPWS-IF97. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008: 7-150. https://doi.org/10.1007/978-3-540-74234-0_3.
 - [136] Bell I, Wronski J, Quoilin S, et al. Pure and pseudo-pure fluid thermophysical property evaluation and the open-source thermophysical property library coolprop[J/OL]. Industrial & engineering chemistry research, 2014, 53: 2498-2508. DOI: 10.1021/ie4033999.

致 谢

论文的最后，向所有关心和帮助我的人致以最诚挚的谢意。

首先，我要衷心感谢我的导师蒋东翔教授和刘超老师。从博士论文的选题、研究框架的构建，到研究思路的梳理与完善，蒋东翔教授始终给予我悉心指导与宝贵建议，使我在学术道路上不断成长。刘超老师在研究期间对我工作安排的规划与时间上的关照，为我创造了良好的研究条件，让我能够有计划地投入研究与论文写作，在此深表感激。

感谢课题组的各位师兄师弟，无论是在科研探索中遇到的困惑，还是在项目工作中面临的压力，你们都给予了我支持与陪伴。

感谢项目合作单位的各位同事，在科研协作与项目实施过程中，你们的专业见解与默契配合为本文的顺利推进提供了坚实保障，彼此的交流与支持让我受益良多。

最后，我要深深感谢我的父母。你们始终在我身后默默守护，在重大问题的选择上给予我方向指引，在生活点滴中给予我无微不至的关怀。你们的理解与支持，是我坚持完成学业的根本动力。

在此，再次向所有帮助过我的人致以最真诚的谢意！

声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名：_____ 日 期：_____

个人简历、在学期间完成的相关学术成果

个人简历

宋克禹，出生于 1998 年 4 月 27 日。

2016 年 9 月考入清华大学能源与动力工程系，2020 年 7 月本科毕业并获得工学学士学位。

2020 年 9 月免试进入清华大学能源与动力工程系攻读博士至今。

在学期间完成的相关学术成果

论文发表：

- [1] **Song K**, Chao L, Jiang D. A positive-unlabeled learning approach for industrial anomaly detection based on self-adaptive training[J]. Neurocomputing, 2025. DOI: 10.1016/j.neucom.2025.130488. (SCI 源刊收录, IF=6.5, WOS:001502690700002)
- [2] **Song K**, Chao L, Jiang D. Uncertainty-Aware Modeling for Optimal Asymmetrical Load Distribution in Multi-Unit Combined Cycle Power Plants. (在投论文, Applied Thermal Engineering 大修)
- [3] **Song K**, Chao L, Jiang D. Addressing Annotation Uncertainty in Wind Turbine Anomaly Detection: A Probabilistic Positive-Unlabeled (PPU) Learning Approach. (在投论文, Engineering Applications of Artificial Intelligence 大修)
- [4] **Song K**, Chao L, Jiang D. Semi-supervised Anomaly Detection on Industrial Process Data Using Self-adaptive Training[C]// International conference on the Efficiency and Performance Engineering Network, 2023. DOI: 10.1007/978-3-031-49421-5_74. (EI 收录, Accession number: 20242416247600)
- [5] **Song K**, Ding Y, Chao L, Jiang D. A Supervised Early Anomaly Detection Procedure for Industrial Process Using Pseudo System State to Bypass Manual Labeling[C]. 6th International Conference on Power and Energy Engineering, 2022. DOI: 10.1109/ICPEE56418.2022.10050319. (EI 收录, Accession number: 20231213743222)
- [6] **Song K**, Zizhen L, Chao L, Jiang D. Trade-offs Between Model Fidelity and Complexity in CCPP Load Forecasting: A Comparative Study via Quantitative Analysis[C]. AI for Energy Engineering (AI4EE), 2026.
- [7] Yao J, Liu C, **Song K**, et al. Fault diagnosis of planetary gearbox based on acoustic signals[J]. Applied Acoustics, 2021, 181: 108151. (SCI 收录)

专利：

- [8] 蒋东翔, 樊昱玮, **宋克禹**, 刘超. 故障诊断模型的构建方法及装置、故障诊断方法及装置:CN202510197311.X[P]. 2025-03-25.
- [9] 蒋东翔, 刘超, 姚家驰, 吴锐, **宋克禹**, 王志军, 吕建海, 王智慧. 窑炉运行状态确定方法、装置和计算机设备:CN202210224068.2[P]. 2022-06-17.
- [10] 王俊华, 崔艾军, 蒋东翔, 刘超, 吴锐, **宋克禹**. 登机廊桥在线预警与故障诊断装置:CN201922148601.8[P]. 2020-11-03.

软件著作权：

- [11] 刘超, 宋焘, 郭腾博, **宋克禹**, 蒋东翔. 多型号燃气轮机性能计算平台:CN2024SR0952844
- [12] 刘超, 冯晨龙, **宋克禹**, 蒋东翔. 柔性转子多临界多平面协调动平衡软件:CN2022SR0597521
- [13] 刘超, **宋克禹**, 蒋东翔, 吴锐. 基于多源异构数据采集与实时分析的边缘智能软件系统:CN2022SR0000800.

指导教师评语

答辩委员会决议书